

時間窓可変型局所モデル構築に基づく CO₂ 濃度からの滞在 人流の推定

角田 啓介¹ 荒井 直樹¹ 尾花 和昭¹

概要：本稿では、室内の滞在人数や滞在時間といった人流情報を低コストに推定することを目的とし、時定数可変型局所モデル構築による室内 CO₂ 濃度からの滞在人数・時間 (人数, 人 × 秒) の推定手法を提案する。室内における二酸化炭素 (CO₂) の濃度から、滞在人数を推定する試みはいくつかなされてきた。しかしながら、特に広い空間を持つ屋内においては、室内における滞在人数と人が呼気で排出する CO₂ の濃度の関係は、変化の速度が大きく異なるだけでなく、換気量が変化すると滞在人数や滞在時間が CO₂ 濃度に影響を及ぼすまでの時定数も変化する。このように、実環境においてはある変数がほかの変数に影響を及ぼすまでの時定数が様々な要因で変化する場合、その 2 変数間の関係は一意に定義できないため、変数間の統一的なモデルを構築し、推定に使用するのは困難である。本稿では Just In Time モデリングと呼ばれる局所モデル構築に、時間窓幅の自動選択を組み込むことで、時定数が変化するケースにおいても局所モデルを構築できる手法を提案する。そして、本手法を実際の室内における CO₂ 濃度を用いた滞在時間・人秒の推定に適用することで、その有効性を示す。

Estimating Number and Dwell Time of Visitors from CO₂ Concentration based on Partial Modeling with Dynamic Time Window

Keisuke Tsunoda¹ Naoki Arai¹ Kazuaki Obana¹

1. 序論

近年、ショッピングセンタなどの商業ビルや都市部のオフィスビル、あるいは主要駅といった大規模施設は、単なる商業やビジネスの場所、交通期間へのアクセスを提供するだけでなく、街にとっての重要なインフラになりつつある。一方で、特に先進国諸国においては施設を含むインフラの老朽化や少子高齢化による労働人口減少、市場競争による利益向上への圧力があり、ICT の力によって、これらの大規模施設が持つ魅力を高めると同時に、施設の管理・運営をより一層効率化することが求められている [1]。

これらの施設を特徴づける基礎的なデータの 1 つは、そこへ集まる人の人数や滞在時間等の傾向、すなわち「人流」と言われる情報である。いつ、人がどのぐらい来て、どの程度滞在するかといったデータは、施設の使われ方がわかると同時に、メンテナンスが容易な時期や時間帯を把握することもでき、施設の魅力向上と運営・管理の効率化の両面で役

立つ [2]。従来、このような人流に関するデータは、施設内に複数設置されたカメラ [3] や、Laser Range Finder(LRF) [4] のようなセンサが用いられてきた。しかしながら、特に広大な空間を持つ室内を対象とする場合、これらの従来手法では多くのセンサを設置する必要があり、センサの設置と運用のコストが高くなる欠点がある。その解決策として、施設内に既設の Building Automation System(BAS) [5] や Building Energy Management System(BEMS) [6]、あるいは独立して設置したセンサで取得可能な空間内の二酸化炭素濃度 (CO₂ 濃度) から、滞在した人数や、人と滞在時間の積 (人・分, 人・秒) を推定する手法 [7] がある。しかしながら、大規模施設において CO₂ 濃度からそのような人流を推定するには 2 つの困難がある。1 つは、特に広い空間においては、人の動きと、人の呼気による CO₂ 濃度の変化速度は大きく異なるという、時定数の観点である。もう 1 つは、そのような施設の空間では一般に、設置された換気機能などによって自動的な換気が行われるケースが多く、上記の時定数が換気の状態によって変化する点であ

¹ 日本電信電話株式会社 NTT スマートデータサイエンスセンタ

る。よって、このような大規模かつ換気がなされるような施設内空間において、BAS や BEMS で用いられるような CO₂ センサを活用しつつ、人流と CO₂ 濃度の間に統一的なモデルを構築し、推定することは困難であった。

そこで本稿では、換気を伴う室内における CO₂ 濃度と人流のような、時定数も変化する複雑な関係性をモデル化するための手法として、時間窓可変型局所モデル構築手法を提案し、低コストな人流情報の推定を試みる。

2. 関連研究

ショッピングセンタといった商業ビルやオフィスビルにおける滞在人数やその滞在時間といった人流を把握し、施設の魅力向上や管理・運営の効率化を目指した取り組みはいくつも行われてきた。ここでは人流把握手法を直接的計測と間接的計測に分類したうえで、それぞれにおける代表的な手法について取り上げる。

2.1 直接的計測による人流把握

直接的な方法としては、屋内に人を検知できるセンサを取り付ける方法である。例としてはカメラを用いたもの [3]、Laser Range Finder(LRF) [4]、LiDAR [8] といった光の反射を用いたものや、ラインカウンタのような定義された線を跨いだ人数をカウントするもの [9] がある。これらの方法は任意の箇所にセンサを設置して計測し続けることが前提であり、計測の確実性や精度は高いといえる。また、カメラや LRF、LiDAR を用いた場合、通過人数だけでなく滞在時間に関する情報や、個人の動きをトラッキングする場合は移動速度や方向も計測可能である。一方で、特に広い空間での計測には、複数のセンサだけでなくそれらのデータの通信・統合・分析システムの導入と維持管理が必要となり、施設の管理・運営者の負担は大きくなる。加えてカメラを利用する場合は、顔を隠す、事前に被写体の承諾をもらうといったプライバシー面での対策が必要となる。

2.2 間接的計測による人流把握

間接的な方法とは、人が影響する何かしらのデータを計測し、そこから人流を推定する方法である。例として、人が持つデバイスの Bluetooth や WiFi といった信号を検知する方法 [10]、人の動きを WiFi の電波強度で検知する方法 [11]、人の呼気に含まれる二酸化炭素 (CO₂) に着目し、その濃度の変化を検知する方法 [7] がある。これらの手法のメリットとして、LRF や LiDAR と比較して測定デバイスが安価な点、WiFi ルータや BEMS の一部として設置された CO₂ 濃度センサのような既設センサを利用できる点、カメラのように直接的に人の顔や動きを測定するわけではないためプライバシー面での懸念が少ない点が挙げられる。また、個人のデバイスが持つ信号を用いる場合は LRF などと同様、滞在時間に関する情報や、移動方向や速度を推定

できる。他方、これらの手法は間接的に人の動きを推定するため、直接的な手法と比較して精度が低下する恐れがある。例えば、人が持つデバイスが出す Bluetooth や WiFi の信号を用いる場合、当然のことながらそのような信号を発するデバイスを持たない人は検知できない。また、CO₂ 濃度から推定する場合、密閉された空間でなく、外部との換気がなされるケースでは、換気量によって CO₂ 濃度が変わりうるため、同じ人流があっても換気状況によって CO₂ 濃度への影響が変化しうるため、統一的な推定モデルの構築が困難である。

3. 要件と課題

3.1 問題設定

本節では、人流情報推定の要件を抽出するため、実環境へ導入するための要求と制約事項を問題設定として整理する。

まず、具体的な要件の検討題材とする環境について説明する。当該環境はオフィスと店舗が同居するビルにおける、施設の運用・管理者にとって関心が高い共用部の 1 つである。当該空間は幅、奥行き、高さとも 10 メートル以上あり、空間内オフィスロビー、隣接している空間には店舗がある。当該ビルには空調や照明といった室内環境を監視・制御する BAS が当初より設置されている。一方で、外部との人の出入りや、共用空間における人の存在や動きを検知するセンサ類は元々設置されていない。また、共用部の訪問人数は 1 日あたりのべ数千人、最大で 1 時間あたり 500 名にもおよぶ、このような共用部において、施設の運用・管理者が把握するニーズがある人流情報と、その計測方法に関する制約について検討する。

まず人流情報の中でも、フロア内の滞在人数だけでなく、どの程度の時間滞在するかという情報も、フロアの使われ方や実際の混雑状況の把握、人体温の影響に基づく空調の制御のために重要な基礎データである。上述した環境でも、同程度の人数が来館したとしても、この広い空間に人が混雑して滞留するのか、あるいは滞留せず次々と通過していくのかによって、誘導の有無、空調の強弱などが大きく変わってしまうことが想定される。よって、人流情報としては滞在人数に加え、滞在時間に関する情報の把握も必要である。

一方で、運用・管理者にとっては同時に、複雑かつ高価なシステムを導入し、日々利用するために維持管理することは極力避けたいというニーズもある。例えば、LRF や LiDAR のようなセンサは、空間内のそれらの設置位置と壁の位置を合わせた前提で計測するため、もし設置位置が変わったならば再度位置合わせを行う必要がある。カメラに関しても、一辺数十メートル以上の広さがある空間では複数台の設置が必要となるため、設置だけでなくそれらの稼働状況や画像解析システムの運用も管理・運営者の負担

となりうる。その観点から、可能な限り BEMS や BAS と
いった施設に元々設置されているシステムの CO₂ 濃度な
どのデータに基づいた、人流情報の推定が求められる。

さらに、管理・運営者としては、推定自体はあくまで本
来の業務を補助するデータの取得であるため、推定システ
ムへのメンテナンスもできるだけ簡易化する必要がある。
具体的には、推定アルゴリズムのパラメータ調整などをで
きるだけ簡略化されていることが望ましい。

3.2 要件

上記の問題設定をまとめると、施設の管理・運営者に
っては以下の要件を満たす人流推定システムが求められ
ていると考えられる。

- 共用部の人流情報として、来訪者の滞在人数や滞在時
間に関する情報を得られること
- 可能な限り施設に既設されたセンサやシステムのデー
タより推定できること
- パラメータ調整といった推定システムへのメンテナ
ンスが極力不要であること

3.3 課題

前節では、有力な手法の候補として、CO₂ 濃度を用いた
人流情報の推定について述べた。一辺数メートルオーダー
の広さを持つ空間や能動的な換気がない空間においては、
人が排出する CO₂ が比較的早く、かつ一定の法則の元室
内の CO₂ 濃度に影響すると考えられる。しかしながら、前
節で述べたように、一辺が十メートルを超えるような共用
空間においては、空間が広いため人の排出する CO₂ が室
内 CO₂ 濃度に影響するまでの時定数が大きい上、そのよ
うな大規模施設には換気機能も備えられており、換気量に
よって室内空気の排出や外気の取入れ量が変化しうると
ため、同じ人流であっても必ずしも一定の時定数に沿って CO₂
濃度に変化が生じるとは言えない。さらに、換気量は法令
等で定められた CO₂ 濃度等の環境を維持するため、CO₂
濃度などによって自動調整されるケースもあるが、そのア
ルゴリズムは施設によって高度にカスタマイズされている
ケースや、換気システムのメーカーが公開していないケー
スがあり、ブラックボックスとなっている可能性も考慮す
る必要がある。

言い換えると、本稿で扱う CO₂ 濃度からの人流推定で
は、換気量という別パラメータによる、人流が CO₂ 濃度
に変化を及ぼす時間である時定数の変化の、推定モデルへ
の反映を、パラメータ調整なども極力不要な手法で実現す
ることが課題となる。

4. 提案手法

まず上記に基づき、本稿では推定対象として、当該時刻に
当該フロア内に存在したユニークな滞在人数と共に、Co₂

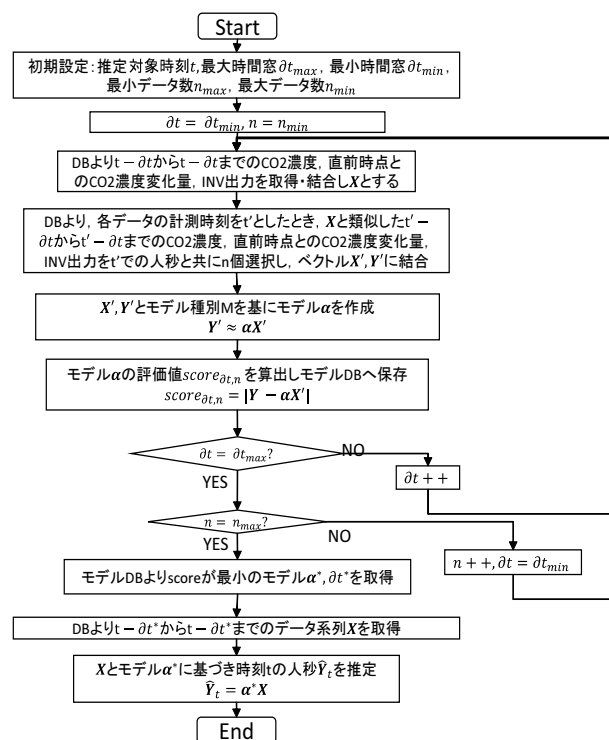


図 1 提案手法における処理フロー

Fig. 1 Flow of proposal

濃度に影響し、かつ滞在人数で除することで平均滞在時間
が算出可能な滞在人数 × 滞在時間である人秒を取り上げ、
それぞれの推定を試みる。

そして、本稿では上記課題を解決するため、Lazy learning,
または Just in Time モデリングと呼ばれる [12], 推定点毎
に推定モデルを作成する局所モデル構築手法を採用する。
局所モデル構築では、推定点におけるデータと近傍のデー
タを蓄積したデータから選択し、モデルの作成と推定を行
う。ただし、従来の局所モデル構築手法では非線形な事象
のモデルへの適用事例は多数あるものの、時定数が一定の
ケースのみを対象としていたため、そのままでは本稿にお
ける時間窓が変化するという課題を解決することは困難
である。そこで本稿では時定数の変化も考慮できる、時間
窓可変型局所モデル構築手法を新たに提案する。提案手法
は、1) 時間窓とデータ選択数を可変とした際のモデル構築
と評価、2) 評価に基づくモデルの選択と選択モデルに基
づく推定の 2 ステップからなる。提案手法の詳細な処理フ
ローを図 4 に示す。なお、本手法では考慮する時間窓は推
定対象時刻の前後で同一としているが、これらを独立して
探索し、それぞれの最適な時間窓を含むモデルを決定する
ことも可能である。

最初は推定に用いる初期設定値として、推定対象となる人
流 (滞在人数または人秒) の時刻 t , 時間窓の最小値 δt_{min} と
最大値 δt_{max} , 選択データ数の最小値 n_{min} と最大値 n_{max}
を設定後、時間窓 $\delta t = \delta t_{min}$, 選択データ数 $n = n_{min}$ を設

定する。

初期設定の後、時間窓と選択データ数を変化させながらモデルの作成と評価を行う。まず、 $t - \delta t$ から $t + \delta t$ までの CO2 濃度、直前時点からの CO2 濃度変化量 (以下、CO2 濃度変化量)、給気インバータ出力 (以下、INV 出力) を取得し、1つのベクトル \mathbf{X} として結合する。そして、計測したデータが複数蓄積されている DB (以下、DB) より、データの各計測時刻 t' としたとき、 $t' - \delta t$ から $t' + \delta t$ までの CO2 濃度、CO2 濃度変化量、INV 出力が、 \mathbf{X} と近い上位 n 件のデータを t' 時点の被説明変数と共に取得し、それぞれ結合して \mathbf{X}' , \mathbf{Y}' とする。その \mathbf{X}' を説明変数、 \mathbf{Y}' を被説明変数とし、モデル α を作成する。次に、作成したモデル α の評価値 $score_{\delta t, n}$ として、正解値 \mathbf{Y}' と作成したモデルでの推定値 $\alpha \mathbf{X}'$ での平均誤差を算出する。作成したモデル α とその評価値 $score_{\delta t, n}$ は、対象時刻 t 毎に作成したモデルを蓄積する DB (以下、モデル DB) に保存する。以下、 δt をインクリメントし、 $\delta t = \delta t_{max}$ まで同様の処理を繰り返す。 $\delta t = \delta t_{max}$ での処理が終わったら、データ選択数 n をインクリメントし、再度 $\delta t = \delta t_{min}$ から処理を繰り返す。 $n = n_{max}$ かつ $\delta t = \delta t_{max}$ での処理が終わったら、モデル作成を終了する。

モデル作成と評価を終了したら、最適な時間窓と選択データ数を持つモデルの選択と、選択モデルに基づく推定を行う。まず、モデル DB の中で最も評価値が高いモデル α^* とその時の時間窓 δt^* を取得する。そして、再度 $t - \delta t^*$ から $t + \delta t^*$ までの CO2 濃度、直前時点からの CO2 濃度変化量 (以下、CO2 濃度変化量)、給気インバータ出力 (以下、INV 出力) を取得し、1つのベクトル \mathbf{X} として結合した後、モデル α^* と共に時刻 t での推定対象人流 \hat{Y}_t を算出する。

5. 実データを用いた評価

5.1 問題設定

まず、本稿で評価対象とする施設の空間とその前提について述べる。評価に用いた空間の概略図を図 5.1 に示す。この対象となる空間 (以下、対象フロア) は検討対象としたフロアと同一であり、幅約 10 メートル、奥行き約 25 メートル、高さは約 10 メートルである。空調が 1 系統、給気口 (Variable Air Volume: VAV, Constant Air Volume: CAV) は複数、排気口は 1 つある。また BAS によって、排気の CO2 濃度と空気の還流に関連する給気インバータ出力が 10 分ごとに測定されている。また、空間は広いロビーであり、ここからオフィスフロアへ向かうゲートおよび、ATM および店舗へ向かう通路、他フロアへアクセスするエスカレータ、自動ドアを経由した室外への出入口が設置されている。そのため、平日朝から夕方を中心に、オフィスや店舗、ATM へ訪れる人が絶え間なく行き来し、時には対象フロア内のソファに着席する、あるいはオフィスフ




図 2 評価対象となった空間の概略図

Fig. 2 Target area map

ロア入口の先にあるエレベータを待つため、数分から数十分間滞在するケースもある。

5.2 評価方法

既存の測定手法と比較する観点から、対象フロア内に LRF センサを複数台設置し、正解データとなる 10 分毎の滞在人数と、滞在人数×滞在時間 (秒) となる人秒を測定・算出した。その上で、10 分毎の LRF による人流データと BEMS で取得した前述の室内 CO2 濃度および給気インバータ出力を用いて、提案手法の評価を行った。データ計測 98 日間実施し、そのうち 85 日間を学習データ、5 日間の休日を含む 13 日間を評価用データとした。

提案手法における時間窓は 1~12 点、すなわち 10 分から 120 分の範囲で可変とし、選択データ数も 25, 50, 75, 100 で可変とした。比較手法として、時間窓を 1 から 12 とし、全データを用いて推定を実施した。比較手法・提案手法ともに、用いるモデルは Support Vector Regression (SVR) とした。

特徴量として、各時点の CO2 濃度、給気インバータ出力と、直前時点からの CO2 濃度変化量を用いた。

5.3 結果

5.3.1 人数推定

表 1 に人数推定における各手法での実測値、推定値の相関係数、平均推定誤差率、平均絶対誤差をそれぞれ示す。また図 3 に、ある平日の各手法の推定例を示す。

表 1 人数推定の評価結果

Table 1 Evaluation results in num.

	時間窓長	相関係数	推定誤差率	平均絶対誤差
比較手法	3	0.88	0.40	56.08
	6	0.90	0.37	51.82
	9	0.91	0.36	49.90
	12	0.92	0.34	47.73
提案手法	可変	0.94	0.25	35.26




図 3 ある平日における人数推定結果例

Fig. 3 Example of results of num. in one weekday

表 2 人秒推定の評価結果

Table 2 Evaluation results of num. \times sec

	時間窓長	相関係数	推定誤差率	平均絶対誤差
比較手法	3	0.85	0.43	1972.58
	6	0.87	0.40	1859.72
	9	0.87	0.39	1801.05
	12	0.88	0.38	1755.99
提案手法	可変	0.93	0.26	1219.59




図 4 ある平日における人秒の推定結果例

Fig. 4 Example of results of num. \times sec. in one weekday

5.3.2 人秒の推定

表 2 に人秒推定における各手法での実測値，推定値の相関係数，平均推定誤差率，平均絶対誤差をそれぞれ示す。また図 4 に，ある平日の各手法の推定例を示す。

5.4 考察

5.4.1 人数推定における効果

まず表 1 より，全体として提案手法では比較手法と比べ，より実測値に近い滞在人数を推定ができていることがわかる。具体的には図 3 より，特に平日の朝 9 時から 10 時ごろや 12 時から 15 時のような，人数が大きく増加するケースでは，提案手法の方が実測値に近い値を推定できている，つまり，提案手法はこのような急激な人流変化があった際は特に有効な手法であるといえる。

次に，各時間帯における提案手法の効果について考察する。図 5 に，1 日を 3 時間ごとの時間帯に分割した際の各手法の平均絶対誤差を示す。図 5 より，提案手法は 4 つの比較手法と比べ，滞在人数が非常に少ない 0:00-5:50 ではわずかに比較手法より誤差が大きい傾向があるものの，ほかの時間帯において平均誤差が大きく減少しており，精度向上に効果があったといえる。また，その中でも提案手法の絶対誤差が大きく減少している，言い換えると効果が大きい時間帯は 9:00-11:50，12:00-14:50 であることがわかり，図 3 で示されたような傾向はほかの日でも起こると考えられる。

また，上記の例は主に平日に着目した結果だったため，平日，休日別の結果についても考察する。図 6 に，平日，休日別の各手法における平均絶対誤差を示す。図 6 から，人通りが多くかつ通勤ピークなど急激な人数の増減がある平日の方が，提案手法の効果は大きいものの，休日でも提案手法は比較手法より高い精度で推定できていることがわかる。よって，提案手法は急激な人流の増減があるケースでは特に有効であるが，それが少ないデータにおいても有効な手法であると考えられる。

5.4.2 人秒推定における効果

まず表 2 より，全体として提案手法では人秒についても比較手法と比べ，より実測値に近い推定ができていることがわかる。具体的には図 4 より，特に平日の朝 9 時や 12 時前後のような，急激に人秒が増加するケースで，人数と同様に提案手法の方が実測値に近い値を推定できていることわかる。そして，人数推定と比較すると，人秒の変化は急激であるが，提案手法はそのような急激な変化にも追従して推定できていることがわかる。つまり，提案手法は人数よりさらに急激に変化し得る人秒に対しても有効な手法であるといえる。

次に，各時間帯における提案手法の効果について考察する。図 7 に，1 日を 3 時間ごとの時間帯に分割した際の各手法の平均絶対誤差を示す。図 7 より，提案手法は 4 つの比較手法と比べ，すべての時間帯において平均誤差が減少しており，精度向上に効果があったといえる。また，その中でも提案手法の絶対誤差が大きく減少している，言い換えると効果が大きい時間帯は朝に通勤ピークが含まれる 6:00-8:50，9:00-11:50 と，昼休みが含まれる 12:00-14:50 で




図 5 人数推定での各手法による各時間帯の平均絶対誤差

Fig. 5 Average of absolute error from each method in each time




図 6 人数推定での各手法による休日・平日別の平均絶対誤差

Fig. 6 Average of absolute error from each method in weekday and holiday

あることがわかり、図 4 で示されたような傾向はほかの日のデータでも起こると考えられる。加えて、時間帯別の結果で着目すべき点として、最適な時間窓長は時間帯で異なる可能性が示唆されている点が挙げられる。図 7 においては、各比較手法ではおおむね時間窓長が大きい方が精度が高い傾向があるが、時間帯によっては必ずしもそうではなく、たとえば 21:00-23:50 の時間帯は時間窓長=6 が最も精度が高い。この場合、もし固定時間窓による従来手法を適用した場合、施設の管理・運営者のポリシーによってどの時間帯の精度を重視すべきかを決定し、考慮したうえで、時間窓長のチューニングが必要となるため、運用上の負担が大きくなることが想定される。一方で、提案手法ではどの時間帯でも精度が高くなるよう時間窓を自動決定するため、そのような運用上の負荷を軽減できることが期待される。

また、上記の例は主に平日に着目した結果だったため、平日、休日別の結果についても考察する。図 8 に、平日、休日別の各手法における平均絶対誤差を示す。図 8 から、滞在人秒も滞在人数と同様に、人通りが多くかつ通勤ピー

クなど急激な人流の増減がある平日の方が、提案手法の効果は大きいものの、休日でも提案手法は比較手法より高い精度で推定できていることがわかる。よって、提案手法は急激の増減があるケースでは特に有効であるが、それが少ないデータにおいても有効な手法であると考えられる。

5.4.3 共通の効果

ここではまず、提案手法による人数・人秒推定共通の効果として、時間窓を可変にしたことが実際どのように推定に寄与しているのかを考察する。図 9 に、人数推定、人秒推定それぞれにおいて、提案手法で選択された時間窓数と、その際の平均 INV 出力を示す。図 9 が示すように、時間窓数が多い時点ほど、INV 出力が大きい、つまり給気が多くなされている傾向があることがわかる。これは、給気が多い、つまり換気量が多い時点ほど人の排出した CO2 が CO2 濃度へ影響を及ぼすまで時間がかかり、長い時間窓を含めてモデル化するため、局所モデル構築の際に長い時間窓が選択されたことを示唆していると考えられる。よって、提案手法は当初の目的通り、換気量などによって人流が CO2 濃度へ影響を及ぼす時間である時定数数が変化するケースにおいて、適切な時間窓を自動選択して局所モデルを構築することでより高精度な推定を実現できたといえる。

また、比較手法では時間窓長は任意の値を設定する必要があるため、実際に良い精度を出すには試行錯誤を通じたパラメタ調整が必要となるが、提案手法は時間窓長とデータ選択に必要なデータ選択数を自動的に決定できるため、運営・管理者にとってもメンテナンスコストが低い方式であるといえる。そのため、精度だけでなく運用の簡易性という観点でも、提案手法の方が優れた方法であるといえる。

最後に、提案手法によって推定される人数、人秒によってもたらされる情報について論じる。一般に、人数と人秒は正の相関があり、増減は連動すると想定される。しかし




図 7 人秒推定での各手法による各時間帯の平均絶対誤差

Fig. 7 Average of absolute error from each method in each time




図 8 人秒推定での各手法による休日・平日別の平均絶対誤差

Fig. 8 Average of absolute error from each method in weekday and holiday




図 9 選択された時間窓長毎の平均 INV 出力

Fig. 9 Average of inverter output in each selected time window

ながら、同じある平日の結果である図 3, 4 を比較すると、必ずしもそうでないケースが明らかになる。一例としては、これらは共に朝の 9 時前後と 10 時前後にそれぞれピークがあるものの、滞在人数は後者の方が大きく、人秒は逆に前者の方が大きいことがわかる。これによって、前者の 9 時頃の方が、10 時ごろより平均滞在時間が長いことがわか

り、行列や滞留が起きていることが示唆されている。同様の考察は、13 時前後のデータに対しても適用可能であり、これらの結果を比べると滞在人数は 12 時から 14 時ごろまで多い傾向が続くが、人秒では 13 時前頃にピークがあることがわかる。これは 12 時から 14 時ごろは同程度の滞在人数であっても、13 時前頃には平均滞在時間が長くなることがわかる。これらの要因は様々に考えられるが、このように提案手法により、人数と人秒を同一手法で高精度かつ低コストに推定できることで、行列や滞留などの可能性を検知でき、施設の管理・運営者が空調の制御や施設のメンテナンス、あるいは施設の使われ方の分析に役立てられる情報が得られるようになったといえる。

6. 結論

本稿では、施設の運営・管理者に役立つ室内の滞在人数・時間といった人流情報を低コストに推定することを目的とし、時定数可変型局所モデル構築による室内 CO2 濃度からの滞在人数推定手法について述べた。本手法は、空調における換気量などの変化によって生じる、室内人流が CO2 濃度に影響を及ぼすまでの時間、すなわち時定数の変化に対応するため、新たに提案した時間窓可変型局所モデル構築手法を用いるものである。施設における BAS から得られた CO2 濃度と、実測した滞在人数および滞在人秒データを用いて検証した結果、提案手法は時間窓を固定して統一的な推定モデルを構築した従来手法と比較し、より実測値に近い値を推定でき、かつ時間窓長や選択データ数の調整が不要な、管理・運営者にとって運用コストが低い推定を実現できることが明らかになった。また、選択された時間窓数とその時点での時定数に影響を及ぼす給気インバータ出力との比較から、提案した時間窓可変型局所モデル構築手法における時間窓の自動選択は狙い通り、時定数変化に対応した高精度な推定に寄与していることを示した。そして、実際の滞在人数及び人秒の推定結果を比較することで、

施設の管理・運営者の要件を満たす情報を、低コストに得られることを明らかにした。

今後の課題としては、複数の空調系統がある空間における適用に向けた技術の改良および評価が挙げられる。

参考文献

- [1] Araszkievicz, K., Digital Technologies in Facility Management – The state of Practice and Research Challenges, *Procedia Engineering*, Vol. 196, pp. 1034-1042 (2017).
- [2] Ehrlich, C. R. and Blankenbach, J., Pedestrian localisation inside buildings based on multi-sensor smartphones. *Proc. IEEE UPINLBS 2018*, pp. 1-10 (2018).
- [3] Teixeira, T and Savvides, A., Lightweight people counting and localizing for easily deployable indoors wsns. *IEEE Journal of Selected Topics in Signal Processing*, Vol.2, No.4, pp.493-502 (2008).
- [4] Panangadan, A., Matarić, M. and Sukhatme, G. S., Tracking and Modeling of Human Activity Using Laser Rangefinders, *International Journal of Social Robotics*, Vol.2, pp.95-107 (2010).
- [5] Kastner, W., Neugschwandtner, G., Soucek, S. and Newman, H. M., Communication systems for building automation and control. *Proc. IEEE*, Vol.93, No.6, pp.1178-1203 (2005).
- [6] Manic, M., Wijayasekara, D., Amarasinghe, K., and Rodriguez-Andina, J. J., Building energy management systems: The age of intelligent and adaptive buildings, *IEEE Industrial Electronics Magazine*, Vol.10, No.1, pp.25-39 (2016).
- [7] Arief-Ang, I. B., Hamilton, M., and Salim, F. D., A scalable room occupancy prediction with transferable time series decomposition of co2 sensor data, *ACM Trans. Sensor Networks (TOSN)*, Vol.14, No.(3-4), pp.1-28 (2018).
- [8] Shackleton, J., VanVoorst, B., and Hesch, J., Tracking people with a 360-degree lidar, *Proc. 7th IEEE AVSS*, pp. 420-426 (2010).
- [9] AXIS People Counter, <https://www.axis.com/products/axis-people-counter>,
- [10] Longo, E., Redondi, A. E. and Cesana, M., Accurate occupancy estimation with WiFi and bluetooth BLE packet capture, *Computer Networks*, Vol.163, No.9, 106876 (2019).
- [11] Zou, H., Zhou, Y., Yang, J. and Spanos, C. J., Device-free occupancy detection and crowd counting in smart buildings with WiFi-enabled IoT, *Energy and Buildings*, Vol.174, pp.309-322, No.1 (2018).
- [12] Bontempi, G., Birattari, M. and Bersini, H., Lazy learning for local modelling and control design, *International Journal of Control*, Vol.72, Issue.7-8, pp.643-658 (1999).