

# 電子麻酔記録データを用いた 麻酔導入後低血圧予測システムの提案

稲田 大陸<sup>1</sup> 土井 千章<sup>1</sup> 関 博志<sup>2</sup> 出野 智史<sup>3</sup> 加藤 純悟<sup>3</sup> 山田 高成<sup>3</sup> 森崎 浩<sup>3</sup> 重野 寛<sup>1</sup>

概要：麻酔薬の投与は血圧低下を引き起こすが、その程度は患者の全身状態や麻酔薬の投与量などに影響を受け、予測が困難である。特に麻酔導入時には高度の血圧低下（以下導入後低血圧）を来すことがある。高度の低血圧は心筋梗塞や脳梗塞などの有害事象を引き起こし、患者予後に影響を及ぼす可能性がある。そこで、導入後低血圧の発生を事前に予測し、医師の術前計画立案時や研修医のトレーニング時に使用可能なシステムを実装することで、導入後低血圧を発生しない麻酔薬投与量決定のサポートすることが期待できる。本稿では、年齢や性別、予定術式等の患者情報から導入後低血圧を予測し発生確率を可視化する導入後低血圧予測システムを提案する。本システムで使用を想定して、過去の電子麻酔記録データを用い、導入後低血圧の発生に対して相関の高かった患者年齢を層別化して、機械学習手法を用いて予測モデルを構築した。そして、構築したモデルを組み合わせて用いことで、F 値 0.70 で予測できることを確認した。

## Proposal of system for predicting hypotension after induction of anesthesia by using electronic anesthesia records

RIKU INADA<sup>1</sup> CHIAKI DOI<sup>1</sup> HIROYUKI SEKI<sup>2</sup> SATOSHI IDENO<sup>3</sup> JUNGO KATO<sup>3</sup>  
TAKASHIGE YAMADA<sup>3</sup> HIROSHI MORISAKI<sup>3</sup> HIROSHI SHIGENO<sup>1</sup>

### 1. はじめに

近年、医療現場では IT 技術を活用した高度で先進的な医療サービスの提供が求められている。内閣府では、AI や IoT、ビッグデータを活用することで、医療現場の課題を解決する「AI ホスピタルによる高度診断・治療システム」[1] を推進している。このシステムは、医療現場での診断のサポートや教育やコミュニケーションの支援を目的としている。これらのシステムでは、患者に装着した医療機器や患者への問診を通して収集されたデータが用いられる。医療機器から収集されるデータの 1 つに電子麻酔記録データがある。従来、麻酔科医は患者の心拍数や血圧、術中のイベントなどを麻酔記録に手書きしていたが、麻酔記録の電子

化により業務の効率化と同時に蓄積したデータを様々な目的に活用することが可能となった。

国内の手術件数は年々増加しており、慶應義塾大学病院では、2014 年度で 13,860 件、2018 年度で 15,450 件と 4 年間で 11.5% 増加している [2]。手術時の麻酔薬投与量は、医師が患者の状態を鑑みて決定する。患者の状態と麻酔薬の投与量によっては、麻酔薬投与後に低血圧（以下、導入後低血圧）を引き起こすことがあるが、その程度を予め予測することは困難である。導入後低血圧は、心筋梗塞 [3] や腎障害 [4] などの有害事象 [5] を引き起こし、患者予後に影響を及ぼす可能性があるとされている。著者らは、手術前に各患者が導入後低血圧を引き起こしうる状態であるか否かがわかれば、麻酔薬の投与量を調節することで導入後低血圧の発生率を低減できると考えた [6][7]。

本稿では、年齢や性別、予定術式等の患者情報から導入後低血圧を予測し発生確率を可視化する導入後低血圧予測システムを提案する。本システムは、導入後低血圧の発生を事前に予測し、医師の術前計画立案時や研修医のトレ

<sup>1</sup> 慶應義塾大学大学院理工学研究科  
Graduate School of Science and Technology, Keio University  
<sup>2</sup> 東京歯科大学市川総合病院 麻酔科  
Department of Anesthesiology, Tokyo Dental College  
Ichikawa General Hospital  
<sup>3</sup> 慶應義塾大学医学部 麻酔学教室  
Department of Anesthesiology, Keio University school of  
Medicine

ニング時に使用可能である。既存研究では、術前の検査結果や患者情報から低血圧予測を行う例があるが、低血圧の定義が研究により異なるので、複数の定義について導入後低血圧を予測した結果を確認する必要があるという課題があった。本システムの実現により、時間をかけずに導入後低血圧の発生確率を予測することが可能である。

本システムでの使用を想定して、本稿では導入後低血圧の発生に対して相関の高かった患者年齢を層別化して構築した予測モデルについても検討する。導入後低血圧の発生予測には2017年4月1日から2018年3月31日の間に慶應義塾大学病院で手術を受けた18歳以上の患者のうち、麻酔導入薬として国内外で最も広く使用されているプロポフォールとフェンタニルの組み合わせで迅速導入した1,618件の電子麻酔記録データを抽出して用いる。電子麻酔記録データには患者の年齢や性別、身長、体重、診療科名、術式などのほか、術中薬剤投与データ、術中血圧データなども含まれる。

以下、本稿では2章において関連研究について述べ、3章では本研究で用いたデータセットについてに説明する。4章では提案の導入後低血圧予測システムについて述べ、5章では評価を示す。最後に6章で結論を述べる。

## 2. 関連研究

本章では、電子麻酔記録データを用いた導入後低血圧予測を行う関連研究及び、問題点について述べる。

### 2.1 麻酔導入後低血圧の予測因子調査

Reich ら [8] は、患者のデータを多変量解析することにより麻酔導入後の低血圧を来す要因を明らかにした。この研究では、低血圧の定義を平均血圧が導入前に70mmHg未満とした。そして、全身麻酔で手術を受けた4,096人分の患者データを分析した。その結果、重度の低血圧を回避するためには、年齢が50歳以上かつASA-PS3（米国麻酔学会術前状態分類。1-6の6つのクラスにされ、数字が大きいほど全身状態が悪いことを示す。3は高度の全身疾患を有する）以上の患者にはプロポフォール以外の薬剤による薬剤による麻酔導入を検討する必要があること、導入前に平均血圧が70mmHg未満の患者に対してはプロポフォールの投与を避けることが重要であることを明らかにした。

### 2.2 麻酔導入後低血圧予測のための機械学習分析

Kendall ら [9] は13,323人の患者データを用いて、導入後低血圧の発生を予測した。データセットは、米国の施設から収集された12歳以上の全身麻酔患者である。この研究では、低血圧の定義を麻酔導入後10分以内に平均血圧が55 mmHg未満になることとした。8つの機械学習手法

表 1: 電子麻酔記録データ

分類	項目
患者 データ	年齢
	性別
	身長
	体重
	BMI
	ASA PS
	診療科
	気道
	予定麻酔法
	予定術式
	術前診断
	手術部位 大分類
	手術部位 小分類
術中投薬 データ	術前合併症 大分類
	術前合併症 小分類
	投与方法
血圧 データ	用量
	薬剤名
	投与時刻
	平均血圧
血圧 データ	収縮期血圧
	拡張期血圧
	測定時刻

を使用して、低血圧予測モデルを構築して予測精度を明らかにした。しかし、この研究は予測精度を向上させるという点については考慮していない。

### 2.3 動脈圧波形を用いた手術中の低血圧予測

Hatib ら [10] は1334人の患者データと高精度の動脈圧波形から低血圧予測指数（HPI）アルゴリズムを用いて、低血圧が今後5～15分で発生する確率を示した。この研究では、術中に少なくとも1分以上平均血圧が65mmHg以下となる状態を低血圧、平均血圧が75mmHg以上の状態を非低血圧と定義し、HPIアルゴリズムは、患者の動脈圧波形をもとに、低血圧の発生を予測した。アルゴリズムは、動脈圧波形を5つの異なるフェーズに分割し、時間や振幅などの特徴として後で使用される脈波の複数の特徴を検出し、モデルの構築を行った。低血圧予測の感度と特異度は、低血圧発生前の15分で88%と87%を達成した。しかし、予測精度を向上させるために、明確に低血圧および非低血圧と定義することができない平均血圧が65mmHgから75mmHgの間の患者は、学習及び検証用データとして除外された。また、麻酔薬投与などの血圧の低下に関わる外的要因に関して考慮していない。

表 2: 性別・年齢別の各症例数

年齢	男性	女性	年代ごとの合計 (件数)
10 代	12	7	19
20 代	52	73	125
30 代	52	162	214
40 代	74	261	337
50 代	129	157	286
60 代	150	124	275
70 代	142	112	257
80 代	42	60	104
90 代	3	6	9
性別ごとの合計 (件数)	656	962	1618




図 1: 年代別低血圧発生割合

### 3. データセット

電子麻酔記録データは、倫理委員会の承認（承認番号：20180049）後、2017 年 4 月 1 日から 2018 年 3 月 31 日の間に慶應義塾大学病院で予定手術を受けた 18 歳以上の患者のうちプロポフォール・フェンタニルの単回投与で迅速導入した症例を対象として、1,618 件を抽出して用いた。

電子麻酔記録データは表 1 に示すように、患者データ、術中投薬データ、血圧データの 3 種類のデータを含む。患者データには患者と手術に関する基本情報が含まれている。術中投薬データには、手術の開始から患者に投与された薬剤に関する情報が含まれる。血圧データには、術前または術中の血圧の情報が含まれる。表 2 に性別及び年代ごとの症例数を示す。全体の 41%（656 件）が男性、59%（962 件）が女性である。最も症例数が多い年代は 40 代であり、21%（337 件）である。

### 4. 導入後低血圧予測システム

本章では、導入後低血圧定義、提案の導入後低血圧予測システム、データの前処理、予測モデルの構築、およびシステムの実装について説明する。

#### 4.1 導入後低血圧定義

導入後低血圧の分析を行うためには、低血圧の定義を行う必要がある。しかし、低血圧の絶対的な定義はなく、130 以上の異なる基準が提唱されている [11]。低血圧は収縮期血圧と平均血圧のいずれか、もしくは両方の血圧についての絶対的基準や相対的基準により定義される。

本稿では、低血圧の定義を本システムによるデータ分析と麻酔科医と検討した上で決定した。電子麻酔記録データを使用して、麻酔導入から 20 分以内に平均血圧が 60mmHg 未満または収縮期血圧が 80mmHg 未満を満たすものを導入後低血圧とした。導入後低血圧と分類されたのは全体のうち 42%（673 件）である。図 1 に各年代の低血圧を発生した症例数と割合を示す。

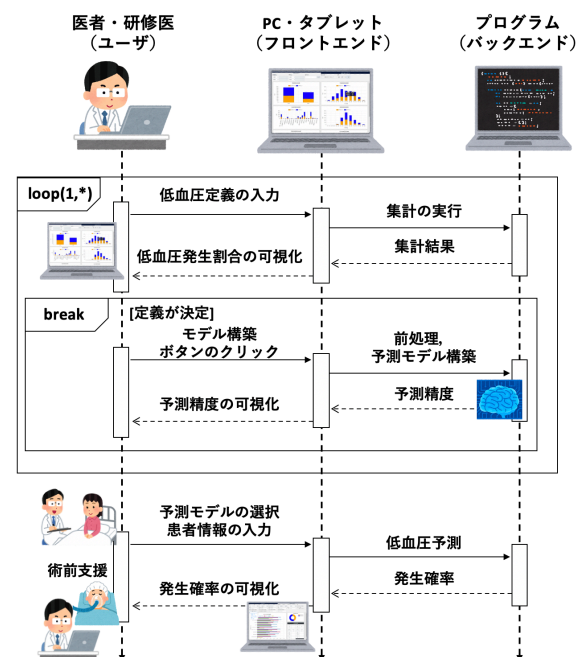


図 2: 導入後低血圧予測システムの使用手順

#### 4.2 システム概要

本システムは、医師の術前計画や研修医のトレーニング用のシステムとして用いることを想定している。図 2 にシステムの使用手順を示す。まず、システムは医師が入力した低血圧の定義をもとに、低血圧に該当する症例数、および発生割合を可視化する。そして、発生割合を確認した医師は入力した低血圧の定義が適切か否かの判断を行う。必要に応じてこの検討を繰り返し、低血圧の定義を決定する。その後、システムは予測モデルの構築を行い、予測精度を可視化する。図 3、図 4 に低血圧発生割合とモデル別予測精度の可視化機能を示す。最後に、構築したモデルの中から予測に使用するモデルを選択し、表 1 に示す電子麻酔記録データのうち、患者データに該当する情報を入力する。患者情報を受け取ったシステムは構築した予測モデルをもとに低血圧の発生予測を行い、発生確率を可視化する。



図 3: 低血圧発生割合の可視化

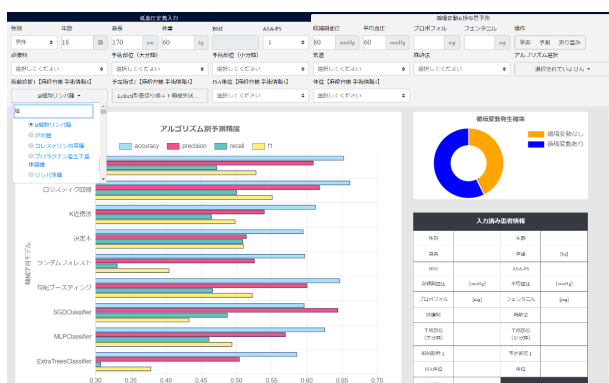


図 4: モデル別予測精度の可視化

### 4.3 前処理

医師が適切な低血圧の定義を決定した後に、データの前処理を行う。前処理として、定量変数と定性変数の欠損値処理と特徴量選択を行う。

#### 定量変数

欠損値の内、定量的な値を持つ項目は他の説明変数を基に補完した。定量的な説明変数は「身長」と「体重」であり、いずれか一方が欠損していた場合、全国の標準値 [12] から対象患者が該当する年齢、性別の基に BMI を参照したのち、もう片方の推定を行った。最後に正規化を行った。

#### 定性変数

定性的な値を持つ項目は最頻値で補完した。定性的な説明変数は「気道」であり、うち 94 件が「挿管」である。補完後には、定性的な説明変数はダミー変数に変換して扱った。

#### 特徴量選択

特徴量の選択には、再帰的特徴除去 (RFE)[13] を使用した。外部推定器としてランダムフォレストを使用し、20 の説明変数を選択した。図 5 は、RFE によって選択された説明変数とその寄与度を示す。特に「年齢」、「術前平均血圧」、「身長」、「術前収縮期血圧」と「体重」の寄与度が導入後低血圧の予測に関して高いことを確認した。




図 5: 各説明変数の寄与度

### 4.4 予測モデル構築

予測モデルの構築はデータの前処理後に行う。図 6 に本システムで使用を想定する導入後低血圧予測モデル構築の概要を示す。まず、電子麻酔記録データを低血圧の発生に対して最も相関の高かった「年齢」に着目し、年代ごとに分割した。ただし、10 代と 90 代の症例数が十分でないため、それぞれ 20 代と 80 代として計上した。

学習プロセスでは、各年代の電子麻酔記録データから低血圧判定を行い、低血圧または非低血圧のフラグを電子麻酔記録データに付与した。そして、低血圧予測に用いる機械学習手法として一般的に分類問題に用いられる手法から、サポートベクタマシン (SVM)、ロジスティック回帰 (LR)、ランダムフォレスト (RF)、勾配ブースティング (GBM)、決定木 (DT)、ニューラルネットワーク (MLP) を採用し、各年代に対してモデルを構築した。予測プロセスでは、各年代ごとに最も予測精度が高くなった予測モデルを使用して予測を行った。

### 4.5 システムの実装

本稿で実装するシステムは Python[14] および、Python で作られる Web フレームワークの Django[15] を用いて実装を行なった。低血圧発生割合やモデル別予測精度の可視化機能には Javascript[16] のライブラリの Chart.js[17] を用いて実装した。予測モデルの保存には Python のライブラリ Joblib[18] を用いた。

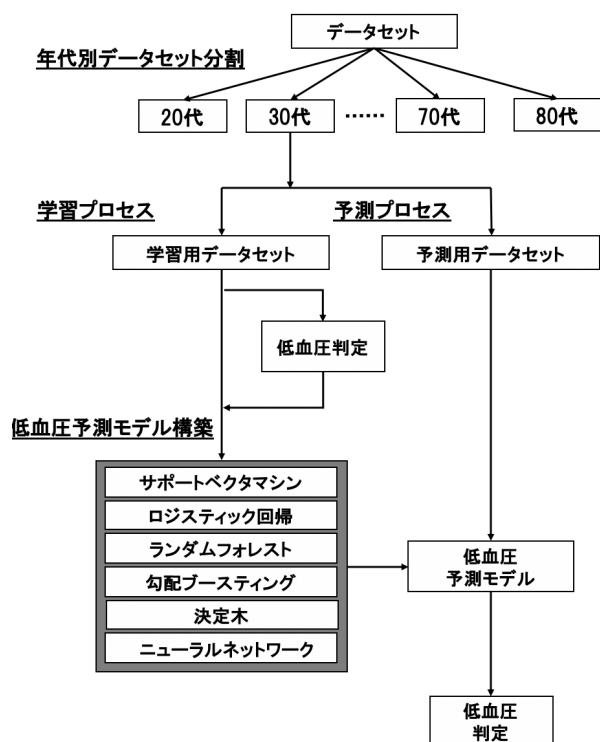


図 6: 予測モデル構築の概要

## 5. 評価

本章では、提案したシステムでの使用を想定した低血圧の発生に対して最も相関が高かった年代ごとに構築し複合した予測モデル（COM）と 6 つの予測モデルとの比較する。

### 5.1 評価指標

導入後低血圧予測モデルの予測性能を確認するため、4 つの評価指標、Accuracy（正解率）、Precision（適合率）、Recall（再現率）、F-measure（F 値）を算出する。各評価指標の値は次式で与えられる。ここで、TP, FP, TN, FN をそれぞれ真陽性、偽陽性、真陰性、偽陰性を表す。本稿では、複合した予測モデルの優位性を示すために、Precision と Recall の調和平均である F-measure を重視して評価した。評価方法としては 10 分割交差検証を採用した。

$$Accuracy = \frac{TP + TN}{TP + FP + TN + FN} \quad (1)$$

$$Precision = \frac{TP}{TP + FP} \quad (2)$$

$$Recall = \frac{TP}{TP + FN} \quad (3)$$

$$F - measure = \frac{2 * Precision * Recall}{Precision + Recall} \quad (4)$$




図 7: 年代別予測精度（F-measure）




図 8: 予測モデル別予測精度（F-measure）

### 5.2 評価結果

複合したモデルには、各年代で最も F-measure の値が高いモデルを採用した。図 7 に年代別の各モデルの F-measure の値を示す。採用されたモデルは、20 代で MLP、30 代、40 代で RF、50 代で LR、60 代、70 代、80 代で SVM である。図 8 に全年代に対する各モデルおよび複合したモデルの F-measure、図 9 に Accuracy, Precision, Recall を示す。複合したモデルにおいて、F-measure は最も高い 0.70 を達成した。さらに、Recall も最も高い 0.82 を達成した。一方で、Accuracy と Precision の改善は見られなかった。

## 6. おわりに

本稿では、年齢や性別、予定術式等の患者情報から導入後低血圧を予測し発生確率を可視化する導入後低血圧予測システムを提案した。さらに、1,618 人の電子麻酔記録データを用いて、低血圧の発生に対して相関の高かった患者年齢を層別化して予測モデルを構築した。電子麻酔記録データは、患者データ、術中薬物投与データ、血圧データで構成されている。導入後低血圧の定義は、本システム及び麻酔科医と検討の上で、麻酔導入後 20 分以内に収縮期血圧 80mmHg 以下、もしくは平均血圧 60mmHg 以下と定義した。前処理で RFE を使用して選択された 20 個の説明変数




図 9: 予測モデル別予測精度 (Accuracy, Precision, Recall)

のうち、「年齢」、「術前収縮期血圧」、「術前平均血圧」、「身長」および「体重」は最も重要な説明変数であった。評価結果は、年代ごとに構築されたモデルが最高の F-measure 0.70 で導入後低血圧を予測できることを示した。さらに、Recall は 0.82 ですべてのモデルで最も高い値となった。将来、著者らは、術前の情報を利用することにより、予測精度をさらに向上させることを目指す。

## 参考文献

- [1] 内閣府政策統括官 (科学技術・イノベーション担当): 戦略的イノベーション創造プログラム (SIP) AI (人工知能) ホスpitalによる高度診断・治療システム研究開発 計画, 内閣府 (オンライン), 入手先 <<https://www8.cao.go.jp/cstp/gaiyo/sip/keikaku2/10.aihospital.pdf>> (参照 2020-04-02).
- [2] 慶應義塾大学病院: 統計・実績データ, 慶應義塾大学病院 (オンライン), 入手先 <<http://www.hosp.keio.ac.jp/about/data/>> (参照 2020-04-02).
- [3] Salmasi V, Maheshwari K, Yang D, et al.: Relationship between intraoperative hypotension, defined by either reduction from baseline or absolute thresholds, and acute kidney and myocardial injury after noncardiac surgery: a retrospective cohort analysis. *Anesthesiology*, Vol.126, pp.47-65(online). doi: 10.1097/ALN.0000000000001432(2017).
- [4] Walsh M, Devereaux PJ, Garg AX, et al.: Relationship between intraoperative mean arterial pressure and clinical outcomes after noncardiac surgery: toward an empirical definition of hypotension. *Anesthesiology* Sep;119(3):pp.507-15(online). doi: 10.1097/ALN.0b013e3182a10e26(2013)
- [5] Wesselink EM, Kappen TH, Torn HM, et al.: Intraoperative hypotension and the risk of postoperative adverse outcomes: A systematic review. *Br J Anaesth*. pp706-721(2018).
- [6] Nanaka Asai, Chiaki Doi, Koki Iwai, et al.: Proposal of Anesthetic Dose Prediction Model to Avoid Post-induction Hypotension Using Electronic Anesthesia Records, Twelfth International Conference on Mobile Computing and Ubiquitous Network (ICMU), 4pages (2019).
- [7] Koki Iwai, Chiaki Doi, Nanaka Asai, et al.: Prediction of Post-induction Hypotension Using Stacking Method, Twelfth International Conference on Mobile Computing and Ubiquitous Network (ICMU), 4pages (2019).
- [8] R. DL, H. S, K. M, and et al.: Predictors of hypotension after induction of general anesthesia, *Anesthesia & Analgesia*: Vol.101, pp.622-628(online) . doi: 10.1213/01.ANE.0000175214.38450.91(2005)
- [9] K. S, K. P, R. AD, and W. J.: Supervised machine learning predictive analytics for prediction of postinduction hypotension, *Anesthesiology*, pp.675-688,(2018)
- [10] Hatib F, Jian Z, Buddi S, Lee C, et al.: Machine learning algorithm to predict hypotension based on high-fidelity arterial pressure waveform analysis. *Anesthesiology*. Oct;129(4):pp.663-674(online). doi: 10.1097/ALN.0000000000002300(2018).
- [11] Bijker JB1, van Klei WA, Kappen TH, van Wolfswinkel L, Moons KG, Kalkman CJ.: Incidence of Intraoperative Hypotension as a Function of the Chosen Definition: Literature Definitions Applied to a Retrospective Cohort Using Automated Data Collection.
- [12] 厚生労働省: 第2編 保健衛生 第1章 保健 身長・体重の平均値, 性・年次×年齢別, 厚生労働省 (オンライン), 入手先 <<https://www.mhlw.go.jp/toukei/youran/indexxyk21.html>> (参照 2020-04-02) .
- [13] Guyon, I., Weston, J., Barnhill, S. et al.: Gene Selection for Cancer Classification using Support Vector Machines. *Machine Learning* 46, pp.389 - 422 ,(2002).
- [14] Python Software Foundation: Python(online), 入手先 <<https://www.python.org/>> (参照 2020-04-02).
- [15] Django Software Foundation: Django(online), 入手先 <<https://www.djangoproject.com/>> (参照 2020-04-02).
- [16] Mozilla Developer Network: Javascript(online), 入手先 <<https://developer.mozilla.org/en-US/docs/Web/JavaScript>> (参照 2020-04-02).
- [17] Open source HTML5 Charts for your website: Chart.js(online), 入手先 <<https://www.chartjs.org/>> (参照 2020-04-02).
- [18] Joblib developers: Joblib(online), 入手先 <<https://joblib.readthedocs.io/en/latest/>> (参照 2020-04-02).