

# 機械学習を用いた外れデータ検出による 行動認識モデルの推定精度への影響

加川宗嗣<sup>1</sup> 水野真<sup>2</sup> 濱崎大輔<sup>2</sup> 長谷川達人<sup>1</sup>

**概要:** 本研究では, スマートフォンを用いた行動認識を目的としたセンサデータ収集において起こり得るアノテーション誤りを検出し除去を行う手法の比較を行う. アノテーション誤りを検出できることによってデータセットの品質を高めることができるため行動認識の推定精度向上が実現できる. 本研究では, One Class Support Vector Machine, クラス確率に基づく手法, 距離に基づく手法の3つの手法を用いたアノテーション誤りの検出を行う手法を開発する. センサを用いた行動認識に関するベンチマークデータセットである HASC Corpus に対して意図的にアノテーション誤りを起こし, 誤り検出精度, 及び, 行動認識精度を比較評価した結果, 距離に基づく手法が最も行動認識モデルの推定精度向上に貢献することがわかった. また, アノテーション誤りが含まれる割合が増加することに対して行動認識の推定精度への悪影響がある点や, 距離を用いた手法において前処理の有無や種類による行動認識の推定精度への影響を明らかにした.

## Effect of Outlier Detection Using Machine Learning on Accuracy of Human Activity Recognition model

MUNETSUGU KAGAWA<sup>1</sup> MAKOTO MIZUNO<sup>2</sup> DAISUKE HAMAZAKI<sup>2</sup> TATSUHIITO HASEGAWA<sup>1</sup>

### 1. はじめに

行動認識を目的としたセンサデータ収集において, センサデータは人間の目視では行動ラベルが判断しづらく, アノテーション誤りが起こり得る. 機械学習において訓練データは完全に正しいものとして想定されているが, Quinlan [1] は, 訓練データに誤りが存在する場合, データが不適切なものとなったり, そのようなデータを用いたモデルが意図しない特徴を学習するというを示している. 一般的に, 誤ったラベルが付加されているデータ (以下外れデータ) を訓練データセットに含んで機械学習を行った場合, 推定精度が低下することが知られている. したがって, より推定精度の高い行動認識モデルを訓練するにあたって, 外れデータを除去することは重要である. 外れデータの除去は一般に機械学習の前処理のデータクレンジングとして, 専門家による手作業で実施されることが多

い. しかし, 行動認識のアノテーション誤りの除去に関する議論は深くされていない. 本研究では, 推定精度を低下させる可能性のある外れデータを訓練用データから検出する手法を複数開発する. また, 比較検証実験を経てその有効性を明らかにし, 行動認識精度を向上させることを示す.

### 2. 関連研究と本研究の位置付け

#### 2.1 異常な部位の検出に関する研究

黒滝らの研究 [2] では, 深層学習を用いて2次元胸部X線写真に対して写真に写る異常な部位を検知し, 異常な肺の画像を検知する手法を提案されている. 変分オートエンコーダ(VAE)に対して正常な肺の画像を訓練データとして訓練を行った後, テストデータとして, 正常または異常な画像を入力し異常な肺の画像を検知できることを示されている. Bergmann らの研究 [3] では, オートエンコーダの損失関数を SSIM と呼ばれる画像の類似度を測る指標にする手法が提案されている. 提案された手法を用いることで, 画像に存在する汚れや欠損といった異常な部位の検知する精度をより高めることができることを示している. Pankaj

<sup>1</sup> 福井大学大学院工学研究科知識社会基礎工学専攻  
Graduate School of Engineering, University of Fukui

<sup>2</sup> 福井大学大学院工学研究科情報・メディア工学専攻  
Graduate School of Engineering, University of Fukui

らの研究 [4] では、Long Short Term Memory(LSTM) を用いて時系列データの心電図やエンジンなどの周期的な波形に対して波形に現れる異常な部位を検出する手法を提案されている。

以上のように、データ内の異常な部位を検出する研究に関しては、特に画像や時系列データで盛んに行われている。これは画像や波形中の一部の異常箇所を検出することを目的としており、本研究で行うアノテーション誤りを検出するものとは目的が異なる。

## 2.2 異常な訓練データの検出に関する研究

Zhu らの研究 [5] では、大規模なデータセットまたは分散データセット内の誤ったラベルの付いたインスタンスを検出および除去するルールベースの手法が提案されている。評価実験では、一部のデータに誤ったラベルを付与した画像のデータセットに対して手法を適用し精度向上を達成できることが示されている。Gamberger らの研究 [6] では、ランダムな誤分類に対するノイズの多い訓練データを検出する手法が提案されている。提案された手法によって検出されたデータが訓練データから除去され、残ったデータを用いることで分類タスクの精度向上を達成できることが示されている。

以上のように、アノテーション誤りを検出する研究に関しては、筆者が調べた限りでは、主にルールベースの手法で行われている。

## 2.3 本研究の位置付け

関連研究から、異常検知の領域においてセンサデータは画像データに比べ未開拓である。特に、加速度センサデータセット中のアノテーション誤りを検出する研究はあまり議論されていない。以上を踏まえ、本研究では加速度センサデータに対して、行動認識精度を低下させるデータの検出を実現する。本研究の貢献は下記の3点である。

- (1) センサデータを用いた行動認識タスクにおいて、外れデータが推定精度に与える影響を明らかにする。
- (2) 訓練データに外れデータが含まれる状況下における行動認識モデルの認識精度向上に関して、外れデータ検出の観点から有効な手法を明らかにする。
- (3) 訓練データに外れデータが含まれる状況下における行動認識モデルの認識精度向上に関して、行動認識精度向上に寄与する外れデータ検出手法を明らかにする。

## 3. 実施手法

本研究で実施する外れデータの除去手法の概要を図1に示す。Rは外れデータ除去処理である。Mは基本行動認識を行う機械学習モデルである。Mの入力はラベル付き加速度センサデータであり、出力は6種類 (stay, jog, walk,




図 1: 外れデータの検出手法の概要

skip, stUp, stDown) の行動ラベルである。

実験に使用した機械学習モデルは Yang らの文献 [7] で採用されている一般的な CNN モデルアーキテクチャを用いた。CNN モデルは畳み込み層とプーリング層を交互に3層ずつ、全結合層を2層重ねたモデルを用いる。本研究では、外れデータ検出処理 R に関して、複数の手法の比較評価を行う。今回、(1) One Class Support Vector Machine, (2) クラス確率に基づく手法, (3) 距離に基づく手法を採用した。

### 3.1 One Class Support Vector Machine

One Class Support Vector Machine (OC-SVM) [8] とは、Bernhard らが提案した外れ値検知に用いられる教師なし機械学習アルゴリズムである。OC-SVM は SVM を基に提案された手法であり、原点と外れデータでないデータ (以下正常なデータ) の間を分離し、外れデータが原点に近くなるように訓練を行う。

本研究では、データセットを付与されているラベルごとに分け、訓練用データで OC-SVM を訓練する。検証用データをこのモデルに与えると、データに誤ったラベルが付与されている場合、外れデータとなる。この手法を用いて、クラスごとに OC-SVM を行い、外れデータを検出し除去する。

OC-SVM のハイパーパラメータを変化させることで外れデータの検出状況が変化させることができる。本研究で採用した OC-SVM のパラメータを表1に示す。表は左からパラメータ名、パラメータの説明、本研究で用いる値の順に表記されている。 $\mu$  は異常データの割合を決めるパラメータであり、kernel は OC-SVM の訓練に使用するカーネルである。異常データの割合を示すパラメータ  $\mu$  は、観測データのみが与えられる場合、一般的に未知である。本研究では、これを仮に既知であるとして OC-SVM の検証を執り行った。

### 3.2 クラス確率に基づく手法

クラス確率に基づく手法とは、ニューラルネットワークの出力である各クラスに属する確率を用いて外れデータ検出を行う手法である。図2に示すように、ニューラルネットワークでは、出力をクラス数の分だけ出力している。その後、Softmax 関数によって値を正規化しクラス間で値を

表 1: One Class Support Vector Machine のパラメータ

パラメータ	説明	値
$\mu$	異常データの割合を決める	訓練用データセットに含まれる割合と同じ
kernel	訓練に使用するカーネル	RBF(radial basis function)

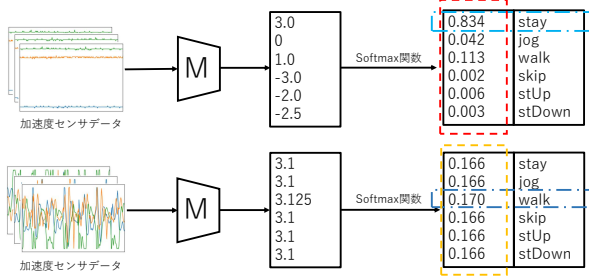


図 2: ニューラルネットワークにおける Softmax 関数の出力例

比較し最大値となっているクラスを予測したラベルとしている。Softmax 関数には図のようにクラス分出力されている値がそれぞれ 0 以上 1 以下の範囲になり、全要素の合計が 1 となるように正規化する性質がある。

一般に、分類タスクにおいて機械学習モデルにデータを入力した際の Softmax 関数の出力は各クラスに属する確率とされている。機械学習モデルが予測として出力するクラスはその入力データが各クラスに属する確率の最大値のクラスとなる。一方で、図 2 下のように、各クラスに属する確率が全体的に均一な場合や各クラスに属する確率の最大値と二番目に大きい値が似た値になっている場合は、該当データの予測が正常に実施されていないといえる。

そこで、本研究では、一度行動認識モデルを訓練し、訓練したモデルにデータを入力する。その後、入力データの各クラスに所属する確率を比較し、最大値が一定の閾値を超えた場合、ラベルミスがないデータとして訓練に用いるという手法で、外れデータの除去を行った。今回、閾値を 0.5 とした。

### 3.3 距離に基づく手法

距離に基づく手法とは、分布の距離の一つであるマハラノビス距離を用いて外れデータ検出を行う手法である。マハラノビス距離とは、統計学で用いられる距離の一種であり、多変数間の相関に基づき集団の分布の広がりを考慮した距離である。 $\vec{a}, \vec{b}$  を距離を計算する点のベクトル、 $\Sigma^{-1}$  を集団の分散共分散行列としたとき、マハラノビス距離  $D^2(a, b)$  は計算式は式 1 で定義される。

$$D^2(a, b) = (\vec{a} - \vec{b})^t \Sigma^{-1} (\vec{a} - \vec{b}) \quad (1)$$

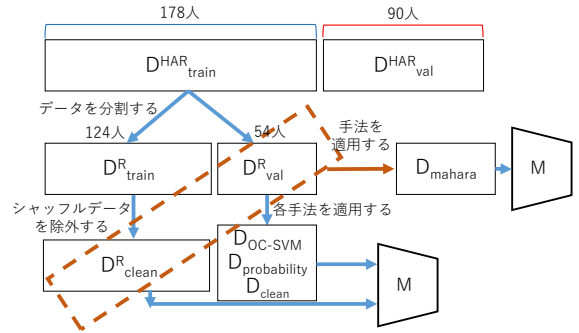


図 3: データセットの分割

本研究では、訓練データを付与されているラベルごとに分割し、1 つのラベルを 1 つの集団として扱い、マハラノビス距離を計算し、閾値を用いて各データが外れデータか否かを判定した。ある行動クラスのデータ集合を  $X$ 、集団の重心  $x_g (\in X)$  としたとき、集合の重心から  $x_n (\in X)$  までのマハラノビス距離を  $D^2(x_g, x_n)$  とする。 $D^2(x_g, x_n)$  の平均を  $\mu_D$ 、標準偏差を  $\sigma_D$  としたとき、以下の式 2 を満たすように閾値を定めた。

$$D^2(x_g, x_n) - \mu_D < \sigma_D \quad (2)$$

## 4. 評価実験

### 4.1 HASC

実験にはセンサを用いた行動認識に関するベンチマークデータセットである HASC Corpus [9] を用いる。人間の行動認識を行うために集められた加速度センサデータである。対象としている行動クラスは「stay」「walk」「jog」「skip」「stUp」「stDown」の 6 種であり、本研究では 268 名の加速度センサデータを用いて評価実験を行う。

### 4.2 実験の流れ

本実験では、HASC データセットで与えられる行動ラベルは全て正しいものと仮定し、誤った行動ラベルは擬似的に生成する。すなわち、一部のデータに対して、正解ラベルとは異なるラベルを意図的に付与し、外れデータとする(以降、シャッフルデータと呼ぶ)。シャッフルデータは外れデータの一種であるため、本研究では実験的に外れデータとして用いる。

データセットの分割の概要図を図 3 に示す。前節で述べた 268 名のデータセットから、ランダムに 178 名を抽出し

表 2: 本実験で比較を行う行動認識モデル

名前	説明
$M_{train}$	$D_{train}^{HAR}$ を用いて訓練を行ったモデル
$M_{clean}$	$D_{clean}$ を用いて訓練を行ったモデル
$M_{mahara}$	$D_{mahara}$ を用いて訓練を行ったモデル
$M_{OC-SVM}$	$D_{OC-SVM}$ を用いて訓練を行ったモデル
$M_{probability}$	$D_{probability}$ を用いて訓練を行ったモデル

行動認識モデルの訓練用データセット  $D_{train}^{HAR}$  とし、残りの 90 名を行動認識モデルの検証用データセット  $D_{val}^{HAR}$  とする。  $D_{train}^{HAR}$  に含まれるデータを 0~50% の割合でシャッフルデータにする。その後、  $D_{train}^{HAR}$  を特定の人数で  $D_{train}^R$  と  $D_{val}^R$  に分割する。  $D_{train}^R$  を用いて各外れデータ検出手法を訓練し、  $D_{val}^R$  で外れデータ検出精度の検証を行う。

外れデータ検出による行動認識精度への影響の検証に用いるデータセットについて説明する。マハラノビス距離は  $D_{clean}^R$  と  $D_{val}^R$  を合わせて一つのデータセットとし外れデータ検出を行い、その後検出が行われたデータセットで行動認識モデルの訓練を行う。距離に基づく手法を適用したデータセットを  $D_{mahara}$  とする。残りの手法は  $D_{val}^R$  に外れデータ検出手法を適用し、その後行動認識モデルの訓練を円滑に進めるためのデータ拡充を目的として、  $D_{clean}^R$  と合わせて一つのデータセットとする。OC-SVM を用いた手法、クラス確率に基づく手法、完全にシャッフルデータを取り除く処理を適用したデータセットをそれぞれ  $D_{OC-SVM}$ 、  $D_{probability}$ 、  $D_{clean}$  とする。

本実験で比較を行うのは表 2 に示す行動認識モデルである。訓練された各モデルに対し  $D_{val}^{HAR}$  を用いて行動認識モデルの精度の検証を行う。今回、マハラノビス距離を計算することにおいてデータが高次元であることや、加速度センサの向きの違いによる検出精度への悪影響を抑えるために前処理を行う。前処理を行ったことによる検出精度への影響の検証を行うため、マハラノビス距離を計算する前に t-SNE [10] やフーリエ変換 [11](FFT: Fast Fourier Transform) を前処理に用いた場合の比較も行う。「前処理を行わない」、「FFTのみ行う」、「t-SNEのみ行う」、「FFT, t-SNE の順に両方とも行う」をそれぞれ、none, FFT, t-SNE, both と表す。

#### 4.3 評価指標

本研究では、シャッフルデータをどれほど検出できたかを検証するため、検出精度の評価指標として、Recall, Precision, F 値を用いる。Recall とは全シャッフルデータのうちいくつ予測できたかを表す指標である。Precision とはシャッフルデータと予測した全てのデータのうち実際にシャッフルデータであった割合を表す指標である。F 値とは式 3 に示すように Recall と Precision の調和平均である。

$$F - measure = \frac{2 \times Precision \times Recall}{Precision + Recall} \quad (3)$$

## 5. 実験結果・考察

この章では、はじめに外れデータ検出手法の検出精度の比較を行うことで貢献 2 を考察する。その後、貢献 2 の考察をもとに 1, 3 の順で考察を行う。

### 5.1 外れデータ検出手法の検出精度

図 4 にマハラノビス距離を用いた手法に対する検出精度、図 5 にクラス確率を用いた手法、OC-SVM を用いた手法に対する検出精度を示す。図 4, 5 の横軸は  $D_{train}^{HAR}$  に含まれるシャッフルデータの割合であり、縦軸は左から  $D_{val}^R$  における外れデータ検出に対する Recall, Precision, F 値の順である。  $D_{train}^{HAR}$  に含まれるシャッフルデータの割合が 0% の場合はシャッフルデータが存在しておらず Recall, Precision, F 値が計算できないため、除外している。

本研究の貢献 2 として示した「訓練データに外れデータが含まれる状況下における行動認識モデルの認識精度向上に関して、外れデータ検出の観点から有効な検出手法」について考察する。図 4 において、マハラノビス距離を用いた統計的閾値を用いた場合、Recall がシャッフルデータの増加に対して変化なし、もしくは減少傾向にある。これは閾値が集団の平均や分散を用いて決定されるため、シャッフルデータが増加することによって平均や分散がシャッフルデータを集団のマジョリティとする方向に移動していき、それに従って、閾値が移動しているためだと考えられる。一方で、Precision がシャッフルデータの増加に対して増加傾向にあり、誤って検出されるデータが少ないことが考えられる。

図 5 において、クラス確率を用いた手法や OC-SVM を用いた手法を用いた場合、Recall がシャッフルデータが増加するにつれて共に増加しており、Precision も同様に増加傾向にある。これは、OC-SVM は外れデータの検出に特化した手法であり、距離に基づく手法に比べて集団の分布の影響が小さくシャッフルデータの検出精度が向上しているためだと考えられ、F 値を見てもそのような傾向がある。

以上をもとに、検出精度の点からシャッフルデータの検出状況を考える。統計的閾値を用いた場合、Recall が減少したが、Precision が増加している。よって、シャッフルデータの検出数は少ないものの、誤って検出されるデータも少ないことがわかる。このことは、特に前処理を t-SNE, FFT の両方とも行った場合に強く見られる。また、全手法の F 値を比較した結果、OC-SVM を用いた場合が最も検出精度が優れていることがわかる。

### 5.2 検出後のデータセットに対する正常なデータの割合

ここでは、検出後のデータセットに対する正常なデータ




図 4: シャッフルデータの割合による統計的閾値を用いた手法での  $D_{val}^R$  におけるシャッフルデータの検出精度  
(左から順に Recall, Precision, F-measure)




図 5: シャッフルデータの割合による機械学習を用いた手法での  $D_{val}^R$  におけるシャッフルデータの検出精度  
(左から順に Recall, Precision, F-measure)

の割合増加の点からシャッフルデータの検出を考察する。実験はシャッフルデータの割合を変化させて検証しており、シャッフルデータの数を実験ごとに異なる。検出されたシャッフルデータの数で検出精度の比較を行うことができないため、検出後の正常なデータの割合でシャッフルデータの検出の検証を行う。図 6 に各手法を適用後のデータセットに対する正常なデータの増加割合を示す。  $D_{train}^{HAR}$  に含まれるシャッフルデータの割合が 0% の場合は検出すべきデータが存在せず、誤って検出されてしまったデータのみ存在しているが、今回はそのような現象については考慮していない。図 6 の横軸は  $D_{train}^{HAR}$  に含まれるシャッフルデータの割合であり、図 6 の縦軸は除去手法適用後のデータセットに対する正常なデータの増加割合を意味する  $R_{diff}$  である。式 4 に  $R_{diff}$  の算出方法を述べる。

$$R_{diff} = R_{non-shuffle} - (1 - R_{D_{train}}) \quad (4)$$

ここで、 $R_{non-shuffle}$  は検出後に含まれるシャッフルデータでないデータの割合、 $R_{D_{train}}$  は  $D_{train}^{HAR}$  に含まれるシャッフルデータの割合である。 $R_{diff} \geq 0$  の場合、検出後のデータセットにおいてシャッフルデータでないデータの割合が増加している、即ちシャッフルデータの割合が減少していることを示している。この指標を用いて、検出後のデータセットが検出前に比べて精錬されているかどうかの検証を行った。

図 6 において  $R_{diff}$  が全体的に 5% を下回っており、最大でも約 4% であるため、どの手法においても大幅に正常

なデータの割合が増加するといったことは見られなかった。

図 6 左においてマハラノビス距離を用いた場合、概ね正の値になっており、検出後のデータセットに対して正常なデータの割合が増加していることから、シャッフルデータの割合の増加に対してシャッフルデータの安定した除去が行われていることがわかる。その中でも前処理を両方とも行った場合が最も増加割合が高いことから、より効果があることもわかる。

一方で、図 6 右においてクラス確率に基づく手法を用いた場合、 $D_{train}^{HAR}$  に含まれるシャッフルデータの割合が 10 から 30% の場合に対してほぼ 0 もしくは負の値になっており、検出後のデータセットにおいて正常なデータの割合が減少している傾向が見られ、40% 以上の場合に対しては、正常なデータの割合が増加し、最終的に他の二つの手法よりも向上している傾向が見られる。つまり、クラス確率に基づく手法は適切な閾値を設定することで他の二つの手法と比べても優れた検出精度を達成する可能性を持つことがわかった。

以上のことを踏まえて、検出後のデータセットに対する正常なデータの割合増加の点からシャッフルデータの検出を考える。それぞれの検出手法は性質が異なり、目的に合わせて適した手法を使用することが重要であることがわかった。なお次セクションでは行動認識モデルの精度向上を目的とした最も有効な手法について議論する。




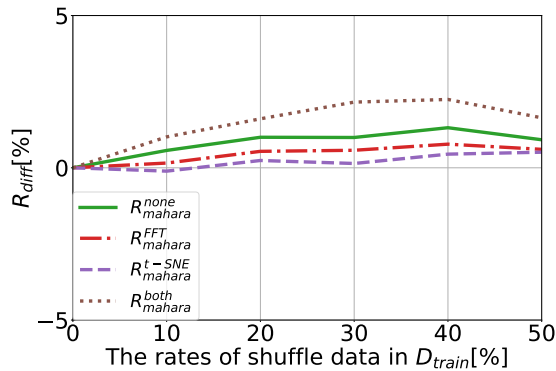


図 6: シャッフルデータの割合による除去手法適用後のデータセットに対する正常なデータの増加割合

### 5.3 検出後のデータセットでの行動認識精度

図 7 に各行動認識モデルの推定精度を示す。縦軸はそれぞれのモデルの  $D_{val}^{HAR}$  に対する推定精度であり、横軸は  $D_{train}^{HAR}$  に含まれるシャッフルデータの割合である。

はじめに、本研究の貢献 1 で示した「センサデータを用いた行動認識タスクにおいて、外れデータが推定精度に与える影響」を考察する。図 7 右の、 $M_{train}$  と  $M_{clean}$  に着目する。 $M_{train}$  はシャッフルデータを含む全ての訓練データで訓練したモデルで、 $M_{clean}$  はシャッフルデータを完全に削除できたとする理想データで訓練を行ったモデルである。これらを見ると、シャッフルデータの割合が上がると、行動認識モデルの推定精度が  $M_{clean}$  と比べ著しく下がることが分かる。したがって、外れデータの増加が行動認識モデルの推定精度の低下に影響することが明らかとなった。また、シャッフルデータの割合が増えると単調に精度が減少することから、より多くの外れデータを除去することが推定精度向上タスクにおいて重要であることを確認した。

次に、本研究の貢献 3 で示した「訓練データに外れデータが含まれる状況下における行動認識モデルの認識精度向上に関して、行動認識精度向上に寄与する外れデータ検出手法」について考察する。図 7 において、概ねどのモデルも  $M_{train}$  に比べて行動認識精度が上回っているため除去手法が行動認識モデルの精度向上に有効であることがわかる。マハラノビス距離を用いた手法はシャッフルデータの検出精度は高くはないが、行動認識精度向上には優れている。シャッフルデータの検出精度から行動認識モデルの精度への影響を考えると、マハラノビス距離を用いた手法は概ね Precision が高い順になっている。すなわち、Precision が高ければ高いほど行動認識モデルの推定精度向上がみられる。他の二つの手法においてもこの傾向はみられる。従って、より行動認識モデルの精度向上を達成するには正常なデータを誤って検出しないことが重要であることが分かった。

## 6. おわりに

今回は外れデータが行動認識に与える影響を検証し、外れデータ検出手法である OC-SVM、クラス確率に基づく手法、マハラノビス距離に基づく手法の 3 つの外れデータ検出手法の有効性の比較を行った。

外れデータによって行動認識精度が低下することや外れデータ検出によって行動認識精度が向上することから外れデータが行動認識精度に与える影響があることを確認した。また、今回比較した 3 つの外れデータ検出手法のうちマハラノビス距離を用いた手法が最も行動認識精度を向上させることがわかった。手法の比較を行うことで、外れデータ検出を行って行動認識モデルの推定精度を向上させる場合、検出されたデータに占める外れデータの割合を高めることが重要であることが分かった。一方で、検出されたデータの数多くはなかったため、データクレンジングとしての役割を果たしているとはあまりいえない。

今後は、本研究で得られた知見を用いて検出されたデータに占める外れデータの割合をより高めることができる手法や、検出されたデータに占める外れデータの割合を保ったまま検出できるデータ数を高める手法を開発し、外れデータ検出の精度を高めていきたい。

## 参考文献

- [1] QUINLAN, J.: Induction of decision trees, *Machine Learning*, Vol. 1, No. 1, pp. 81–106 (1986).
- [2] 黒滝紘生, 中山雅俊, 山口亮平, 河添悦昌, 大江和彦, 松尾 豊: 深層学習による胸部 X 線写真からの診断補助, *Proceedings of The 31st Annual Conference of the Japanese Society for Artificial Intelligence*, 一般社団法人 人工知能学会, pp. 2B13–2B13 (2017).
- [3] Bergmann, P., 'o, S. L., Fauser, M., Sattlegger, D. and Steger, C.: Improving Unsupervised Defect Segmentation by Applying Structural Similarity To Autoencoders, *arXiv preprint arXiv:1807.02011* (2018).
- [4] Malhotra, P., Vig, L., Shroff, G. and Agarwal, P.: Long Short Term Memory Networks for Anomaly Detection in Time Series, *Proceedings of European Symposium on*





図 7: シャッフルデータの割合による行動認識モデルの推定精度

*Artificial Neural Networks, Computational Intelligence and Machine Learning.*, pp. 89–94 (2015).

- [5] Zhu, X., Wu, X. and Chen, Q.: Eliminating Class Noise in Large Datasets, *Proceedings of the 20th International Conference on Machine Learning*, pp. 920–927 (2003).
- [6] Gamberger, D., Lavrač, N. and Džeroski, S.: NOISE DETECTION AND ELIMINATION IN DATA PREPROCESSING: EXPERIMENTS IN MEDICAL DOMAINS, *Applied Artificial Intelligence*, Vol. 14, No. 7, pp. 1443–1471 (2000).
- [7] Yang, J. B., Nguyen, M. N., San, P. P., Li, X. L. and Krishnaswamy, S.: Deep convolutional neural networks on multichannel timeseries for human activity recognition, *Proceedings of the 24th International Joint Conference on Artificial Intelligence* (2015).
- [8] Schölkopf, B., Platt, J. C., Shawe-Taylor, J., Smola, A. J. and Williamson, R. C.: Estimating the Support of a High-Dimensional Distribution, *Neural Computation*, Vol. 14, No. 7, pp. 1443–1471 (2001).
- [9] Kawaguchi, N., Ogawa, N., Iwasaki, Y., Kaji, K., Terada, T., Murao, K., Inoue, S., Kawahara, Y., Sumi, Y. and Nishio, N.: HASC Challenge: Gathering Large Scale Human Activity Corpus for the Real-World Activity Understandings, *Proceedings of the 2nd Augmented Human International Conference*, pp. 1–5 (2011).
- [10] van der Maaten, L. and Hinton, G.: Visualizing Data using t-SNE, *Journal of Machine Learning Research*, Vol. 9, pp. 2579–2605 (2008).
- [11] W.Cooley, J. and W.Tukey, J.: An algorithm for machine calculation of complex Fourier series, *Mathematics of Computation*, Vol. 19, No. 90, pp. 297–301 (1965).