

# 腕装着型センサの時系列情報と顔の温度分布を用いた 温熱快適性推定法の提案

吉川 寛樹<sup>1</sup> 内山 彰<sup>1</sup> 東野 輝夫<sup>1</sup>

**概要：**近年、空調に対する満足度である温熱快適性を推定することで、住居だけでなく学校やオフィスなどにおいて快適な空調制御を行うための研究が盛んに行われている。それらの手法は機械学習を用いることで、ウェアラブルセンサなどにより測定した生体情報と、気温などの環境情報から人の温熱快適性を推定する。それらの多くは推定時点での瞬間的な情報のみの特徴量としており、同一の空間内に留まった被験者において評価を行っている。しかし実環境においては、広い室内の窓際など同じ部屋でも環境が異なる場所が存在し、居住者の移動や気流の変化によっても快適性に関わる周囲の環境は変化する。そのため実環境においては、そのような変化が伴う非定常な環境において正確に推定を行うことが求められる。そこで本研究では、常時生体情報を測定可能な腕装着型センサの特徴を利用し、生体情報の時系列的な変化を用いた温熱快適性推定手法を提案する。推定モデル構築のため被験者 21 名からのべ 123 日分のデータを収集し評価を行ったところ、ベースライン手法と比較して適合率が 3.6%、再現率が 6.8%向上した。また実環境において収集したデータの不均衡を改善するために、時系列データを含むデータセットに対する回帰問題におけるデータバランシング手法を実装し有効性を示した。さらに過去の生体情報の考慮する時間の長さについて評価を行い、過去 10 分間の生体情報を用いることが推定精度向上には有効であることを示した。

## 1. 研究背景

適切な空調制御が労働生産性 [1] や学習効率 [2], [3] を高めることがわかっており、オフィスビルや学校などでは適切な空調制御が求められる。しかし、それらの施設において常に適切な空調制御を行うことは難しい。なぜなら、環境の空間的な不均一性や屋外の気象変化の影響によって理想的な環境が動的に変化する [4], [5] ためである。また、同じ空調環境であっても衣服や代謝の影響により温熱快適性は個人によって異なる [6]。さらに同じ建物内での異なる部屋の移動や、同じ部屋の中での座席の移動など空調環境の異なる空間へ移動することによって、温熱快適性は変化する。理想的な空調環境も変化する [4]。そのため、同じ空調環境に対し常に同じ空調制御を行うだけでは快適な環境を実現することは難しい。それらの理由から、適切な空調環境を実現するためには動的に変化する個人の温熱快適性を把握することが必要となる。

温熱快適性を推定する研究は多く行われており、Fanger は PMV(Predicted Mean Vote) と呼ばれる、人間の温熱快適性を -3 から +3 までの 7 段階 (cold, cool, slightly cool,

neutral, slightly warm, warm, hot) で表現する指標を提案している [7]。この 7 段階の温熱快適性指標は空調に関する国際的な学会である ASHRAE(American Society of Heating, Refrigerating and Air-Conditioning Engineers) の 7 段階指標として近年の研究においても広く用いられていることから、本研究でも温熱快適性の指標として用いる。PMV は人間の温熱快適性を環境要因である、気温、湿度、風速、熱放射と人体側の要因である代謝、着衣量から算出される。しかしながら、これらの値を計測するためには様々なセンサを用いる必要があることや、測定対象人物付近の計測値が必要なことから、個人ごとの PMV は用意に推定できない。また PMV により算出された温熱快適性は、前述の異なる環境への移動などに伴って温熱快適性が変化する状況が考慮されておらず、TSV(Thermal Sensation Vote) と呼ばれる実際に人間が感じる温熱快適性と必ずしも一致しないことが報告されており [8], [9]、TSV を推定することは更に困難な課題となっている。

そのような理由から近年では、機械学習に基づく手法によりウェアラブルセンサから取得した生体情報を用いて TSV を推定する研究が盛んに行われている [10], [11]。これらの文献では心拍数を用いて推定するために、測定精度の問題から腕装着型センサではなくチェストストラップ型のセンサが、ウェアラブルセンサとして使用されており、

<sup>1</sup> 大阪大学 大学院情報科学研究科  
Graduate School of Information Science & Technology, Osaka University

これらのシステムは普及率や侵襲性の点で実環境での導入が困難である。しかし、ウェアラブルセンサとして腕装着型センサのみで測定できる生体情報には制限があるために、温湿度といった環境情報のみを用いた推定に対して、大きな精度向上は難しい。

そこで侵襲性を伴わないセンサとしてサーモグラフィを用いて体表温度を測定し、TSV を推定する研究が行われている [12], [13]。これらの文献では、環境情報に加えてサーモグラフィにより測定した顔周辺の体表温度や、腕装着型センサにより測定した心拍数、手首の体表温度を用いることで、環境情報のみを用いた推定に対して高精度な推定を実現している。しかしながら、これらの生体情報を用いて TSV を推定する多くの研究では、空間の移動に伴う空調環境の急な変化への対応については評価されておらず、前述のような実生活において起こりうる非定常環境に対し高精度に推定を行うには至っていない。さらに、多くの TSV 推定を扱った文献 [10], [13], [14], [15], [16] では評価に用いるデータセットに  $8 - 10^{\circ}\text{C}$  ほど幅のある気温設定下で収集されたデータを用いて評価を行っており、本来空調環境がある程度温湿度的に快適となるよう制御されたオフィスや学校などの環境との乖離が大きい。

しかしながら空調制御された環境における微細な変化を捉えた TSV 推定を行うことは通常困難である。そこで本研究ではそのような温度の変化幅の小さい、かつ空間の移動による空調環境の変化が発生するような実環境に即した TSV 推定手法を提案する。提案手法では、腕装着型センサにより測定した時系列生体情報とサーモグラフィにより測定した顔の温度分布を組み合わせることで、時間的な生体情報の遷移と現在の環境に対する生体反応を捉え TSV を推定する。本研究では図 1 に示すように、常時腕装着型センサにより生体情報のセンシングを行い、扉上部や机上に設置されたサーモグラフィカメラにより瞬間的に顔表面の温度が測定される環境を想定する。サーモグラフィによる測定が行われた時点で、それまでに測定した腕装着型センサによる生体情報を組み合わせ、機械学習に基づいて TSV を推定する。評価実験として被検者 21 名からのべ 123 日分のデータ収集を行い、合計 1442 個の TSV 入力を得た。実環境を想定して収集された本研究のデータセットに含まれる多くのデータは、快適な状態において収集されている。そのような不均衡なデータセットを用いることから、本研究では過学習を防ぐため、回帰問題における時系列データに対するデータバランシング手法についても構築した。推定精度の評価の結果、ベースラインとした時系列情報を考慮しない推定と比較し、適合率 3.6%、再現率 6.8% の精度向上を確認した。さらに過去の生体情報について考慮する時間の長さについても評価を行い、過去 10 分の生体情報を考慮することが TSV 推定において有効であることを示した。本研究の貢献を以下にまとめる。




図 1 想定環境。

- 時系列として取得した生体情報と、瞬間的に測定した環境情報及び生体情報それぞれを用いた TSV 推定器を別々に構築し、それらの推定器を組み合わせることで、実環境における空調環境の変化を考慮したアンサンブル推定器を構築した。評価の結果、瞬間的な情報のみを用いた推定に比べ提案手法が有効であることを示した。
- 機械学習の回帰問題において、時系列データを含む不均衡データのバランシング手法を構築し、温熱快適性推定精度への影響を評価することで手法の有効性を示した。
- 時系列情報を考慮する提案手法において用いる過去の生体情報の長さを変化させることで、温熱快適性推定において考慮が必要な過去の時間の長さについて評価を行った。

## 2. 関連研究

### 2.1 温熱快適性と生体情報

温熱快適性を推定する手法は古くから多く研究が行われている。Brager ら [17] は季節により温熱快適性推定のモデルを切り替える手法を提案している。これは単純な室内気温などの環境要素のみのセンシングでは快適な状態を推定することが難しいことを示している。Fanger[7] によれば温熱快適性は気温や湿度などの環境要因 [18] に加え、環境内の人間の代謝量や着衣量などの人的要因も関係して変化することが明らかになっている。高田らは 7 点法 [19] を用いて取得した人体各部位の平均皮膚温度から非定常環境における TSV を推定するモデル [20] や個人の特徴を反映した皮膚温度と深部体温による推定モデル [21] を構築している。これらの文献により体温は TSV を決定する重要な要因であることが示されている。心拍変動から高精度に空調環境に対する不快感を検知する手法 [22] も存在する。この手法では心拍変動のみから不快感の検知を行っており、詳細な心拍変動を用いることで TSV を推定できることを示している。皮膚電位は発汗に伴って変化する指標である [23]。そのため皮膚電位を TSV の指標として用いる研

究も多く存在し [24], [25], [26], 推定のための特徴量として有効であることがわかる。これらの既存研究から、本研究では個人の TSV を高精度に推定するため環境情報である温湿度に加え、生体情報である体表温度、心拍、皮膚電位を用いる。

## 2.2 ウェアラブルセンサを用いた温熱快適性推定

Barrios ら [10] は心拍数をチェストストラップ型のウェアラブルセンサから取得することで、機械学習に基づく手法により TSV を推定している。同文献では腕装着型センサを心拍センサとして用いることも検討されているが、測定誤差がチェストストラップ型に比べ大きいと、腕装着型センサから取得した心拍数を特徴量として高精度に推定を行うことは難しいとしている。Liu ら [11] は腕装着型とチェストストラップ型に加え足首にもウェアラブルセンサを装着し、日常生活における生体情報を収集することで個人向けの推定器を構築している。同手法では被験者の移動にも対応可能である一方で、多くのウェアラブルセンサを必要としており侵襲性の観点からオフィスや学校などの実環境で導入するのは難しい。PMV を利用することで、ウェアラブルセンサを用いた温熱快適性推定を行う研究も存在する。Hasan ら [27] は腕装着型センサにより取得した心拍数と加速度から代謝率を推定し、PMV を算出する手法を提案している。しかし PMV は、非定常環境を想定していないため実環境においてユーザが感じる温熱快適性と必ずしも一致しないことがわかっており [8], [9], ユーザの温熱快適性に応じた空調制御を行うために PMV を用いることは必ずしも適切とは言えない。また、これらのウェアラブルセンサを用いた推定手法は測定した生体情報の過去数分間、あるいは数時間の平均値や最大値、最小値、回帰直線の傾きなどの統計量のみを特徴量として用いており、詳細な変動は考慮されていない。本研究では非定常環境へ対応した推定を行うために、RNN の一種である LSTM を用いた深層学習器を構築し各生体情報の波形から時系列的な変化の情報を特徴量として抽出することで高精度に推定を行う。

## 2.3 熱画像を用いた温熱快適性推定

近年の研究では顔の温度分布のような面的な体表温度情報を非侵襲に測定できることからサーモグラフィが TSV の推定に使用されている。Ranjan ら [12] はサーモグラフィにより取得した熱画像を用いて TSV を推定することで、建物内のエネルギー消費を削減できることを示唆している。さらに Aryal ら [13] は、室内温度を徐々に上昇あるいは下降させる非定常環境において、推定精度向上のため他の生体センサと熱画像を組み合わせることで TSV を推定している。Cosma ら [15] は熱画像から顔の複数部位の温度を抽出し、設定温度を固定した定常環境において学習データ

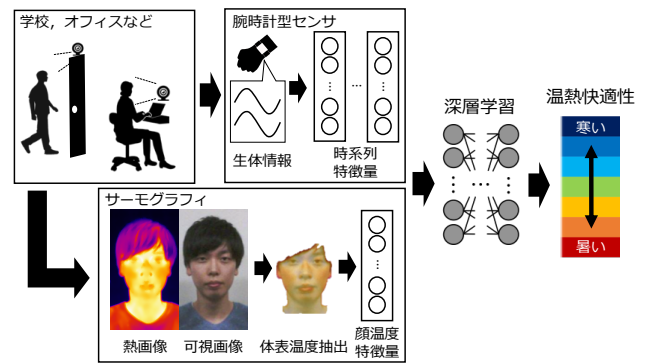


図 2 提案手法の概要。

を収集し、徐々に設定温度を変化させる非定常環境において推定精度を評価している。しかしながらこれらの文献では、最高室温を 30°C 付近、最低室温を 20°C 付近と大きく変化させることで不快な状態を意図的に作り出し性能評価をしているため、実環境で発生する微細な室温変化は評価の対象となっていない。また、空間の移動により周囲環境が瞬時に変化し、人体がその環境に徐々に慣らされるといった非定常環境は想定されていない。本研究では、可視画像と熱画像を組み合わせることで顔の温度分布の抽出システムを構築し、抽出した体表温度情報を腕装着型センサによる時系列情報と組み合わせることで非定常環境に対応した推定を実現する。

## 3. 提案手法

### 3.1 手法概要

本研究では腕装着型センサとサーモグラフィを組み合わせた温熱快適性推定法を提案する。手法の概要を図 2 に示す。腕装着型センサによる測定値は実環境における微細な空調環境の変化に対する生体反応の情報として用いる。さらにサーモグラフィを用いて顔の温度分布を取得し、現在の空調環境に対する生体反応を推定に反映する。それらの生体情報と環境情報である温湿度を組み合わせる推定を行うために深層学習に基づいた推定器を複数構築し、組み合わせることでアンサンブル推定器を構築する。以下では、腕装着型センサにより測定した時系列生体情報に基づく推定器と、瞬間的に測定した生体情報と環境情報に基づく推定器を構築し、それらを組み合わせるアンサンブル推定器の構築手法について述べる。

### 3.2 入力データの前処理

#### 3.2.1 腕装着型センサによる測定

本研究では、時系列生体情報として一般的に腕装着型センサに搭載されているセンサを用いて測定可能な心拍数 ( $W_{hr}$ ), 体表温度 ( $W_{temp}$ ), 皮膚電位 ( $W_{eda}$ ) を用いる。それらの時系列情報として時刻  $t$  から時間  $N$  だけ遡った  $W_{hr}^t = \{W_{hr}^t, \dots, W_{hr}^{t-N}\}$ ,  $W_{temp}^t = \{W_{temp}^t, \dots, W_{temp}^{t-N}\}$ ,






図 3 顔の温度分布抽出の流れ.




図 4 顔の各部位の位置.

表 1 顔の各部位の位置を示す矩形の算出式.  $X, Y, W, H$  はそれぞれ顔の  $x$  座標,  $y$  座標, 横幅, 縦幅であり, それぞれの座標は矩形の左上の頂点座標である.

Part	$x$ ,	$y$	width,	height
額	$X + 7W/16$ ,	$Y + H/4$	$W/8$ ,	$H/8$
右頬	$X + W/5$ ,	$Y + 9H/16$	$W/6$ ,	$H/4$
左頬	$X + 19W/30$ ,	$Y + 9H/16$	$W/6$ ,	$H/4$
鼻先	$X + 7W/16$ ,	$Y + H/2$	$W/8$ ,	$H/8$
口	$X + 3W/8$ ,	$Y + 3H/4$	$W/4$ ,	$H/8$

$\mathbf{W}_{eda}^t = \{W_{eda}^t, \dots, W_{eda}^{t-N}\}$  を時刻  $t$  における推定器への入力として用いる. ここで  $W_X^t$  は, 時刻  $t$  における腕装着型センサによる生体情報  $X$  の測定値である. 本研究では各生体情報について 1 分間の平均値を測定値として扱う. 4.5 項では考慮する過去の時間として最適な  $N$  についての評価を行う.

### 3.2.2 サーモグラフィによる測定

本研究では, 1 節で述べたようにユーザーがサーモグラフィに正対し, 熱画像として顔付近の温度分布を取得可能な環境を想定する. 顔付近の温度分布から顔表面の温度のみを抽出するために, 前処理の一部として図 3 のようなマスク処理を行う. まず可視画像から顔の体表だけを残したマスク画像を生成する. マスク画像は肌検出 [28] と OpenCV の haar-like 特徴による顔検出 [29] をそれぞれ行い, それらの二値化画像の積集合によって生成する. 生成されたマスク画像を用いて, 熱画像に対しマスク処理を行うことで顔の温度分布のみを熱画像から抽出する. 可視画像と熱画像は異なるカメラを用いて撮影されるため, 各画像内の撮影対象の位置にもずれが生じ, マスク処理を行うためには各画像の画素を対応付ける必要がある. そこで文献 [30] に基づき, エッジ検出に基づく可視画像と熱画像の重ね合わせ

を行うことで各画像の画素を対応させ, マスク処理を行う.

推定器への入力としてマスク処理により生成された顔の温度分布から特徴量を抽出する. 特徴量として用いるのは図 4 に示す額, 右頬, 左頬, 鼻先, 口周りの各部位の温度と, 顔の温度分布の最大, 最小, 平均, 分散である. 時刻  $t$  におけるそれぞれの値を  $T_{fh}^t, T_{r\_chk}^t, T_{l\_chk}^t, T_{ns}^t, T_{mth}^t, T_{max}^t, T_{min}^t, T_{ave}^t, T_{var}^t$  と表し, 時刻  $t$  における推定器への入力として用いる. 顔の各部位の温度は表 1 に示す式により算出した各矩形内の温度の平均を用いる.

### 3.3 アンサンブル推定器の構築

時系列情報と瞬時的な情報を組み合わせるために, それぞれに対して TSV の推定器を構築し, それらの学習済みのネットワークを転移学習させ, 組み合わせたアンサンブル推定器を構築する. また, これらの推定器への入力には正規化されたデータを用いる. アンサンブル推定器の構成を図 5 に示す.

時系列情報に基づく推定器は (図 5 上部) 腕装着型センサにより取得した生体情報  $\mathbf{W}^t = \{\mathbf{W}_{hr}^t, \mathbf{W}_{temp}^t, \mathbf{W}_{eda}^t\}$  を入力とし, 1 層の LSTM 層と 2 層の全結合層 (FC 層) から構成されている. また, 問題の非線形性を考慮するため, 活性化関数として LSTM 層の出力には Tanh 関数を, 前の全結合層の出力には ReLU 関数を用いる. 過学習を防ぐためのドロップアウト率は 0.5 とする. より詳細な特徴を抽出可能なネットワークを構築するため, TSV ( $V_t$ ) を正解データとした回帰問題として学習させることで, ユーザーの TSV を数値として出力する推定器を構築する. 以降ではこの推定器を LSTM<sub>part</sub> と表記する.

瞬時的な情報に基づく推定器は (図 5 下部) 腕装着型センサによる測定値  $\mathbf{W}^t = \{\mathbf{W}_{hr}^t, \mathbf{W}_{temp}^t, \mathbf{W}_{eda}^t\}$  と, サーモグラフィによる顔表面温度の測定値  $\mathbf{T}^t = \{T_{fh}^t, T_{r\_chk}^t, T_{l\_chk}^t, T_{ns}^t, T_{mth}^t, T_{max}^t, T_{min}^t, T_{ave}^t, T_{var}^t\}$  に加え, 時刻  $t$  における室内の気温と相対湿度をそれぞれ  $A_{temp}^t, A_{humid}^t$  と表し,  $\mathbf{A}^t = \{A_{temp}^t, A_{humid}^t\}$  を推定器への入力として用いる. こちらの推定器は 2 層の全結合層 (FC 層) から構成され, 一層目の全結合層の出力には ReLU 関数を活性化関数として用い, ドロップアウト率は 0.5 とする. こちらも TSV を正解データとし回帰問題として学習させることで, ユーザーの TSV を数値として出力する推定器を構築する. 以降ではこの推定器を FC<sub>part</sub> と表記する.

これら学習済みの推定器の一層目の隠れ層同士を結合することで 20 ノードの隠れ層を形成し, 2 層の全結合層を用いて, TSV を多クラス分類として再度学習させることでアンサンブル推定器を構築する. 1 層目の全結合層では活性化関数を ReLU 関数とし, ドロップアウト率を 0.5 とする.

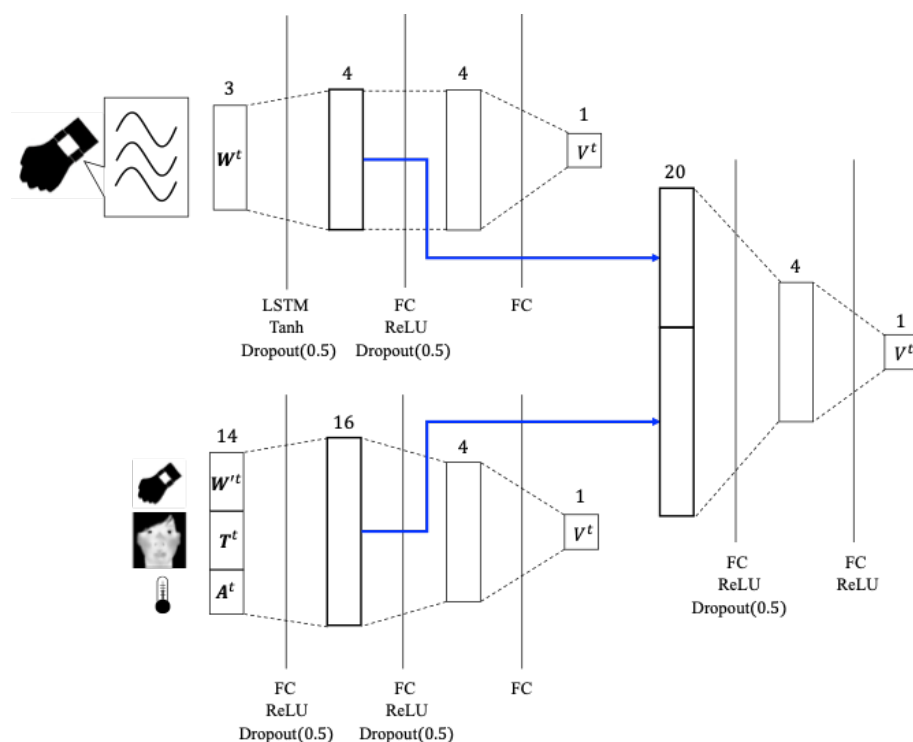


図 5 推定器の構成.

表 2 シナリオ A における TSV のクラス別申告数.

TSV	申告数
-3 (Cold)	10
-2 (Cool)	33
-1 (Slightly cool)	142
0 (Neutral)	679
1 (Slightly warm)	152
2 (Warm)	33
3 (Hot)	3

表 3 シナリオ B における TSV のクラス別申告数.

TSV	申告数
-3 (Cold)	0
-2 (Cool)	24
-1 (Slightly cool)	77
0 (Neutral)	231
1 (Slightly warm)	53
2 (Warm)	5
3 (Hot)	0

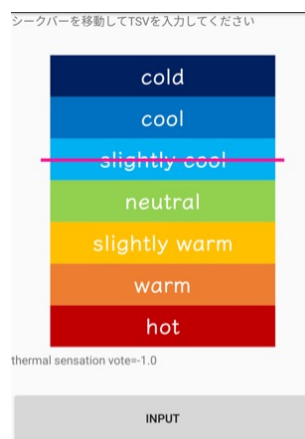


図 6 スマートフォンアプリによる TSV 収集画面.

$[-3.5, 3.5]$  の範囲で小数第一位まで入力することができる. 以降では入力された TSV は, 7 段階の分類において  $[-3.5, -2.5]$  を Cold,  $(-2.5, -1.5]$  を Cool,  $(-1.5, -0.5]$  を Slightly cool,  $(-0.5, 0.5]$  を Neutral,  $[0.5, 1.5]$  を Slightly warm,  $[1.5, 2.5]$  を Warm,  $[2.5, 3.5]$  を Hot として扱う. また両シナリオでは共通して, 腕装着型センサとして Empatica 社の E4 wristband[31], サーモグラフィカメラは FLIR 社の FLIR T540[32] を使用した. シナリオ A では空調の効いた部屋で服装の指定は行わず, 30 分ごとに TSV と熱画像, 可視画像を収集した. 実験の間被験者は腕時計型のデバイスを装着し, 心拍数, 手首体表温度, 皮膚電位を測定した. このシナリオでは男性 15 名から各季節にわたってのべ 98 日分のデータを収集し, 合計 1052 個の TSV を得た. TSV 申告値の内訳を表 2 に示す. 平時と同様に空調

## 4. 評価

### 4.1 評価環境

評価のため 2 つのシナリオ (シナリオ A, シナリオ B) を設定し, 研究室環境で温熱快適性を収集する実験を行った. 図 6 に示すように, 被験者はスマートフォンアプリ上でシークバーを上下させることにより TSV 入力を行い,

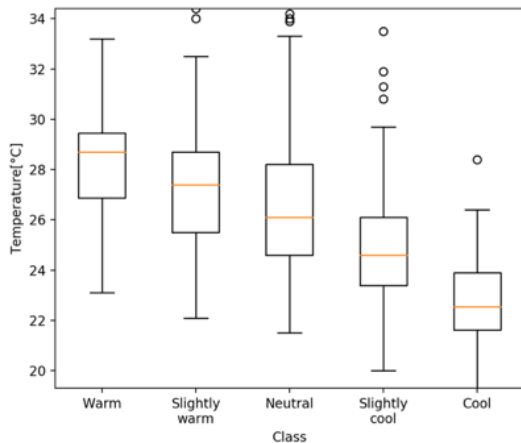


図 7 TSV 各クラスにおける室内温度の分布.

の設定温度を制御したため、Neutral が最も多く申告され、3(Hot) や-3(Cold) はほとんど申告されなかった。シナリオ B では空調の効いた部屋において発生しうる  $1^{\circ}\text{C}$  から  $5^{\circ}\text{C}$  ほどの温度差がある 2 部屋を 30 分から 1 時間ごとに被験者が移動する非定常な環境において実験を行った。この実験でも服装の指定は行わず、10 分ごとに同様に TSV と熱画像、可視画像を収集し、腕時計型のデバイスにより各生体情報を測定した。このシナリオでは男性 10 名、女性 2 名からのべ 25 日分のデータを収集し、合計 390 個の TSV 入力を得た。TSV 申告値の内訳を表 3 に示す。この実験では、実環境を考慮したわずかな温度差を設定しており、3(Hot) や-3(Cold) は全く申告されなかった。

各シナリオのうち 6 名は両シナリオに参加しており、合計 21 名、のべ 123 日分のデータを収集した。その間収集した TSV 申告値と室内温度の関係を図 7 に示す。申告数が少ないため Hot は Warm に、Cold は Cool に含む。図 7 のように室温が高いほど TSV も Warm に近づく傾向はあるが、同じ室温でも申告が異なることもあり室温のセンシングだけでは推定が難しいことがわかる。

#### 4.2 各特徴量の重要度

ランダムフォレストでの推定に 3.3 項で定義した特徴量である  $\{W^t, T^t, A^t\}$  を用いることで、各特徴量の重要度 (feature importance) を算出した結果を図 8 に示す。この指標は推定対象のデータを分類する際に、ある特徴量を用いることで下げることができる不純度 (impurity) を相対値として算出したものである。これによると、TSV 推定において最も重要な特徴量は気温 ( $A_{temp}$ ) であり、次いで頬の温度 ( $T_{r\_chk}, T_{l\_chk}$ ) や体表画素の検出により算出した顔全体の平均温度 ( $T_{ave}$ ) が重要であることがわかる。また、腕装着型センサによる測定値の中では手首の体表温度 ( $W_{temp}$ ) が最も重要であり、心拍数 ( $W_{hr}$ ) は重要度が低い結果となった。これには文献 [10] でも報告されているよう




図 8 各特徴量の TSV 推定に対する重要度.

に腕装着型センサの心拍測定精度が影響していることが考えられる。

#### 4.3 不均衡データのバランシング

本研究で収集した TSV は 4.1 節で述べたように Neutral の多い不均衡なデータセットとなっている。そのようなデータセットに対し機械学習を行うと、データ量の多い値を推定値として出力しやすい推定器となる。本研究では部分的な推定器を回帰問題として学習させることから、回帰問題のためのデータのバランシング手法である SMOGN[33] を用いてデータの不均衡を緩和させる。SMOGN はクラス分類のためのオーバーサンプリング手法である SMOTE[34] を回帰問題に対し拡張した手法である SMOTER[35] とガウスノイズによるデータ生成を組み合わせた手法である。しかしながら、SMOGN では時系列データに対し新たなデータを生成することは想定されていないため、LSTM<sub>part</sub> への入力データに対するバランシング手法として用いることはできない。そこで本研究では 2 クラス分類のための時系列データの生成手法である TS.SMOTE[36] を SMOTER と組み合わせることでバランシングを行う。

時系列データのバランシング手法について述べる。Algorithm 1 に示すように、SMOTER に従い  $\phi(y)$  のしきい値  $t_E$  に基づいて、オーバーサンプリングを行うデータとアンダーサンプリングを行うデータの境界を決定する。ここで  $\phi(y)$  はデータのユニークさを示す関数であり、値が大きいほどサンプル数の少ないデータ ( $y$ ) であることを示す。決定した境界に基づき、 $y$  の中央値  $\tilde{y}$  より小さいデータと大きいデータに分割してデータの生成を行う。時系列データの生成手法を Algorithm 2 に示す。オーバーサンプリング対象データに含まれるあるサンプル (case) に対して、Dynamic Time Warping[37] により算出した距離に基づき K 近傍を抽出する。その中からランダムに選出した近傍 ( $n$ ) について TS.SMOTE により、新たな時系列

**Algorithm 1** Main SMOTER algorithm.

**Input:**  $\mathcal{D}$  - A data set  
 $t_E$  - Threshold  
 $\%o, \%u$  - Percentages of over- and under-sampling  
 $k$  - Number of neighbours used in case generation

**Output:**  $\mathcal{D}_{new}$  - A generated data set

```

rareL  $\leftarrow \{(\mathbf{x}, y) \in \mathcal{D} : \phi(y) > t_E \wedge y < \tilde{y}\}$ 
newCasesL  $\leftarrow \text{GENSYNTHCASES}(\text{rareL}, \%o, k)$ 
rareH  $\leftarrow \{(\mathbf{x}, y) \in \mathcal{D} : \phi(y) > t_E \wedge y > \tilde{y}\}$ 
newCasesH  $\leftarrow \text{GENSYNTHCASES}(\text{rareH}, \%o, k)$ 
newCases  $\leftarrow \text{newCasesL} \cup \text{newCasesH}$ 
nrNorm  $\leftarrow \%u$  of  $|\text{newCases}|$ 
normCases  $\leftarrow \text{sample of nrNorm case} \in \mathcal{D} \setminus \{\text{rareL} \cup \text{rareH}\}$ 
return  $\text{newCases} \cup \text{normCases}$ 

```

**Algorithm 2** Generating synthetic cases.

**Input:**  $\mathcal{D}, \%o, k$

**Output:**  $\mathcal{D}_{new}$

```

newCases  $\leftarrow \{\}$ 
ng  $\leftarrow \%o/100$ 
for all case  $\in \mathcal{D}$  do
  nns  $\leftarrow \text{KNN}(k, \text{case}, \mathcal{D} \setminus \{\text{case}\})$ 
  for i  $\leftarrow 1$  to ng do
    n  $\leftarrow$  randomly choose one of the nns
     $\alpha \leftarrow$  randomly choose in  $[0, 1]$ 
    new[y]  $\leftarrow \min(\text{case}[y], n[y]) + \alpha|\text{case}[y] - n[y]|$ 
    for all f  $\in$  features do
      warpPairs  $\leftarrow \text{DTW}(\text{case}[f], n[f])$ 
      for t  $\leftarrow 1$  to  $|\text{warpPairs}|$  do
         $(t_{new}, v_{new}) \leftarrow \text{TIMEPOINT}(\text{warpPairs}[t]_{\text{case}}, \text{warpPairs}[t]_n, \text{case}[f], n[f], \alpha)$ 
        new[f, tnew]  $\leftarrow v_{new}$ 
      end for
    end for
    newCases  $\leftarrow \text{newCases} \cup \{\text{new}\}$ 
  end for
end for
return newCases

function TIMEPOINT( $t_a, t_b, ts_a, ts_b, \alpha$ )
  tnew  $\leftarrow \min(t_a, t_b) + (t_a + t_b)/2$ 
  vnew  $\leftarrow \min(ts_a[t_a], ts_b[t_b]) + \alpha|ts_a[t_a] - ts_b[t_b]|$ 
  return tnew, vnew
end function

```

データ ( $new$ ) を生成する。それを繰り返すことで目的のサンプル数 ( $ng$ ) を生成し、生成された新しいデータセット ( $newCases$ ) を返す。

**4.4 性能評価の指標**

本研究では、申告された TSV に対して Cold, Cool, Slightly Cool をまとめて Cool とし、Hot, Warm, Slightly Warm をまとめて Warm とした 2 クラスに、Neutral を加えた 3 クラスのクラス分類として手法の評価を行う。評価は被験者をランダムに 4 分割して作成したグループに対し、3 つのグループを学習データとし、残りの 1 つのグループをテストデータとする LOGO(Leave One Group Out) 交差検証により行う。推定精度は Warm, Neutral, Cool の 3

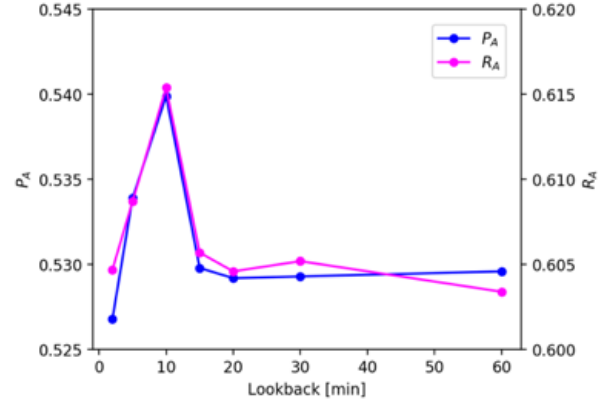


図 9 ルックバック時間と推定精度の関係。

表 4 データバランシングの有無による推定精度。

	LSTM <sub>part</sub>		FC <sub>part</sub>		提案手法	
	$P_A$	$R_A$	$P_A$	$R_A$	$P_A$	$R_A$
有	<b>0.392</b>	<b>0.460</b>	<b>0.524</b>	<b>0.585</b>	<b>0.540</b>	<b>0.615</b>
無	0.383	0.434	0.517	0.579	0.522	0.602
% $\Delta$	<b>2.3</b>	<b>6.0</b>	<b>1.4</b>	<b>1.0</b>	<b>3.4</b>	<b>2.6</b>

クラスそれぞれの適合率の平均 ( $P_A$ ) と再現率の平均 ( $R_A$ ) により比較する。

**4.5 考慮する過去の時間の評価**

提案手法では腕装着型センサにより測定した各生体情報の過去一定時間分の測定値を特徴量として用いる。本項ではそれら生体情報を遡って用いる時間 (ルックバック時間) についての評価を行う。ルックバック時間を 2 分から 60 分まで変化させたときの、推定精度を図 9 に示す。2 分から 5 分、10 分、15 分、20 分、30 分、60 分とルックバック時間を変化させた。その結果、10 分まではルックバック時間が長くなるのに従って推定精度も向上し、10 分に設定したときに推定精度が最も高い結果 ( $P_A = 0.540, R_A = 0.615$ ) となった。以降ではルックバック時間を 10 分として評価を行う。

**4.6 データバランシングの効果**

LSTM<sub>part</sub> に入力するデータセットに対して、4.3 節で述べたように SMOTER と TS\_SMOTE を組み合わせた手法によりバランシングを行う。また、FC<sub>part</sub> に入力するデータセットに対して SMOGN を適用する。それらのデータバランシングの有無による推定精度の比較を表 4 に示す。推定精度は Warm, Neutral, Cool の 3 クラスそれぞれの適合率の平均 ( $P_A$ ) と再現率の平均 ( $R_A$ ) によって評価する。% $\Delta$  はデータバランシングによって精度が向上した割合を示す。LSTM<sub>part</sub>, FC<sub>part</sub> のそれぞれの推定精度は回帰問題として学習を行った後、もう一方の推定器との結合を行わずに 3 クラス分類として学習した結果である。この






図 10 各推定手法による混同行列.

表 5 温熱快適性推定精度の評価.

手法	$P_A$	$R_A$
提案手法	<b>0.540</b>	<b>0.615</b>
RF	0.521	0.576
% $\Delta$	<b>3.6</b>	<b>6.8</b>

結果, データバランシング手法によりそれぞれの推定で精度が向上したことから, バランシング手法が推定精度に対して有効に働くことがわかった.

#### 4.7 温熱快適性推定精度

本項までの評価によって, 表 4 からわかるように腕装着型センサ, サーモグラフィ, 環境センサによる瞬間的な情報と腕装着型センサによる時系列情報を組み合わせることで精度が向上することを確認した. 文献 [14] で述べられているように, 温熱快適性推定手法に用いる機械学習手法としてランダムフォレスト (RF) が特に小さなデータセットに対しては優れたパフォーマンスを示すことがわかっている. そのため  $FC_{part}$  への入力として用いるデータを入力とした RF をベースラインとして提案手法の精度を評価する. RF による推定結果の混同行列を図 10(a) に, 提案手法による推定結果の混同行列を図 10(b) に示す. また, 各クラスの適合率の平均 ( $P_A$ ) と再現率の平均 ( $R_A$ ) を表 5 に示す. % $\Delta$  は提案手法によってベースラインである RF と比較し, 精度が向上した割合を示す. 評価の結果, RF の  $P_A$  は 0.521,  $R_A$  は 0.540 となり, 提案手法の  $P_A$  は 0.576,  $R_A$  は 0.615 となった.  $P_A$ ,  $R_A$  それぞれについて提案手法が RF を上回ったことから, 時系列情報を考慮することによる TSV 推定精度の向上が示された.

しかしながら, 提案手法においても Warm と Neutral の分類については Cool と Neutral よりも曖昧であることが図 10(b) からわかる. これは, 発汗を反映した推定を行うことを期待して用いた皮膚電位を指標とすると, 図 11 に示すように実環境における Warm の状態ではそれほど発汗しない状態が含まれていることがわかる, したがって本研究で用いた皮膚電位による発汗の検知だけでは Warm 状態の推定に対して不十分であることが示唆されている. また図 12 に示す各クラスにおける右頬の温度の分布からわかるように, Cool の状態では気温の影響を強く受け体表

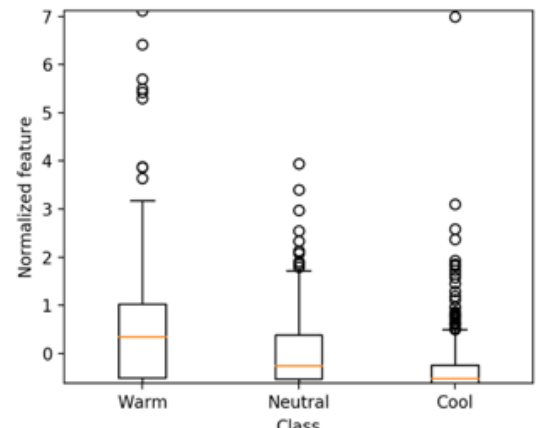


図 11 各クラスにおける皮膚電位の分布.




図 12 各クラスにおける右頬の温度の分布.

温度は下がる. 一方で, Warm の状態では体表温度がそれほど上昇せず Neutral との分布の差は小さい. そのため, Neutral と Warm の高精度な分類は発汗や体表温度を考慮するだけでは難しいことがわかった. この問題を解決するために今後筆者らはデータをさらに収集することで, ユーザごとの服装や気温などの好みを反映したパーソナル推定を構築し, 個人差を考慮することによる推定精度の向上を目指す.

#### 5. まとめ

本研究では環境情報に加え, 腕装着型センサとサーモグラフィを用いて測定した生体情報を用いて温熱快適性を推定する手法を構築した. 腕装着型センサによる生体情報の測定が常時行えることを生かし, 測定値の時系列情報を特徴量として用いることで推定精度が向上することを示した. また, 実環境において収集された温熱快適性のデータは Neutral に偏った不均衡なデータセットとなるため, 時系列データを含むデータセットに対するデータバランシング手法を構築し, 収集したデータセットに対して用いるこ



とで有効性を示した。さらに、現在の温熱快適性に影響を与える過去の時間の長さについても評価を行い、過去 10 分間の生体情報を考慮することが推定において有効であることがわかった。今後の課題として個人ごとにパーソナライズされた推定器を構築することによる推定精度の向上を考えている。

## 謝辞

本研究にあたり協力いただいたダイキン工業株式会社に感謝の意を表する。

## 参考文献

- [1] O. Seppänen, W. Fisk and Q.H. Lei: Effect of temperature on task performance in office environment, *Proceedings of Cold climate HVAC Conference, Moscow* (2006).
- [2] M.C. Lee, K.W. Mui, L.T. Wong, W.Y. Chan, E.W.M. Lee and C.T. Cheung: Student learning performance and indoor environmental quality (IEQ) in air-conditioned university teaching rooms, *Building and Environment*, Vol. 49, pp. 238 – 244 (2012).
- [3] F. Barbic, M. Minonzio, B. Cairo, D. Shiffer, A. Dipasquale, L. Cerina, A. Vatteroni, V. Urechie, P. Verzeletti, F. Badilini, M. Vaglio, R. Iatrino, A. Porta, M. Santambrogio, R. Gatti and R. Furlan: Effects of different classroom temperatures on cardiac autonomic control and cognitive performances in undergraduate students, *Physiological Measurement*, Vol. 40, No. 5 (2019).
- [4] O. Kaynakli and M. Kilic: Investigation of indoor thermal comfort under transient conditions, *Building and Environment*, Vol. 40, No. 2, pp. 165 – 174 (2005).
- [5] R. Zhao: Investigation of transient thermal environments, *Building and Environment*, Vol. 42, No. 12, pp. 3926 – 3932 (2007).
- [6] G. Havenith, I. Holmér and K. Parsons: Personal factors in thermal comfort assessment: clothing properties and metabolic heat production, *Energy and Buildings*, Vol. 34, No. 6, pp. 581 – 591 (2002).
- [7] P.O. Fanger: *Thermal Comfort: Analysis and Applications in Environmental Engineering* (1970).
- [8] N. H. Wong and S. S. Khoo: Thermal comfort in classrooms in the tropics, *Energy and Buildings*, Vol. 35, No. 4, pp. 337 – 351 (2003).
- [9] D. Teli, M.F. Jentsch, P.A.B. James and A. Bahaj: Field study on thermal comfort in a UK primary school, *Proceedings of 7th Windsor Conference: The Changing Context of Comfort in an Unpredictable World, Windsor, UK* (2012).
- [10] L. Barrios and W. Kleiminger: The Comfstat - automatically sensing thermal comfort for smart thermostats, *Proceedings of the 2017 IEEE International Conference on Pervasive Computing and Communications, Hawaii, USA*, pp. 257–266 (2017).
- [11] S. Liu, S. Schiavon, H. P. Das, M. Jin and C. J. Spanos: Personal thermal comfort models with wearable sensors, *Building and Environment*, Vol. 162 (2019).
- [12] J. Ranjan and J. Scott: ThermalSense: Determining Dynamic Thermal Comfort Preferences using Thermographic Imaging, *Proceedings of the 2016 ACM International Joint Conference on Pervasive and Ubiquitous Computing*, ACM (2016).
- [13] A. Aryal and B. Becerik-Gerber: A comparative study of predicting individual thermal sensation and satisfaction using wrist-worn temperature sensor, thermal camera and ambient temperature sensor, *Building and Environment* (2019).
- [14] W. Hu, Y. Luo, Z. Lu and Y. Wen: Heterogeneous Transfer Learning for Thermal Comfort Modeling, *Proceedings of the 6th ACM International Conference on Systems for Energy-Efficient Buildings, Cities, and Transportation*, p. 61–70 (2019).
- [15] A. C. Cosma and R. Simha: Using the contrast within a single face heat map to assess personal thermal comfort, *Building and Environment*, Vol. 160 (2019).
- [16] A. Ghahramani, G. Castro, S. A. Karvigh and B. Becerik-Gerber: Towards unsupervised learning of thermal comfort using infrared thermography, *Applied Energy*, Vol. 211, pp. 41 – 49 (2018).
- [17] G. S. Brager and R. J. de Dear: Thermal adaptation in the built environment: a literature review, *Energy and Buildings*, Vol. 27, No. 1, pp. 83 – 96 (1998).
- [18] 田辺新一, 堤 仁美, 鈴木孝佳: オフィス空間における湿度が熱的快適性に与える影響に関する研究: 第 1 報-空気温度・相対湿度の組合せによる温冷感の違い, *空気調和・衛生工学会論文集*, Vol. 31, No. 109, pp. 1–9 (2006).
- [19] Mitchell, D. and Wyndham, C. H.: Comparison of weighting formulas for calculating mean skin temperature, *Journal of Applied Physiology*, Vol. 26, No. 5, pp. 616–622 (1969).
- [20] S. Takada, S. Matsumoto and T. Matsushita: Prediction of whole-body thermal sensation in the non-steady state based on skin temperature, *Building and Environment*, Vol. 68, pp. 123 – 133 (2013).
- [21] S. Takada, H. Kobayashi and T. Matsushita: Thermal model of human body fitted with individual characteristics of body temperature regulation, *Building and Environment*, Vol. 44, No. 3, pp. 463 – 470 (2009).
- [22] K. Nkurikiyeyezu, K. Shoji, A. Yokokubo and G. Lopez: Thermal Comfort and Stress Recognition in Office Environment, *Proceedings of the 12th International Conference on Health Informatics* (2019).
- [23] J. T. Cacioppo, L. G. Tassinary and G. Berntson: *Handbook of Psychophysiology*, Cambridge University Press, 3 edition (2007).
- [24] N. Gerrett, B. Redortier, T. Voelcker and G. Havenith: A comparison of galvanic skin conductance and skin wettedness as indicators of thermal discomfort during moderate and high metabolic rates, *Journal of Thermal Biology*, Vol. 38, p. 530–538 (2013).
- [25] Y. P. Sun, N. Zhu, Z. Tian, N. Li and J. Liu: Thermal Discomfort Evaluation in Hot Environment, *Frontiers of Green Building, Materials and Civil Engineering II*, Applied Mechanics and Materials, Vol. 193, pp. 1320–1323 (2012).
- [26] A. Ugursal and C. Culp: Gender Differences of Thermal Comfort Perception Under Transient Environmental and Metabolic Conditions, Vol. 119, pp. 52–62 (2013).
- [27] M. H. Hasan, F. Alsaleem and M. Rafaie: Sensitivity study for the PMV thermal comfort model and the use of wearable devices biometric data for metabolic rate estimation, *Building and Environment*, Vol. 110, pp. 173 – 183 (2016).
- [28] W.R. Tan, C.S. Chan, P. Yogarajah and J. Condell: A Fusion Approach for Efficient Human Skin Detection, *IEEE Transactions on Industrial Informatics*, Vol. 8, No. 1, pp. 138–147 (2012).

- [29] OpenCV: Template Matching — OpenCV 2.4.13.7 documentation, [https://docs.opencv.org/2.4/doc/tutorials/imgproc/histograms/template\\_matching/template\\_matching.html](https://docs.opencv.org/2.4/doc/tutorials/imgproc/histograms/template_matching/template_matching.html) (Accessed on May 18, 2020).
- [30] H. Yoshikawa, A. Uchiyama and T. Higashino: Thermal-Wrist: Smartphone Thermal Camera Correction Using a Wristband Sensor, *Sensors*, Vol. 19, p. 3826.
- [31] Empatica: Real-time physiological signals — E4 EDA/GSR sensor, <https://www.empatica.com/en-int/research/e4/> (Accessed on May 18, 2020).
- [32] FLIR: FLIR T540, <https://www.flir.com/products/t540/> (Accessed on May 18, 2020).
- [33] P. Branco, L. Torgo and R. P. Ribeiro: SMOGN: a Pre-processing Approach for Imbalanced Regression, *Proceedings of 1st International Workshop on Learning with Imbalanced Domains: Theory and Applications* (2017).
- [34] N. V. Chawla, K. W. Bowyer, L. O. Hall and W. P. Kegelmeyer: SMOTE: Synthetic Minority Over-sampling Technique, *Journal of Artificial Intelligence Research*, Vol. 16, p. 321–357 (2002).
- [35] L. Torgo, R. Ribeiro, B. Pfahringer and P. Branco: SMOTE for Regression, *Progress in Artificial Intelligence*, Vol. 8154, pp. 378–389 (2013).
- [36] E. Marín, J. Villar, P. Vergara, Á. Herrero and J. Sedano: Design issues in Time Series dataset balancing algorithms, *Neural Computing and Applications*, pp. 1–18 (2019).
- [37] D.J. Berndt and J. Clifford: Using dynamic time warping to find patterns in time series, *Proceedings of the 3rd international conference on knowledge discovery and data mining*, pp. 359–370 (1994).