

敵対的訓練を用いた サンプリング周波数の相違に頑健な行動認識

長谷川 達人^{1,a)} 木村 洋文¹

概要：スマートフォン等を用いたセンシングによりユーザの身体活動の自動認識を行う行動認識という研究分野がある。日常行動をセンシングする場合、デバイスの種類や所持方法、装着方法、計測アプリケーション等の様々な計測条件がユーザや計測日によって異なる事が多い。センサ値から行動を予測するモデルは機械学習で実現されることが多く、計測環境が不統一なデータは機械学習の予測精度を低下させる可能性がある。本研究では、計測環境の中でもサンプリング周波数の相違に頑健な行動認識手法を提案する。提案手法は通常の行動認識モデルに対して敵対的訓練を適用し、サンプリング周波数を特定できなくする特徴表現の獲得を実現している。基本行動認識の HASC データセットを用いて、サンプリング周波数が混在するデータが計測された環境をシミュレートし評価実験を行った。その結果、従来手法では推定精度が低下すること、提案手法ではそれを改善できることを明らかにした。

Human Activity Recognition Robust to Difference in Sampling Frequency via Adversarial Training

Tatsuhito Hasegawa^{1,a)} Hirofumi Kimura¹

1. はじめに

スマートデバイスや IoT 機器が普及した現在、周囲の環境や人間の行動などをコンピュータに認識させるコンテキストウェアネスに関する研究が盛んに行われている。中でも、スマートフォン等に搭載されているセンサを用いて、ユーザの身体活動の自動認識を行う行動認識は多くの研究がなされている [1], [2], [3], [4]。行動認識が実現できることで、ライフログや、行動に応じたスマートフォンの機能変更、大規模なユーザデータを集めれば、マーケティングや集団行動の解析など、様々な分野への応用が可能となる。

行動認識は、設置型のカメラを用いて画像ベースに行う手法もあるが、本研究では、ユーザが常日頃から持ち歩く機器で計測したセンサデータを用いた行動認識に焦点を当てる。設置型と比べ、時間や場所を問わずデータが取得できる点や、特定のユーザに特化した情報を獲得しやすいというメリットがある。各ユーザが独自にデバイスを所持し

なければならない手間がデメリットだが、近年急激に普及したスマートフォンやスマートウォッチを利用することで回避できる。しかし、デバイスの種類、所持方法、装着方法、計測アプリケーション等の様々な計測条件が、ユーザによって、計測日によって異なるという問題点が残る。

センサデータを機械学習で自動分類する手法が一般的な行動認識の原理である [5], [6], [7], [8]。一方、機械学習では一貫性のないデータを用いてモデルを訓練すると推定精度が低下する恐れがあるため、計測環境は統一されていることが望ましい。深層学習では訓練時に大量のデータが必要となるが、計測環境を統一しつつ大量のデータを収集することは容易ではない。すなわち、一貫性の無いデータに対しても高い認識精度を達成できる手法が望まれる。

以上を踏まえ、本研究ではセンサを用いた行動認識において、様々な計測環境に対して頑健な行動認識手法を開発することを目的とする。本稿では特に、サンプリング周波数に焦点をあてる。サンプリング周波数はデバイスの種類や計測アプリケーションによって変動し行動認識精度に影響を与える要因の一つである。例えば Android スマート

¹ 福井大学大学院工学研究科
Graduate School of Engineering, University of Fukui
^{a)} t-hase@u-fukui.ac.jp

フォンの場合、API^{*1}でサンプリング間隔を変更することができる。機種やスペックによってもサンプリング間隔が多少変動する。ウェアラブルデバイスを併用する場合なども変動する。そこで、本研究ではサンプリング周波数の相違に対して頑健な行動認識手法を開発する。深層学習による敵対的訓練を応用することで、様々なサンプリング周波数で計測されたセンサデータが混在する環境（以降、SF 混在環境とする）における、行動認識精度の向上を実現する。

2. 関連研究

2.1 従来の行動認識研究とサンプリング周波数

1章で述べた行動認識研究でも、サンプリング周波数について全く議論していないものが多い [1], [3], [4], [5], [6]。サンプリング周波数に関する記述がある研究 [2], [7] でも一定のサンプリング周波数で計測された、統一のとれた計測データを用いている。Li らの研究 [9] では、センサベースの行動認識のベンチマークデータセットを複数用いて、表現学習による行動認識手法を複数比較検証している。使用されたデータセットは OPPOTUNITY [10] と UniMiB-SHAR (University of Milano Bicocca Smartphone-based HAR) [11] であり、それぞれデータセット内で統一のサンプリング周波数 (30Hz, 50Hz) で計測されたデータを用いている。

サンプリング周波数が混在するものとしては、基本行動認識のベンチマークデータセット HASC [12] がある。主に iPhone3Gs 等のスマートフォンで計測されているが、センサデバイス WAA-001^{*2}等の幅広い機器でも計測されており、サンプリング周波数は 25Hz~100Hz 等様々な計測条件で記録されている。我々の先行研究 [13] では、HASC データセットに対して複数の CNN モデルの比較検証を行っているが、サンプリング周波数は 100Hz のデータに限定して評価している。Wang のサーベイ [8] より、サンプリング周波数が異なる環境で計測されたデータセットが 2 つ (ActiveMiles [14], Heterogeneous [15]) 紹介されている。Ravi らの研究 [14] では SF 混在環境を意識してデータ収集を行い ActiveMiles データセットとして公開しているが、SF 混在環境を改善する工夫等は実施していない。

サンプリング周波数の相違に焦点を当てた研究としては、Heterogeneous データセットを作成した Allan らの研究 [15] がある。彼らはデバイスごとにセンサの特性が異なることを実験的に示した上で、様々なデバイスで日常行動のセンシングを行ったデータセットを公開している。また、SF 混在環境による悪影響を指摘し、機種ごとにクラスタリングを行った上で、クラスタ毎に分類機を学習させる手法を提案している。本研究と同様に SF 混在環境に着目し

た研究であるが、事前に多くのデバイスのセンサ特性を計測した上でクラスタリングを行う手法であり、計測時の情報のみを用いる本研究とは対象としている条件が異なる。

中島ら [16] はサンプリング周波数を意図的に制御することで、行動認識の省電力化を図る手法を提案している。サンプリング周波数を低下させ、それを補間する手法を開発し、行動認識精度の低下を抑制しつつ省電力化を実現している。低サンプリングレートのデータを補間するという点では、本研究に類する部分はあるが、この研究は SF 混在環境は対象としていないことから立ち位置が異なる。また、本研究の提案手法はアップサンプリングにより一度サンプリング周波数を揃える処理を内包しており、その処理を中島らの手法に置き換えることも可能である。すなわち、提案手法は様々な補間手法と共存可能である。

2.2 敵対的訓練

本研究では、深層学習の敵対的訓練を応用し、サンプリング周波数の相違に頑健な行動認識モデルを提案する。ここで、敵対的訓練の関連研究について述べる。

敵対的訓練を用いた代表的な研究として Goodfellow らの提案した Generative Adversarial Network (GAN) [17] がある。GAN では、ノイズから画像を生成する Generator と、画像から本物か自動生成したものかを弁別する Discriminator を敵対させて訓練を行うことで、Generator が Discriminator を騙すような本物に近い画像を生成できるように、モデルを訓練する。

敵対的訓練をドメイン適応の文脈で応用した、DANN (Domain-Adversarial training of Neural Networks) [18] や ADDA (Adversarial Discriminative Domain Adaptation) [19] が提案されている。ラベルありのソースドメインデータセットを用いてラベルなしのターゲットドメインデータセットの推定を行うドメイン適応問題を対象としている。基本原理は、ソースドメインとターゲットドメインそれぞれのデータを潜在空間に写像するネットワークを訓練し、このときの特徴表現がどちらのドメインからきたものかを弁別する Discriminator を敵対させる手法である。

行動認識の分野に敵対的訓練を応用した事例としては、岩澤らの研究 [20] がある。この研究では行動認識時にユーザを特定するプライバシー情報を含む可能性を指摘し、行動認識精度を低下させずに、センサデータから個人を特定する特徴を取り除くように表現学習を行うモデルである。これは行動認識精度を向上させるためでなく、個人を特定できないような特徴表現を獲得することを目的としている。

2.3 本研究の貢献

以上を踏まえ、以下の 4 点が本研究の主要な貢献である。
SF 混在環境の影響調査 従来研究では、独自計測のデータセットを用いた場合でも、ベンチマークデータセッ

^{*1} Android developers SensorManager: <https://developer.android.com/reference/android/hardware/SensorManager>

^{*2} ATR-Promotions Inc. WAA-001: <https://www.atr-p.com/support/support-sensor01.html>

トを用いた場合でも、実験内でサンプリング周波数を統一して研究が行われていた．それに対して本研究では、SF 混在環境が行動認識精度に与える影響を実験により明らかにした．

敵対的訓練手法の提案 深層学習を用いた行動認識の識別器に対して、サンプリング周波数の弁別器を敵対させる行動認識手法を提案し、定式化を行った上で実装した．深層学習を用いた行動認識モデルに SF 混在環境のデータセットを入力した際、モデルの表現力の高さからサンプリング周波数ごとに特徴表現を獲得する可能性がある．そこで、あえてサンプリング周波数が弁別できないような特徴表現を獲得させることで、SF 混在環境における頑健性を高められると考え、本手法の着想に至った．

有効性検証実験 複数のベースラインモデルと提案手法を実装し、SF 混在環境における行動認識精度を比較検証した．その結果、提案手法が推定精度を向上させることを明らかにした．最終的に、ダウンサンプリングしたデータを併用した提案手法で最高精度を達成した．

計測条件の偏りによる影響 サンプリング周波数毎にデータ数の偏り方が異なるケースについても検証を行い、どの条件下においても提案手法が有効に働くこと、及びその偏りごとの特徴を明らかにした．

3. 提案手法

3.1 モデル構造

Li らの研究 [9] のように、従来の研究で採用されている深層学習を用いた行動認識モデルは、入力データをサンプルにネットワークに通し、行動を分類するモデルである．ネットワークは Multi Layer Perceptron (MLP) ベースのもの、Convolutional Neural Network (CNN) ベースのもの、Recurrent Neural Network (RNN) ベースのもの等々だが、本稿では CNN ベースで議論を行う．前述の通り関連研究ではこのモデルを特定のサンプリング周波数に限定して訓練を行っていた．従って、SF 混在環境にサンプルに応用する場合、図 1 のようにサンプリング周波数

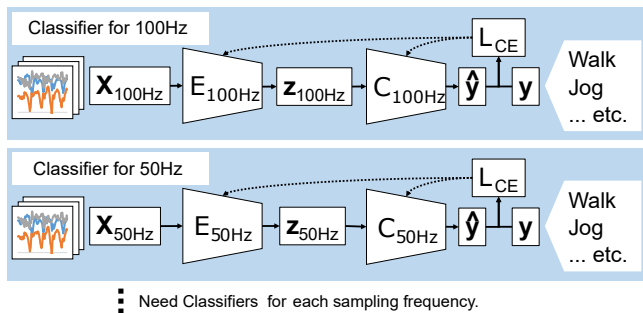


図 1 従来手法：CNN を用いた一般的な行動認識

Fig. 1 Conventional method: common method of human activity recognition using CNN.

ごとにモデルを訓練することになる．ここで、 $X_{100\text{Hz}}$ はサンプリング周波数 100Hz で計測されたセンサデータであり、ネットワークへの入力の意味する． $E_{100\text{Hz}}$ は同 100Hz に訓練される特徴抽出器、 $z_{100\text{Hz}}$ は $E_{100\text{Hz}}$ から出力される特徴マップ、 $C_{100\text{Hz}}$ は行動を分類する分類器、 \hat{y} は分類器の予測結果である．予測結果 \hat{y} と真の行動ラベル y から、クロスエントロピー誤差 L_{CE} を算出し、ネットワークの損失関数としている．従来手法は、サンプリング周波数ごとにモデルを訓練、管理しなければならない点がデメリットとなる．また、サンプリング周波数ごとにモデルを訓練することから訓練データの量が限定的となり、深層学習モデルを訓練しきれない可能性もある．

これに対し、提案手法は以下の 3 点で従来手法と異なる．

- SF 混在環境において全てのデータを同一のモデルで訓練する点
- 行動ラベルだけでなくサンプリング周波数ラベルを併用する点
- サンプリング周波数ラベルは敵対的に訓練に利用する点

以上を踏まえた、提案手法のモデル構造を図 2 に示す．特徴抽出器 E は全てのサンプリング周波数の計測データを一手に入力として受け入れる．この時、入力長を統一するため、 $X_{50\text{Hz}}$ 等のデータは全て 100Hz になるように線形補間を用いてアップサンプリング処理を行っている．すなわち、入力データの時間長、サンプル長は前処理として揃えている．次に、図 2 の上部では従来手法と同様に行動認識を行い、 L_{CE} を最小化するように E と C を訓練する．図 2 の下部では、 z を D にも同時に入力し、 z からサンプリング周波数 \hat{f} を予測する．これはドメイン適応手法 DANN[18] におけるドメイン検出部と同様の働きをする．本モデルでは入力長は線形補間により統一されているが、 $X_{100\text{Hz}}$ と線形補間済みの $X_{25\text{Hz}}$ では波形の滑らかさに差がある． D はこの差を検出することでサンプリング周波数を推定する．予測結果 \hat{f} と真のサンプリング周波数 f から、Discriminator 誤差 L_D を算出し、ネットワークの損失関数としている．本提案手法のメリットは、サンプリン

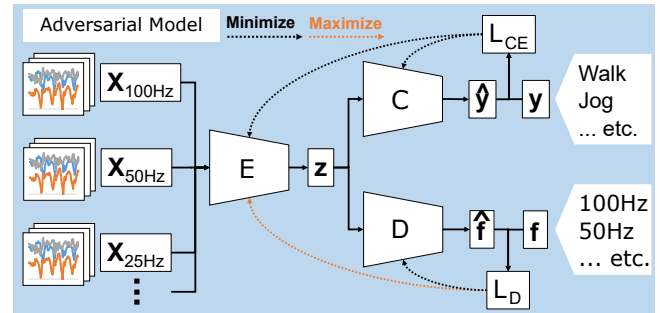


図 2 提案手法：サンプリング周波数に頑健な行動認識

Fig. 2 Proposed method: human activity recognition robust to the difference of sampling frequency.

グ周波数ごとに分割せず唯一のモデルとして訓練ができる点、サンプリング周波数が混在するデータ全てを利用することによる精度向上が見込める点、そして敵対的訓練によりサンプリング周波数の相違に頑健な特徴表現が獲得できる点である。

3.2 定式化

L_{CE} は従来手法でも用いられている、一般的なニューラルネットワークの損失関数であり、下式 (1) で定義される。

$$L_{CE} = -\frac{1}{N} \sum_{n=1}^N \sum_{m=1}^M \{y_{nm} \log C(E(x_n))\} \quad (1)$$

ここで、 N はミニバッチサイズ、 M は行動ラベルのカテゴリ数、 x_n は入力 $X_{100\text{Hz}}$ のミニバッチのうち n 番目の入力系列、 y_{nm} は同 n 番目の出力を one-hot 表現した際の m 番目の値 $\{0, 1\}$ である。 C 及び E は従来手法であれば各周波数に対応したものである必要がある (例: $C_{100\text{Hz}}$)。

L_D はサンプリング周波数を弁別する Discriminator から得られる損失関数であり、本研究ではこれを下式 (2) で定義する。

$$L_D = -\frac{1}{N} \sum_{n=1}^N \sum_{k=1}^K \{f_{nk} \log D(E(x_n))\} \quad (2)$$

ここで、 K はサンプリング周波数の種類数である。すなわち L_D はサンプリング周波数を分類する D のクロスエントロピー誤差である。DANN[18] では、ソースとターゲットドメインを弁別するためバイナリクロスエントロピー誤差が採用されていた。一方、本研究ではいくつかの限定された種類のサンプリング周波数が混在する環境を想定し、これをカテゴリ分類問題として取り扱うこととした。なお、今後の拡張として、これを Mean Squared Error 等に置き換えることでサンプリング周波数を限定しない手法も実現できると考えている。

以上を踏まえ、提案手法のネットワーク全体の損失関数 L を下式 (3) で定義する。

$$L = L_{CE} - \lambda L_D \quad (3)$$

岩澤らの研究 [20] では、 L_D をカテゴリ分類問題として取り扱うことでバイナリ分類問題よりも D の認識能力が低下し、 C と D の敵対のバランスを取ることが難しくなることを指摘している。これに対し、岩澤らは λ を徐々に大きくするアニーリングを行っている。一方、本研究では予備実験的に試した結果、この現象が発生しなかったことから $\lambda = 1$ としている。

3.3 最適化

提案手法は、特徴抽出器 E 、行動分類器 C 、サンプリング周波数弁別器 D の 3 つのモデルで構成される。それぞ

れのネットワークのパラメータを θ_E , θ_C , θ_D とすると、探索対象の各パラメータ $\hat{\theta}_E$, $\hat{\theta}_C$, $\hat{\theta}_D$ は下式 (4, 5) で算出される。

$$(\hat{\theta}_E, \hat{\theta}_C) = \underset{\theta_E, \theta_C}{\operatorname{argmin}} L(\theta_E, \theta_C, \hat{\theta}_D) \quad (4)$$

$$\hat{\theta}_D = \underset{\theta_D}{\operatorname{argmax}} L(\hat{\theta}_E, \hat{\theta}_C, \theta_D) \quad (5)$$

本研究では、上記の最小化、最大化問題を交互最適化により実装する。式 (4) では、 θ_D を固定した状態で算出された L を最小化するように θ_E , θ_C を探索する。これは、 L_{CE} の最小化と、 L_D の最大化を行うようなパラメータを探索しており、行動認識精度を上げるように E , C を訓練し、サンプリング周波数の弁別精度を下げるように E を訓練することと同義である。式 (5) では、同様に θ_E , θ_C を固定した状態で算出された L を最大化するように θ_D を探索する。この時、パラメータが固定されているため L_{CE} は変動しないことから、 L の最大化は L_D の最小化を意味している。したがって、サンプリング周波数の弁別精度を上げるように D を訓練することと同義である。ミニバッチ単位でこれらを交互に最適化する。

4. 実験環境

4.1 データセット

スマートフォンの加速度センサを用いて人間の基本行動認識を行う HASC データセット [12] を用いる。HASC は人間行動理解のための装着型センサによる大規模データベースの構築^{*3}を目的とした非営利任意団体が提供する行動認識データセットである。基本行動 6 種類 (停止, 歩行, 走行, スキップ, 階段上り, 階段下り) のラベルがついた加速度, ジャイロ等のセンサデータがコーパスとして提供されている。

2011 から 2013 年までのコーパスの BasicActivity よりサンプリング周波数が 100Hz のデータを抽出し、加速度センサの生データのみを用いることとした。前処理として、各計測ファイルから前後 5 秒を除去し、フレームサイズ 256 サンプル、ストライド 256 サンプルで時系列分割を行う。計測開始から端末の格納動作等の影響を取り除くため前後 5 秒でトリミングしている。計測機種や性別等のメタ情報は用いない。トリミング後に 1 フレーム以上データが取得できた 176 名のデータを採用した。

4.2 データセットの分割

モデルの訓練及び検証に使用するデータセットの分割方法について説明する。行動認識研究では、評価対象者自身のデータを訓練時に使用することで推定精度が向上することが知られている。したがって本研究では、訓練と検証用のデータセットを人単位で分ける Hold-out 法により分割

^{*3} HASC: <http://hasc.jp/>

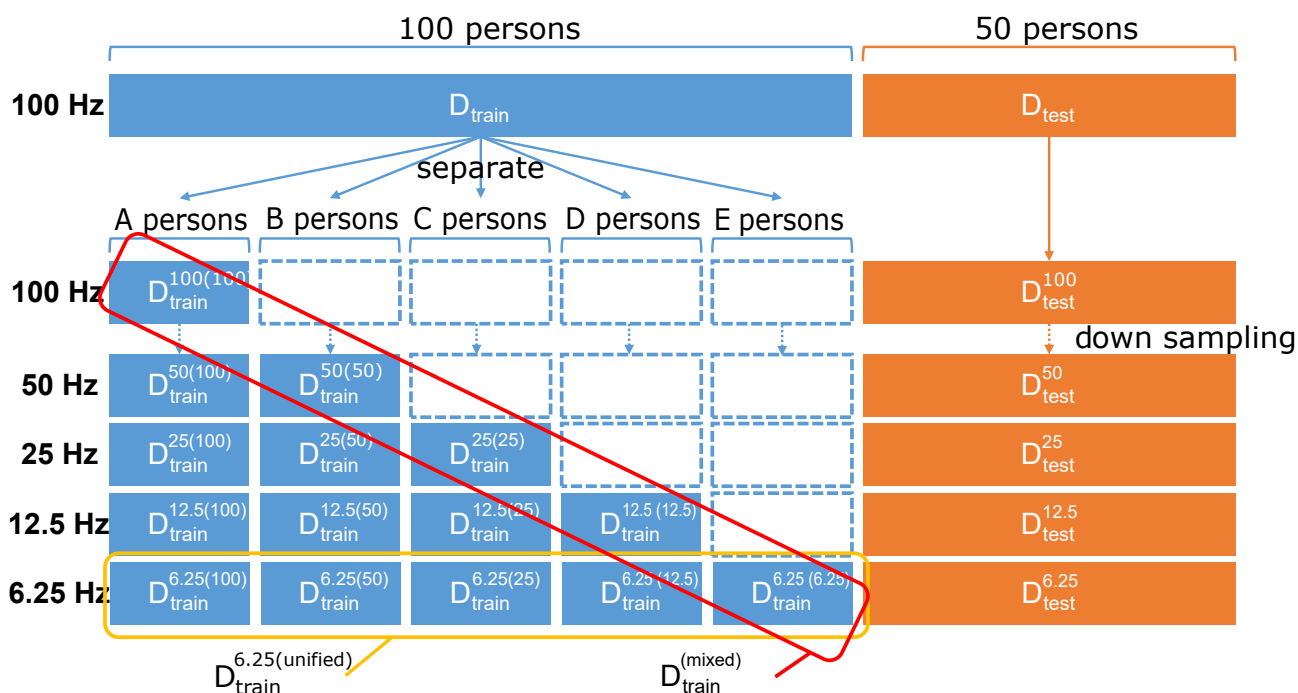


図 3 データセットの分割方法
Fig. 3 How to separate the dataset.

する．分割の概要図を図 3 に示す．前節で述べた 176 名のデータセットから，ランダムに 100 名を抽出し訓練用データセット D_{train} とし，同様に別途ランダム抽出した 50 名を検証用データセット D_{test} とする．

D_{test} は評価対象が様々なサンプリング周波数であることを考慮し，ダウンサンプリングによって 100Hz のもの (D_{test}^{100}) から 50Hz のもの (D_{test}^{50})，25Hz，12.5Hz，6.25Hz と複数種類準備し，それぞれで精度検証を行う．サンプリング周波数間で同一の被験者 50 名を用いる．具体的なダウンサンプリング手順については次節で述べる．

訓練用データセットは D_{train} からダウンサンプリングにより SF 混在環境を疑似的に再現する．はじめに， D_{train} を特定の人数で分割する（図の A，B，C，D，E 名）．次に，A 名のデータはサンプリング周波数 100Hz で計測されたものとし $D_{train}^{100(100)}$ とする．B 名のデータはサンプリング周波数 50Hz で計測されたものとし $D_{train}^{50(50)}$ とする．この時，B 名の 100Hz データは D_{train} 自体には含まれているが，ダウンサンプリング後の $D_{train}^{50(50)}$ に変換するためだけに使用しており，100Hz の状態では実験に使用しない．同様に C 名は 25Hz で，D 名は 12.5Hz で，E 名は 6.25Hz で計測されたデータとし，それぞれ $D_{train}^{25(25)}$ ， $D_{train}^{12.5(12.5)}$ ， $D_{train}^{6.25(6.25)}$ とした．これらを総称して，SF 混在環境における訓練用データセット $D_{train}^{(mixed)}$ とした．

$D_{train}^{(mixed)}$ は更にダウンサンプリングを行うことにより，自身より低サンプリングレートのデータセットを疑似的に再現することが可能となる．例えば， $D_{train}^{100(100)}$ はダウンサンプリングにより $D_{train}^{50(100)}$ や $D_{train}^{25(100)}$ 等を再現できる．

これを全パターン実施した内，6.25Hz に全て統一したデータセットを $D_{train}^{6.25(unified)}$ とする．

4.3 ダウンサンプリング

エリアジング誤差を防止するため，間引きによるダウンサンプリングを行う前に，ローパスフィルタ (LPF) を適用する．時系列波形データはサンプリング定理に基づき，計測したい信号に含まれる最高周波数の 2 倍以上の周波数でサンプリングを行う必要がある．したがって，100Hz で計測されたデータを 50Hz にダウンサンプリングする際には，信号に含まれる情報を 50Hz/2 = 25Hz 以下にする必要がある．これを実現するために LPF を用いて信号から高周波成分を除去する．例えば，100Hz で計測されたセンサデータが図 4 の original のように高周波数情報を含む場合，単純に間引き処理のみを行うと only thinning のようになる．一方，LPF 適用後間引きを行うと thinning with LPF のようになる．




図 4 オリジナルのセンサデータ例と間引きのみを行った例，LPF と間引きを行った例

Fig. 4 A sample of the original sensor data, performed only thinning, and performed thinning after LPF.

更に、本研究ではモデルへの入力長を揃えるために、間引き後のデータを線形補間により同一サンプル数となるように変換している。したがって、図 4 の thinning with LPF は見た目上は変わらないが、モデル入力時にサンプル数 256 となっている。

ダウンサンプリング処理は、実験用データを整形するだけでなく、 $D_{train}^{100(100)}$ から $D_{train}^{50(100)}$ 等を生成する際にも使用する。

4.4 深層学習のモデル構造

提案手法は E , C , D の 3 つのモデルで構成され、各モデル内のアーキテクチャについては本研究の範囲外である。それぞれを最適な構造とすることで精度向上が見込める可能性はあるが、本研究では VGG16 をベースにしたモデルを採用した。CNN のアーキテクチャを比較した先行研究 [13] より、VGG16 は実装が容易ながら行動認識に対して高い推定精度を実現するアーキテクチャであることから採用した。 E は VGG16 の Flatten までとし、 C と D はシンプルに全結合層（ユニット数 1024）に、活性化関数 ReLU、ドロップアウト 0.5 を適用したものとした（図 5）。ただし、 C の出力層は 6 ユニット（行動 6 種類の分類）、 D は 5 ユニット（サンプリング周波数 5 種類の分類）である。

5. 予備実験

5.1 予備実験の目的

これまで SF 混在環境における深層学習モデルの行動認識精度に関する議論が行われていなかったことから、本実験の前に以下の点を検証するための予備実験を行った。

(1) データセット内に複数のサンプリング周波数が混在す

ることが行動認識精度の低下につながるのかを検証する。一般に、機械学習では不統一な環境で計測されたデータは統一されたデータに比べて推定精度が低下する。これが本課題でも発生するのか、及び、深層学習を用いた際でも発生するのかを検証する。

- (2) 動作検証として、従来手法におけるサンプリング周波数の検出精度と、提案手法における検出精度を比較し、提案手法が適切に学習できていることを確認する。
- (3) 本実験で使用する評価指標や、訓練エポック数の妥当性の検証を行う。

5.2 予備実験設定

4 章で述べた実験環境において、 D_{train} の分割を均等に 20 名ずつ ($A:B:C:D:E = 20:20:20:20:20$) とした。比較に用いるモデルは図 1 で示した従来の一般的な CNN モデル（以降、 M_{org} とする）と、図 2 で示した提案手法の敵対的訓練モデル (M_{adv}) の 2 種類である。従来手法では同一のサンプリング周波数データに限定してモデルを訓練することが一般的である。本研究では SF 混在環境による影響を調査するため、従来手法同様 $D_{train}^{6.25(6.25)}$ の 20 名のみを訓練に使用するケース ($M_{org}(D_{train}^{6.25(6.25)})$) : **Ref** と呼ぶ、SF 混在環境のデータ 100 名分を訓練に使用するケース ($M_{org}(D_{train}^{mixed})$) : **Mixin** と呼ぶ、検証対象のサンプリング周波数にダウンサンプリングで統一した 100 名分を訓練に使用するケース ($M_{org}(D_{train}^{6.25(unified)})$) : **Ideal** と呼ぶで比較を行う。これを **Ideal** と呼ぶのは、100 名分全てのデータを同一サンプリング周波数 6.25Hz で計測できた理想環境を擬似的に再現しているためである。実運用でも実現可能ではあるが、最も低いサンプリング周波数 6.25Hz を推定するときだけであり、100Hz を推定するときにはこの手法は実現できない。そのため、理想環境として 6.25Hz のみで評価する。同様に $M_{adv}(D_{train}^{mixed})$ を **Adv** と呼ぶ。

なお、 M_{org} のアーキテクチャは M_{adv} と同等であり、 E , C は同一で、 D のみが存在しないものである。本研究では、Adam[21] を学習率 0.0001, $\beta_1 = 0.9$, $\beta_2 = 0.999$ で用いて最適化を実施し、全モデル 150 エポック訓練を行う。なお、訓練時に 10 エポックごとに検証用データに対する予測精度を計測し記録している。

5.3 予備実験結果

予備実験におけるエポック毎の推定精度変化を示した図 6 を用いて、予備実験の目的 (1) を考察する。train_act は訓練用データの行動認識精度、test_act は検証用データの行動認識精度、train_freq は訓練用データのサンプリング周波数弁別精度を示している。まず、**Ref** と **Mixin** の行動認識の最高検証精度に着目すると、それぞれ 66.4%, 77.0% となり、同一サンプリング周波数 20 名で訓練するよりは、SF 混在環境でも 100 名で訓練するほうが精度が高

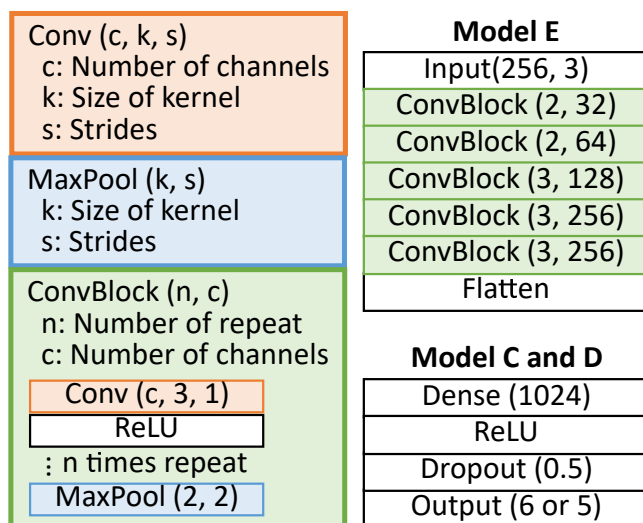


図 5 実験で使った VGG16 ベースのモデル構造

Fig. 5 Model architecture based on VGG16 that we used in experiments.




図 6 予備実験における各モデルの訓練時と検証時の推定精度変化

Fig. 6 Changes in estimation accuracy during training and validation of each model in preliminary experiments.

くなることがわかった。これは、訓練データが少ないことでモデルが汎用的な特徴表現を獲得しきれていないことが原因と考えられる。一方、理想環境 **Ideal** の最高検証精度は 83.9%であり、SF 混在環境の **Mixin** と比べて高精度であることから、深層学習モデルでも SF 混在環境により精度低下が起こることを明らかにした。なお、**Adv** の最高検証精度は 77.0%となり、**Mixin** と同等で **Ideal** より低い結果であったが、**Adv** の行動認識精度については次章の本実験で詳細に議論する。

次に、図 6 のサンプリング周波数弁別精度 (train_freq) に着目し、予備実験の目的 (2) を考察する。**Mixin** では通常サンプリング周波数弁別を行わないが、図 2 から L_D の最大化による E の訓練を行わないようにすることで、 E と C は通常の **Mixin** のまま、 D でサンプリング周波数弁別性能を検証することが可能となる。**Mixin** の train_freq を見ると訓練が進むにつれてサンプリング周波数の弁別精度が大幅に向上し、最大で 96.1%となっていることが確認できる。これは行動認識モデルを訓練するに当たり、サンプリング周波数ごとに異なる傾向を持つ特徴マップ z が抽出されていることを意味する。一方、**Adv** に着目すると、弁別精度は 2 割程度で安定している。今回はサンプリング周波数 5 種類を対象としているため精度 2 割とはランダムに予測を行った場合と同じ精度を意味する。したがって、 L_D の最大化によってサンプリング周波数の弁別精度を抑制できており、サンプリング周波数の敵対的訓練が適切に実現できている事が確認できた。

最後に、図 6 の収束具合に着目し、予備実験の目的 (3) を考察する。まず、 M_{org} の 3 種類はどれも行動認識精度が 50 エポック付近で頭打ちとなっており、150 エポックの訓練は十分である事がわかる。一方、 M_{adv} は 100 エポック付近まで学習がつついており、今後もやや精度が向上する可能性はあるものの、概ね 150 エポックで収束していることが確認できた。したがって以降の実験は 150 エポックで実施する。また、検証用データの推定精度は、最終エポックの精度で議論することが多いが、本研究では最大となっ

た検証用精度で議論を行うこととする。図 6 を見ると訓練精度が大幅に上に振れることは起こらず基本安定していることから、この指標が評価を恣意的に歪めることはない。一方、 M_{adv} を用いた場合、80 エポックや 95 エポック付近で計測されるように急激に訓練精度が低下する減少が起こりうる。最終エポックで評価すると、偶然この現象が最終エポック付近で発生した際に精度を大幅に下げることになり、一律的な比較が困難となる。したがって、本研究では最大となった検証用精度で議論を行うこととした。なお、最終エポックでの精度でも確認を行っているが、概ね同じ結果であり、以降の考察を覆すことはなかった。

6. 本実験

6.1 実験環境

予備実験の実験環境から以下の 4 点の変更を行った。

- 実環境では計測データが偏ることを踏まえ、偏りのある状態を含む複数パターンで D_{train} を分割する。
- D_{train} , D_{test} のランダム抽出、及び、その先の D_{train} の分割は選択される人によって検証精度が異なる。したがって、人を変えて全てのパターンを 20 試行ずつ実施し、20 試行の平均精度で比較検討を行う。
- 評価用データはサンプリング周波数 5 種全て使用する。
- 考慮できうる複数のベースラインを定義し比較することで提案手法の有効性を示す。

D_{train} の分割パターンは、低サンプリング周波数が充実しているケースとして Low₁ (A:B:C:D:E = 5:5:5:5:80), Low₂ (10:10:10:10:60) の 2 パターン、均一なケースとして Even (20:20:20:20:20), 高サンプリング周波数が充実しているケースとして High₁ (60:10:10:10:10), High₂ (80:5:5:5:5) の 2 パターンで、計 5 パターン検証する。

6.2 ベースラインと提案手法

ベースラインとして訓練用データの扱い方を工夫し以下の 5 種類を定義する。各名称のカッコ内の数字は、訓練が必要なモデル数を意味している。

表 1 20 試行を行った際の各手法の平均推定精度 [%]

Table 1 Average of estimation accuracy for each method over 20 trials [%].

	Low ₁ (5:5:5:5:80)					Low ₂ (10:10:10:10:60)					Even (20:20:20:20:20)					High ₁ (60:10:10:10:10)					High ₂ (80:5:5:5:5)				
	100Hz	50Hz	25Hz	12Hz	6Hz	100Hz	50Hz	25Hz	12Hz	6Hz	100Hz	50Hz	25Hz	12Hz	6Hz	100Hz	50Hz	25Hz	12Hz	6Hz	100Hz	50Hz	25Hz	12Hz	6Hz
Ref	55.2	56.3	54.3	56.8	81.7	64.9	65.6	65.8	65.9	80.3	74.9	75.5	73.6	75.4	68.9	84.4	64.5	67.4	66.8	59.2	86.0	53.5	53.8	55.9	48.0
Mixin	80.6	81.1	81.9	82.9	82.0	83.9	84.1	84.5	84.7	81.4	85.6	85.9	85.9	85.1	75.9	86.8	86.7	86.2	84.3	71.5	87.0	86.8	86.3	83.7	65.8
DS-Mixin	80.5	81.3	82.2	82.9	83.1	83.9	84.1	84.6	84.9	83.7	85.5	85.8	86.1	<u>86.3</u>	83.0	86.6	86.5	86.6	<u>86.5</u>	83.0	86.8	87.1	87.0	<u>86.9</u>	83.0
F-Mixin	81.2	81.6	82.4	83.5	82.5	83.6	83.9	84.3	84.9	82.5	86.2	86.4	<u>86.5</u>	<u>86.3</u>	<u>82.7</u>	86.9	86.9	86.9	<u>86.5</u>	<u>82.8</u>	87.4	87.5	<u>87.4</u>	<u>86.8</u>	82.7
Multi	76.3	77.1	77.8	77.5	80.4	78.7	79.4	79.6	78.9	77.3	83.6	84.0	84.1	82.0	72.1	85.0	84.9	84.0	80.5	65.9	85.4	85.3	84.1	79.5	61.0
Adv	<u>82.2</u>	<u>82.5</u>	<u>83.0</u>	<u>83.7</u>	82.4	<u>85.0</u>	<u>85.3</u>	<u>85.4</u>	<u>85.4</u>	81.9	<u>86.3</u>	<u>86.5</u>	86.4	85.4	76.0	<u>87.6</u>	<u>87.5</u>	<u>87.0</u>	85.1	72.2	<u>87.7</u>	<u>87.6</u>	86.8	84.5	67.8
F-Adv	82.5	82.8	83.4	84.2	<u>83.0</u>	85.6	85.8	86.0	86.1	<u>83.5</u>	86.8	86.9	87.0	86.6	82.5	88.2	88.2	88.0	87.3	83.0	88.3	88.4	88.2	87.6	<u>82.9</u>

Ref (5) 従来手法と同様に、訓練用データ $D_{train}^{(mixed)}$ の内、検証用データのサンプリング周波数と一致するデータのみを使用し M_{org} を訓練する手法である。 D_{test}^{100} を評価する際には $M_{org}(D_{train}^{100(100)})$ を用い、 D_{test}^{50} を評価する際には $M_{org}(D_{train}^{50(50)})$ を用いるというように、5つのモデルを使い分ける手法である。

Mixin (1) 訓練用データ $D_{train}^{(mixed)}$ を用いて M_{org} を訓練する手法である。岩澤ら [22] により、ユーザ適応時に Fine-tuning 等の転移学習手法を用いるよりも、シンプルに適応用データを混在させる Mixin で高精度を達成することが示されていることから、ベースラインとして採用した。

DS-Mixin (5) Down Sampling Mixin を意味する。図 3 で示したように訓練用データはダウンサンプリングによって、低サンプリング周波数側にのみデータを増やすことができる。そこで、予備実験の **Ideal** のように $D_{test}^{6.25}$ を評価する際は $D_{train}^{6.25(unified)}$ を、 $D_{test}^{12.5}$ を評価する際は $D_{train}^{12.5(unified)}$ に $D_{train}^{6.25(6.25)}$ を併せたデータを用いるというように、なるべくサンプリング周波数を統一した 100 名を訓練に用いて、5つのモデルを使い分ける手法である。

F-Mixin (1) Full Mixin を意味する。図 3 で示した全ての訓練データをまとめて Mixin する手法である。シンプルにデータ拡張による精度向上が見込める観点から採用した。

Multi (1) 行動認識とサンプリング周波数弁別を同時に実施するマルチタスク学習を行う手法である。 M_{adv} の L_D 最大化による θ_E の更新を、最小化で行うことで実現できる。サンプリング周波数の学習をモデル内で行う手法のベースラインとして採用した。

これに対して、 M_{adv} を用いた提案手法も、訓練用データの扱い方を工夫し以下の 2 種類定義する。

Adv (1) 与えられた訓練データ $D_{train}^{(mixed)}$ を用いてシンプルに M_{adv} を訓練する手法である。

F-Adv (1) Full Adversarial を意味する。 **F-Mixin** のように図 3 で示した全ての訓練データをまとめて用いて M_{adv} を訓練する手法である。

6.3 本実験結果

20 試行実施した平均推定精度を表 1 に示す。1 行目は D_{train} の分割人数の比率、2 行目は検証対象の D_{test} のサンプリング周波数である。各検証に対して、最大精度を達成できた手法を太字かつ下線で、2 番目に精度が高かった手法を下線で示している。

表 1 より、 D_{train} の分割比率によらず、検証用データが 100Hz から 12.5Hz は **F-Adv** が最高精度、6.25Hz は **DS-Mixin** が最高精度を記録した。また、検証用データが 6.25Hz であっても、 **F-Adv** は **DS-Mixin** とほぼ同等の精度を記録している。2 番目に精度が高かった手法に着目すると、検証用データのサンプリング周波数が高いときは **Adv** が、低いときは **DS-Mixin** や **F-Mixin** が高精度を達成した。考えてみると当然ではあるが、検証用データが 6.25Hz の際にはダウンサンプリングにより 100 名分の訓練データが揃った状態となるため、 **DS-Mixin** が十分な特徴表現を獲得し最高精度を達成できた。一方で、高サンプリング周波数側にデータ拡張を行うことができないため、 **DS-Mixin** や **F-Mixin** は **Mixin** と変わらない推定精度となった。一方、提案手法では低サンプリング周波数にデータが偏っている Low₁ や Low₂ の状況でも高サンプリング周波数の検証精度向上に成功している。特に、Low₂ では 100Hz の訓練用データが 10 名しか揃っていないにもかかわらず、100Hz の検証精度は 85.6% である。これは従来のシンプルな手法 (**Ref**) で 100Hz のデータが 80 名揃っているときの検証精度 86.0% とほぼ同等である。

検証用データの分割比率のごとに平均精度を算出したものを表 2 に示す。検証用データのサンプリング周波数の偏りが一律と仮定すると、全ての分割比率において提案手法の **F-Adv** が最高精度を達成している。提案手法の推定精度は、一般的な従来手法 **Ref** よりも平均約 20% 精度が向上しており、シンプルにサンプリング周波数に適応する **Mixin** よりも平均約 3% 精度が向上している。さらに、ダウンサンプリングによるデータ拡張を行った **F-Mixin** と比較しても平均約 1% 精度が向上している。分割パターン間の特性を見ると、基本的には低サンプリング周波数にデータが偏った際に提案手法が特に有効に働くことが確認できる (**F-Mixin** との比較)。 **Ref** や **Mixin** との比較

表 2 訓練用データの分割パターンごとの平均推定精度の比較 [%]

Table 2 Comparison of the average of estimation accuracy for each separation pattern of training data [%].

	Low ₁	Low ₂	Even	High ₁	High ₂	Avg
Ref	60.9	68.5	73.6	68.5	59.5	66.2
Mixin	81.7	83.7	83.7	83.1	81.9	82.8
F-Mixin	82.2	83.9	<u>85.6</u>	<u>86.0</u>	<u>86.4</u>	<u>84.8</u>
DS-Mixin	82.0	84.2	85.3	85.8	86.2	84.7
Multi	77.8	78.8	81.2	80.1	79.1	79.4
Adv	<u>82.8</u>	<u>84.6</u>	84.1	83.9	82.9	83.6
F-Adv	<u>83.2</u>	<u>85.4</u>	<u>86.0</u>	<u>86.9</u>	<u>87.1</u>	<u>85.7</u>
F-Adv - Ref	22.3	16.9	12.3	18.5	27.6	19.5
F-Adv - Mixin	1.5	1.7	2.3	3.8	5.2	2.9
F-Adv - F-Mixin	1.0	1.6	0.4	0.9	0.7	0.9

では High の方が精度向上が顕著であるが、これは **Ref** や **Mixin** が低サンプリング周波数に対してデータ拡張を行っていないためである。

ここで、**Multi** に着目すると、どれも **Mixin** にすら劣る結果となっている。サンプリング周波数ラベルを弁別する損失関数をモデルに組み込んだことで、マルチタスク学習により精度向上が見込めるかと思われたが、逆に制約となり精度低下につながった。一方で、サンプリング周波数を弁別できなくする制約が、結果として行動認識精度を向上させたことは興味深い結果である。ユーザに対して敵対的訓練を行った岩澤らの研究 [20] では、データセットによって行動認識精度が同程度ないしはやや低下する結果となっている。一方、本研究ではサンプリング周波数の敵対的訓練が行動認識精度を約 3% 向上させる結果となった ([20] に合わせ **F-Adv - Mixin**)。ダウンサンプリングによるデータ拡張の効果も大きいが、サンプリング周波数を弁別させないことでこれに依存しない頑健な特徴表現の獲得に貢献できたと考えられる。

以上を踏まえ、本研究では 7 種のモデル、訓練データの分割パターン 5 種類、各 20 試行の 700 回を超える深層学習モデルの訓練と検証を行った結果、SF 混在環境では提案手法の **F-Adv** を用いることで高精度が実現できることを明らかにした。検証用データがサンプリング周波数 6.25Hz の場合のみ **DS-Mixin** の精度の方が高いが、差は僅かであり、**DS-Mixin** のように複数モデルを訓練しなくて済む観点からも **F-Adv** の方が優れていると結論づける。

6.4 リミテーションと有用性

本研究のリミテーションである 3 点について議論する。
スマホの行動認識 本研究では HASC [12] データセットを用いて実験を行った。そのため、提案手法の有効性は今の所スマホの行動認識の範囲にとどまる。表 1 の Even の **Ref** を見ると、12.5Hz から 6.25Hz 間で推定精度が約 7% と大幅に低下している。HASC の特徴として基本行動認識は特に低周波数成分の特徴が重要で

ある (12.5Hz 程度あれば十分である) ことを意味している。したがって、特に高周波成分が推定に重要となるような行動認識タスクにおいても提案手法が有効に働くかどうかは議論の余地が残る。

ダウンサンプリングによる擬似再現 本研究では各サンプリング周波数のデータセットをダウンサンプリングにより擬似生成して実験を行った。これは実環境における計測値とは異なる可能性があるため、実計測データを用いた場合の効果については議論の余地が残る。

対象サンプリング周波数 本研究では計測対象のサンプリング周波数を 5 種類としたが、実環境ではより多岐にわたる。サンプリング周波数が多岐にわたった場合における効果については議論の余地が残る。

リミテーションを踏まえ、本研究の有用性について議論する。本研究では HASC データセットを用いて提案手法の有効性を示したが、基本行動認識は 12.5Hz 程度のサンプリング周波数でデータが計測されていれば十分であること、及び、HASC データセットの大部分は 100Hz で計測されていることから、有用性に疑問が残るかもしれない。しかし、今後行動認識を実運用することを考えると、スマートフォンのバックグラウンド動作で 100Hz のセンサデータを継続的に計測することは、バッテリーや CPU 消費の観点からも現実的ではない。すなわち、提案手法は今後行動認識を実運用していく際にこそ有用な手法であると考えられる。また、本実験を通じて SF 混在環境でも多くの被験者からデータを計測できることで精度が向上できることを示した。すなわち、単一のサンプリング周波数で少人数からデータを収集するよりは、混在していても多人数からデータを収集し、敵対的訓練を行うことで精度を向上させることを示した。これは今後の行動認識研究の精度向上の一助となると考えている。

7. おわりに

本研究では、センシングによる行動認識を対象に、計測データのサンプリング周波数が混在する環境に頑健な行動認識手法の開発を行った。提案手法は、行動認識を行うモデルと、サンプリング周波数の弁別を行うモデルに分岐しており、それぞれが敵対的に学習を行うことによって、サンプリング周波数に依存しない行動認識の特徴表現の獲得を行うモデルである。基本行動認識の HASC データセットを用いて提案手法の有効性評価を行った結果、敵対的訓練とダウンサンプリングによるデータ拡張を併用した方法で、従来手法と比べ高精度に行動認識が実現できることを明らかにした。今後の課題として、リミテーションに示した 3 点を、別のデータセットを用いた評価実験により検証していく予定である。

謝辞 本研究の一部は立石科学技術振興財団の研究助成 (A) によるものである。ここに謝意を表す。

参考文献

- [1] Kwapisz, J. R., Weiss, G. M. and Moore, S. A.: Activity Recognition Using Cell Phone Accelerometers, *SIGKDD Explor. Newsl.*, Vol. 12, No. 2, pp. 74–82 (online), DOI: 10.1145/1964897.1964918 (2011).
- [2] Xu, C., Pathak, P. H. and Mohapatra, P.: Finger-writing with Smartwatch: A Case for Finger and Hand Gesture Recognition Using Smartwatch, In *Proceedings of the 16th International Workshop on Mobile Computing Systems and Applications*, HotMobile '15, pp. 9–14 (online), DOI: 10.1145/2699343.2699350 (2015).
- [3] Shoaib, M., Bosch, S., Incel, O. D., Scholten, H. and Havinga, P. J. M.: Complex Human Activity Recognition Using Smartphone and Wrist-Worn Motion Sensors, *Sensors*, Vol. 16, No. 4 (online), DOI: 10.3390/s16040426 (2016).
- [4] Voicu, R.-A., Dobre, C., Bajenaru, L. and Ciobanu, R.-I.: Human Physical Activity Recognition Using Smartphone Sensors, *Sensors*, Vol. 19, No. 3 (online), DOI: 10.3390/s19030458 (2019).
- [5] Avci, A., Bosch, S., Marin-Perianu, M., Marin-Perianu, R. and Havinga, P.: Activity Recognition Using Inertial Sensing for Healthcare, Wellbeing and Sports Applications: A Survey, In *Proceedings of the 23th International Conference on Architecture of Computing Systems 2010*, pp. 1–10 (2010).
- [6] Chen, L., Hoey, J., Nugent, C. D., Cook, D. J. and Yu, Z.: Sensor-Based Activity Recognition, *IEEE Transactions on Systems, Man, and Cybernetics, Part C (Applications and Reviews)*, Vol. 42, No. 6, pp. 790–808 (online), DOI: 10.1109/TSMCC.2012.2198883 (2012).
- [7] Lara, O. D. and Labrador, M. A.: A Survey on Human Activity Recognition using Wearable Sensors, *IEEE Communications Surveys & Tutorials*, Vol. 15, No. 3, pp. 1192–1209 (2012).
- [8] Wang, J., Chen, Y., Hao, S., Peng, X. and Hu, L.: Deep learning for sensor-based activity recognition: A survey, *Pattern Recognition Letters*, Vol. 119, No. 1, pp. 3–11 (2019).
- [9] Frédéric Li, Kimiaki Shirahama, M. A. N. L. K. and Grzegorz, M.: Comparison of Feature Learning Methods for Human Activity Recognition Using Wearable Sensors, *Sensors*, Vol. 18, No. 679, pp. 1–22 (2018).
- [10] Chavarriaga, R., Sagha, H., Calatroni, A., Digumarti, S., Gerhard Tröster, J. d. R. M. and Roggen, D.: The Opportunity challenge: A benchmark database for on-body sensor-based activity recognition, *Pattern Recognition Letters*, Vol. 34, No. 15, pp. 2033–2042 (2013).
- [11] Micucci, D., Mobilio, M. and Napolitano, P.: UniMiB SHAR: A Dataset for Human Activity Recognition Using Acceleration Data from Smartphones, *Applied Sciences*, Vol. 7, No. 10 (2017).
- [12] Kawaguchi, N. and et al.: HASC Challenge: Gathering Large Scale Human Activity Corpus for the Real-World Activity Understandings, In *Proceedings of the Augmented Human International Conference (AH'11)* (2011).
- [13] Hasegawa, T. and Koshino, M.: Representation Learning by Convolutional Neural Network for Smartphone Sensor Based Activity Recognition, *Proceedings of the 2019 2nd International Conference on Computational Intelligence and Intelligent Systems*, CIIS 2019, pp. 99–104 (online), DOI: 10.1145/3372422.3372439 (2019).
- [14] Ravi, D., Wong, C., Lo, B. and Yang, G.: Deep learning for human activity recognition: A resource efficient implementation on low-power devices, *2016 IEEE 13th International Conference on Wearable and Implantable Body Sensor Networks (BSN)*, pp. 71–76 (2016).
- [15] Stisen, A., Blunck, H., Bhattacharya, S., Prentow, T. S., Kjærgaard, M. B., Dey, A., Sonne, T. and Jensen, M. M.: Smart Devices Are Different: Assessing and Mitigating Mobile Sensing Heterogeneities for Activity Recognition, *Proceedings of the 13th ACM Conference on Embedded Networked Sensor Systems*, New York, NY, USA, Association for Computing Machinery, pp. 127–140 (online), DOI: 10.1145/2809695.2809718 (2015).
- [16] 中島悠貴, 村尾和哉, 寺田 努, 塚本昌彦: サンプリング制御とデータ補完による行動認識システムの省電力化手法, *情報処理学会論文誌*, Vol. 52, No. 8, pp. 2455–2466 (2011).
- [17] Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., Courville, A. and Bengio, Y.: Generative Adversarial Nets, *Advances in Neural Information Processing Systems 27* (Ghahramani, Z., Welling, M., Cortes, C., Lawrence, N. D. and Weinberger, K. Q., eds.), Curran Associates, Inc., pp. 2672–2680 (online), available from (<http://papers.nips.cc/paper/5423-generative-adversarial-nets.pdf>) (2014).
- [18] Ganin, Y., Ustinova, E., Ajakan, H., Germain, P., Larochelle, H., Laviolette, F., Marchand, M. and Lempitsky, V.: Domain-Adversarial Training of Neural Networks, *The Journal of Machine Learning Research*, Vol. 17, No. 1, pp. 2096–2030 (2016).
- [19] Tzeng, E., Hoffman, J., Saenko, K. and Darrell, T.: Adversarial Discriminative Domain Adaptation, *2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 2962–2971 (2017).
- [20] Iwasawa, Y., Nakayama, K., Yairi, I. and Matsuo, Y.: Privacy Issues Regarding the Application of DNNs to Activity-Recognition using Wearables and Its Countermeasures by Use of Adversarial Training, *Proceedings of the Twenty-Sixth International Joint Conference on Artificial Intelligence, IJCAI-17*, pp. 1930–1936 (online), DOI: 10.24963/ijcai.2017/268 (2017).
- [21] Kingma, D. P. and Ba, J. L.: Adam: a Method for Stochastic Optimization, *International Conference on Learning Representations 2015*, pp. 1–15 (2015).
- [22] 岩澤有祐, 矢入郁子, 松尾 豊: 半教師あり蒸留による深層学習に基づく行動認識モデルのユーザ適応, *人工知能学会論文誌*, Vol. 32, No. 3, pp. A-G82.1–11 (オンライン), DOI: 10.1527/tjsai.A-G82 (2017).