

加速度センサを用いた集団における マイノリティな状況の検出手法

梶原 大暉¹ 村尾 和哉^{1,2}

概要：本研究では、加速度センサを用いて、ダンスや入学試験など同種の動作を行っている集団において、誤った振り付けやカンニングのような大部分の人とは異なるマイノリティな行動をしている人を教師データなしで検出する手法を提案する。提案手法はユーザのスマートフォンやウェアラブルセンサから3軸の加速度データが得られる環境を想定する。まず、センサから3軸加速度を取得し、合成加速度を求める。次に、合成加速度の近似を行い、近似したデータをシンボル列に変換する。そして、シンボル列から一定の長さ以上の部分文字列をモチーフとして抽出し、ユーザごとに Bag of Words (BoW) を作成する。ユーザ間の BoW の類似度を算出し、大部分のユーザいずれとも類似度が低いユーザをマイノリティな行動を行った人として検出する。評価実験では、14人の被験者のうちすべての時間でマイノリティな行動を行った1人は他のいずれの13人とも類似度が低くなり、マイノリティな人を検出できることが分かった。また、一部の時間のみマイノリティな行動をしている場合も、スライディングウィンドウに分割して類似度計算を行うことで検出できることが分かった。

1. はじめに

業務用・民生用を問わず数多く登場しているウェアラブルデバイスには加速度センサや角速度センサが搭載されている。センサから得られた値を解析することで、装着者の行動を認識でき、健康管理や医療支援、スポーツ、エンタテインメントなどへの応用が期待されている。人間の行動を解析する手法では一般的に、認識対象となる動作があらかじめ定義されている必要がある。例えば、歩行を認識したい場合、歩行とは右足と左足を交互に動かして移動する動作と定義でき、センサを装着したユーザに実際に歩いてもらえばデータを採取できる。一方で、食事、スポーツ、レジャーなどの動作は、言葉では理解できるが、明確に定義できない。例えば、バドミントンはスマッシュなどの特徴的な動作が行われるが、スマッシュをしている極めて短い時間だけバドミントンをしていると判断するのは誤りである。このような動作に対しても、動作を行っている区間を指定することでモチーフ抽出により、バドミントン中に行われる動作を網羅的に抽出することができる。

このように、認識したい動作のデータと正解情報の区間が事前に与えることができればそれらの動作を学習できる。しかし、試験中の学生のカンニング行為のように、事

前に定義できず、またデータも網羅的に収集できない行動がある。すべてのカンニング行為を事前に定義することは現実的には不可能であり、それらの行動はカンニング行為を行ってない多くの人との比較によって発見されるものである。

本研究では、加速度センサを用いて、ダンスや入学試験など同種の動作を行っている集団において、誤った振り付けやカンニングのような大部分の人とは異なるマイノリティな行動をしている人を教師データなしで検出する手法を提案する。

以降、2節では関連研究を紹介する。3節では提案手法について述べ、4節では提案手法の性能を評価し、最後に5節で本研究をまとめる。

2. 関連研究

ウェアラブルデバイスには、加速度センサや角速度センサなどの複数のセンサが搭載されており、それらのセンサから得られたセンサ値を分析することで、人間の行動を認識する研究が数多く行われている。Kwapisz ら [6] はスマートフォンに内蔵されている加速度センサを用いることで、歩く、走る、階段を上がるなどの6種類の動作を認識している。Thomaz ら [7] はスマートウォッチに内蔵されている加速度センサを用いて、ユーザの食べる動作を認識している。Barshan ら [8] は、3軸加速度、角速度および地

¹ 立命館大学大学院情報理工学研究科

² 国立研究開発法人科学技術振興機構さきがけ

磁気センサをユーザの胸と両腕と両脚の5箇所に装着し、日常生活での行動やスポーツの運動などの19種類の行動を認識している。Muraoら[9]は、9個の加速度センサと9個の角速度センサをタブレット端末を想定した盤面上に格子状に配置し、27種類のジェスチャの認識を行い、センサ数やセンサの位置を変更することで認識精度の変化を調査している。

Berlinら[3]は、手首に装着された加速度センサから得られたセンサ値に対して、モチーフ抽出を行うことで、日常生活の中で行われる特定の行動（サイクリング、ギターを弾く、フラメンコを踊る、など）を認識している。土橋[10]らは、浴室内に超音波センサを設置し、ユーザの姿勢と動作を認識し、ユーザが危険な状態かどうかを判定している。

このように認識対象の行動のラベルが付与されたセンサデータを学習することで、未知の動作のデータを認識する手法が提案されているが、本研究で想定するような集団において一部の人間が部分的に他人と異なる類の動作を行うことを認識をする手法を提案している研究は筆者らの知る限り存在しない。

3. 提案手法

本節ではウェアラブルセンサやスマートフォンを装着または所持してダンスや試験などの同種の動作を行っている集団において、一部の人がダンスの振り付けを誤ったり、カンニング行為を行うなどほかの大多数の人と異なる種類の動作を行ったときに、それらの動作を行った人および行った時刻を検出する提案手法を説明する。

3.1 提案手法の概要

提案手法の流れを図1に示す。提案手法はユーザのスマートフォンやウェアラブルセンサから3軸の加速度データが得られる環境を想定する。まず、センサから3軸加速度を取得し、合成加速度を求める。次に、合成加速度の近似を行い、近似したデータをシンボル列に変換する。そして、シンボル列から一定の長さ以上の部分文字列をモチーフとして抽出し、ユーザごとにBag of words (BoW)を作成する。ユーザ間のBoWの類似度を算出し、大部分のユーザいずれとも類似度が低いユーザをマイノリティな行動を行った人として検出する。

3.2 加速度データの取得

各ユーザから時刻 t に取得されるX軸、Y軸、Z軸の加速度データ $a_x(t)$, $a_y(t)$, $a_z(t)$ から、合成加速度 $a(t) = \sqrt{a_x(t)^2 + a_y(t)^2 + a_z(t)^2}$ を計算する。採取した加速度データ a が平均0、分散1になるように正規化し、加速度 a_n を得る。

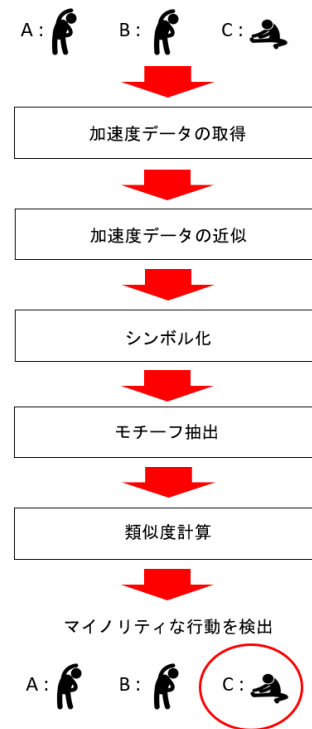


図1 提案手法の流れ

3.3 加速度データの近似

加速度データどうしを比較して類似した部分波形を発見する手法として後述するモチーフ抽出というアプローチがある。モチーフ抽出ではセンサ値をシンボルに変換して量子化し、文字列処理のアルゴリズムを用いて頻出する部分文字列を発見する。センサ値をシンボルに変換する際に、取得されたすべての値をひとつずつシンボルに変換すると変換後のシンボル列が長くなるため文字列処理に時間を要する。そのため、本研究では波形の形状を残しつつ波形を表現するサンプル数を削減する手法であるPairwise Linear Approximation (PLA)という近似アルゴリズムを用いる。PLAは波形を可変長の区間ごとに線形近似する手法であり、その実装としてオンライン処理可能で近似性能の高いSliding-Window and Bottom-Up (SWAB) [1] アルゴリズムを採用する。加速度センサに対してSWABを適用している先行研究はこれまでにあり、その効果が確認されている[2], [3]。

3.4 シンボル化

センサデータの時系列にSWABを適用すると、近似された点を除く点としてオリジナルのセンサデータの時系列の部分集合が得られる。連続する2つのセンサ値から成る線分の系列を文字などのシンボルで量子化して、シンボル系列に変換する。これにより、後述する文字列処理技術を用いてシンボル列に頻出する部分シンボル列抽出できる。このような時系列をシンボルに変換する手法をSymbolic Aggregate Approximation (SAX) [4]と呼ぶ。提案手法で




図 2 センサデータ, PLA 後の近似データ, および SAX 後のシンボル列

は文献 [3] で用いられている, 連続する 2 つの線分の傾きの組み合わせをアルファベット 1 文字に変換する手法を用いる. 具体的にはひとつの線分の傾きを 5 段階に分けて表現すると, 連続する 2 つの線分の傾きの組合せは 25 通りとなる. これをアルファベットの A から Y までの 25 種類に置き換えてシンボル化する. センサデータ, PLA 後の近似データ, SAX 後のシンボル列を図 2 に示す. 図中の PLA 後の波形の頂点に表示されているアルファベットがその頂点の左右の線分に対応するシンボルである. このように, センサデータは大きな変動がないが細かく振動している箇所があり, その区間は PLA によって近似されて波形に変化がある点のみが残されていることが分かる. また, 近似された波形をシンボル化することで, 類似した部分波形には同じ文字列が割り当てられている.

3.5 モチーフ抽出

シンボル化によってセンサデータ時系列が一つの文字列に変換された. モチーフ抽出では, 文字列中出现する部分文字列を抽出して Bag of words (BoW) を作成する. 部分文字列を効率的に発見するアルゴリズムとして Suffix Array[5] が提案されている. 与えられた文字列中出现するすべての部分文字列を Suffix Array によって検索し, それぞれの出現回数を得ることができる. 本研究では 3 文字以上の長さかつ出現回数が 1 回以上の部分文字列を発見し Bag of words (BoW) を作成する. ここで, 対象とする集団が 100 人から構成されている場合, 1 人から BoW がひとつ作成されるため, 100 個の BoW が作成されることになる. また, 提案手法はリアルタイムで動作し, センシング開始から現在時刻までに得られたセンサデータもしくはその一部から BoW を作成するため, BoW は時々刻々更新される.

3.6 類似度計算

作成された BoW から 2 者間の類似度を計算する. ユーザ A とユーザ B の BoW をそれぞれ BoW_A , BoW_B とすると, ユーザ A と B の類似度は, BoW_A と BoW_B に




図 3 実験で行ったラジオ体操第一とは異なる動き

共通する文字列の長さの総和を BoW_A と BoW_B に含まれる文字列の数の和で割ることで求める. 具体的には, BoW_A と BoW_B に含まれる文字列の数をそれぞれ $L(BoW_A)$, $L(BoW_B)$ とし, 両者の BoW に共通する文字列を $BoW_A \cap BoW_B = \{S_k | k = 1, \dots, N\}$ とする. ただし, N は共通する文字列の個数である. S_k の長さを $L(S_k)$ とすると, A と B の類似度 $d(A, B)$ は次式で求められる.

$$d(A, B) = \frac{\sum_{k=1}^N L(S_k)}{L(BoW_A) + L(BoW_B)} \quad (1)$$

この類似度計算をすべての被験者間で行う.

ここで, 特定のユーザの BoW が大きい場合, そのユーザが含まれる類似度は他のユーザどうしの類似度と比較して小さくなる. そのため, 次式に従い, 得られた類似度を被験者ごとの類似度の平均値で割って補正する. ただし, $Group$ は対象とする集団のユーザの集合である.

$$D(A, B) = \frac{d(A, B)}{\sum_{X \in Group} d(A, X)} \quad (2)$$

補正後の類似度の平均が最も低い被験者を, マイノリティな行動をとったと判断する.

4. 評価

本節では提案手法の有効性を評価するために行った実験について述べる.

4.1 実験環境

被験者は 14 名で, 19~23 歳, 大学生, 男性 7 名, 女性 7 名 (被験者 A~N) である. 左腕手首に無線 3 軸加速度センサ (ATR-Promotions 社製 TSND151) を装着し, 被験者 N を除く 13 名は音楽に合わせて, ラジオ体操第一を行った時の加速度データを採取した. 13 名の被験者はそれぞれ別々の時間にデータ採取をした.

被験者 N はマイノリティ行動をする被験者として, 2 種類のデータを採取した. 一つ目はラジオ体操第二を行い, 二つ目はラジオ体操第一の途中に本来とは異なる動きを行った. 二つ目の異なる動きは図 3 の左図のように, 左腕

表 1 すべての時間でマイノリティな動きをしている場合の被験者間の類似度

	A	B	C	D	E	F	G	H	I	J	K	L	M	N
A		1.152	1.002	1.033	0.980	0.963	1.084	0.910	1.057	1.003	0.909	1.006	1.009	0.891
B	1.185		1.036	1.043	1.030	0.984	1.009	0.904	0.954	1.002	1.006	0.959	1.075	0.814
C	1.055	1.060		1.193	0.970	0.942	1.064	0.947	1.035	0.993	0.971	0.917	1.049	0.804
D	1.030	1.011	1.130		1.041	1.000	1.009	0.898	1.025	0.996	0.954	0.991	1.115	0.801
E	1.049	1.071	0.986	1.117		0.953	1.035	0.879	0.964	1.002	1.048	0.960	1.082	0.854
F	1.021	1.013	0.948	1.063	0.944		1.119	1.044	1.039	0.917	0.975	1.011	1.010	0.896
G	1.124	1.016	1.047	1.049	1.002	1.094		0.940	1.038	0.923	0.928	0.919	1.043	0.876
H	1.001	0.965	0.989	0.989	0.903	1.083	0.997		1.027	1.034	0.991	1.025	1.005	0.990
I	1.104	0.968	1.027	1.073	0.941	1.024	1.046	0.975		0.956	0.951	0.848	1.106	0.979
J	1.082	1.050	1.018	1.077	1.010	0.933	0.961	1.015	0.988		0.960	0.986	1.074	0.847
K	0.996	1.071	1.010	1.048	1.073	1.007	0.980	0.987	0.998	0.975		1.011	1.033	0.811
L	1.105	1.024	0.956	1.091	0.986	1.048	0.974	1.024	0.892	1.004	1.013		1.054	0.829
M	1.026	1.061	1.012	1.136	1.028	0.968	1.023	0.929	1.076	1.011	0.958	0.975		0.797
N	1.088	0.967	0.933	0.982	0.975	1.032	1.033	1.100	1.145	0.959	0.904	0.923	0.959	

表 2 すべての時間でマイノリティな動きをしている場合の被験者ごとの類似度の最小値, 最大値, 平均値

	A	B	C	D	E	F	G	H	I	J	K	L	M	N
Min	0.996	0.965	0.933	0.982	0.903	0.933	0.961	0.879	0.892	0.917	0.904	0.848	0.959	0.797
Max	1.185	1.152	1.13	1.193	1.073	1.094	1.119	1.100	1.145	1.034	1.048	1.025	1.115	0.990
Mean	1.067	1.033	1.007	1.069	0.991	1.002	1.026	0.966	1.018	0.983	0.967	0.964	1.047	0.861

を上げて右腕を下げながら体を反時計回りに回転させる動きを行い、その後、図 3 の右図のように、左腕を下げ右腕を上げながら体を時計回りにさせる動きを行った。この 2 種類の動きを約 2 秒おきに交互に行った。これらの動きはラジオ体操第一には含まれていない。この動きをラジオ体操第一の開始直後から 20 秒間行い、残りの時間は他の被験者と同じ体操を行った。同様に、開始 50 秒後から 30 秒間違う動きを行った場合と、開始 150 秒後から 30 秒間違う動きを行った場合の合計 3 種類のデータを採取した。

一つ目のデータはすべての時間においてマイノリティな動作を行っている場合であり、二つ目のデータは特定の時間のみマイノリティな動作を行っている場合である。ラジオ体操第一、第二ともに時間は 3 分である。一つ目のデータについては、3 分間すべてのデータからモチーフ抽出を行って被験者間の類似度を計算した。二つ目のデータについてはマイノリティな動きを行っている区間を見つけるために、ウィンドウ幅 20 秒、スライド幅 1 秒のスライディングウィンドウを適用し、ウィンドウごとに提案手法を用いて被験者間の類似度を求めた。

4.2 全ての時間でマイノリティな動きをしている場合の結果

表 1 に被験者 14 名どうしの類似度を示す。表 1 を縦に見ると、被験者 A~M は類似度がおおよそ 0.85~1.19 であるのに対して、被験者 N はおおよそ 0.80~0.99 にある。この結果から、マイノリティな動きを行った被験者 N は、他のいずれの被験者とも低い類似度を示すことが分かる。また、

表 1 を縦に見たときの被験者ごとの類似度の最小値, 最大値, 平均値を表 2 に示す。表 2 より、被験者 N は最小値, 最大値, 平均値のいずれも、14 名の被験者のなかで最低であることが分かる。

表 2 より、被験者 N は類似度の最小値, 最大値, 平均値が小さいことが分かり、マイノリティな行動をしている人であると検出できたといえる。また、表 2 の平均値は、各被験者とその集団の類似度を示しているといえる。類似度の最小値, 最大値, 平均値に閾値を設定することで、集団をマジョリティとマイノリティに分類することができると考えられる。

4.3 一部の時間だけマイノリティな動きをしている場合の結果

ラジオ体操第一の途中 3 種類の時間帯（開始から 20 秒間、開始 50 秒後から 30 秒間、開始 150 秒後から 30 秒間）にマイノリティな動作を行うデータに対して、スライディングウィンドウで計算された類似度の時間変化をそれぞれ図 4, 図 5, 図 6 に示す。図の横軸は時間、縦軸は各被験者における他 13 人の被験者との類似度の平均を表す。図の時刻 20 秒の類似度は 0~20 秒間のウィンドウから計算された類似度の平均値を表している。また、図中の黒破線は被験者 N が異なる動きをしている区間を表している。図 4 より、被験者 N が異なる動きをしている区間すべてがウィンドウ内に入る 20 秒付近が被験者 N の類似度が最も小さくなり、その後、時間が経つにつれて、ウィンドウ内に含まれる違う動きをしている区間が少なくなり、類似度が




図 4 開始後から 20 秒間被験者 N が他の被験者と異なる動きを行った場合の類似度の時系列変化




図 5 開始 50 秒後から 30 秒間被験者 N が他の被験者と異なる動きを行った場合の類似度の時系列変化




図 6 開始 150 秒後から 30 秒間被験者 N が他の被験者と異なる動きを行った場合の類似度の時系列変化

高くなっていることが分かる。同様に、図 5 より、異なる動きをしている区間がウィンドウ内に含まれる 50 秒から徐々に類似度が下がり、異なる動きをしている区間がウィンドウ内に全て含まれる 70 秒付近で類似度が最も低くなり、その後、類似度が高まっていることが分かる。図 6 でも、異なる動きをしている区間がウィンドウ内に含まれ始めた 160 秒頃から類似度が徐々に下がっていき、170 秒付近で類似度が最も低くなっていることが分かる。

実験結果より、他の人と異なる動きをしている区間がウィンドウ内に多く含まれているほど類似度が低くなっており、ウィンドウごとに分割して類似度計算を行えば、マイノリティな状況を検出できることが分かる。

5. おわりに

本研究では、加速度データから抽出したシンボル列をもとに、人どうしのシンボル列を比較することで、集団においてマイノリティな行動を行う人を検出する手法を提案し

た。評価実験では、14 人の被験者のうちすべての時間でマイノリティな行動を行った 1 人は他のいずれの 13 人とも類似度が低くなり、マイノリティな人を検出できることが分かった。また、一部の時間のみマイノリティな行動をしている場合も、スライディングウィンドウに分割して類似度計算を行うことで検出できることが分かった。

本研究では、マイノリティな行動をしている人が 1 人を想定して実験を行ったが、現実では複数人がマイノリティな行動をすると考えられるため、今後はさまざまなマイノリティのパターンのデータで評価する。

謝辞 本研究は、科学技術振興機構戦略的創造研究推進事業さきがけ (JPMJPR1937) の支援を受けたものである。ここに記して謝意を表す。

参考文献

- [1] Eamonn Keogh, Selina Chu, David Hart, Michael Pazani: An Online Algorithm for Segmenting Time Series, In ICDM 2001, pp. 289–296 (2001).
- [2] Kristof Van Laerhoven, Eugen Berlin, Bernt Schiele: Enabling Efficient Time Series Analysis for Wearable Activity Data, In ICMLA 2009, pp. 392–397 (2009).
- [3] Eugen Berlin, Kristof Van Laerhoven: Detecting Leisure Activities with Dense Motif Discovery, In Ubicomp 2012, pp. 250–259 (2012).
- [4] Jessica Lin, Eamonn Keogh, Stefano Lonardi, Bill Chiu: A Symbolic Representation of Time Series, with Implications for Streaming Algorithms, In DMKD 2003, pp. 2–11 (2003).
- [5] Udi Manber, Gene Myers: Suffix Arrays: A New Method for On-Line String Searches, SIAM Journal on Computing, Vol. 22, Issue 5, pp. 935–948 (1993).
- [6] Jennifer R. Kwapisz, Gary M. Weiss, Samuel A. Moore: Activity Recognition using Cell Phone Accelerometers, SIGKDD Explorations, Vol. 12, No. 2, pp. 74–82 (2010).
- [7] Edison Thomaz, Irfan Essa, Gregory D. Abowd: A Practical Approach for Recognizing Eating Moments with Wrist-Mounted Inertial Sensing, In UbiComp 2015, pp. 1029–1040 (2015).
- [8] Billur Barshan, Murat Cihan Yükek: Recognizing Daily and Sports Activities in Two Open Source Machine Learning Environments Using Body-Worn Sensor Units, the Computer Journal, Vol. 57, No. 11, pp. 1649–1667 (2013).
- [9] Kazuya Murao, Tsutomu Terada, Ai Yano, and Ryuichi Matsukura: Evaluating Gesture Recognition by Multiple-Sensor-Containing Mobile Devices, in ISWC 2011, PP. 55–58 (2011).
- [10] 土橋裕樹, 田嶋拓也, 阿部武彦, 南保英孝, 木村春彦: 超音波センサを用いた浴槽内での異常検知システムの改善, 電気学会論文誌 E センサ・マイクロマシン部門誌, Vol. 129, No. 1, pp. 6–13 (2009).