

名刺型センサを用いた協調学習分析手法に関する一検討

山口 隼平¹ 大多和 修介² 大島 律子² 大島 純² 藤橋 卓也¹ 猿渡 俊介¹ 渡辺 尚¹

概要：協調学習とは、他者と協調（コラボレーション）しながら創造的な問題解決に取り組む能力を育む学習である。他の学習者と協調しながら問題解決に取り組むことによって、自身にはない考え方を他の学習者から学ぶことができたり、他の学習者と意見をすり合わせる過程を通じてメンバ間の社会的関係を向上させる能力を習得したりすることができる。しかしながら、現状の学習科学の分野では定性分析の手法を用いて協調学習を分析しているため、数十人が参加する協調学習を対象として分析するには人的コストや時間的コストの面で課題がある。本研究では、協調学習における定性分析をサポートすることを目的として学習科学の研究者が着目すべきポイントを自動抽出する「Sensor-based Regulation Profiler」を提案する。Sensor-based Regulation Profiler は、学習者からセンサデータを取得する名刺型センサと取得したセンサデータを分析するデータマイニング技術から構成される。データマイニング技術はセンサデータから協調学習中のソーシャルグラフ・学習フェーズ・発話者を自動抽出することで定性分析で生じるコストの低減を図る。名刺型センサを用いた実証実験からデバイス間における時刻同期誤差を約 $\pm 30 \mu s$ に抑えられることがわかった。また、実際の協調学習に対して Sensor-based Regulation Profiler を用いた実験評価から学習者のセンサデータを用いてソーシャルグラフ・学習フェーズを自動的に抽出・視覚化できること、平均約 77.8%の精度で発話者特定を実現できることがわかった。

1. はじめに

学習科学とは、人間の知性を高めるために各個人にあった学習環境をデザインする学問領域である。学習科学は、学習者自身が自分の能力を最大限に活用して自発的に理解を獲得できる学習環境をどのように設計するかを明らかにしようとしている。すべての学習者の能力を同じ教授方法で伸ばすことは困難であり、一方的に教え込むだけでは学習者が自分で伸びる能力を育てることができないという視座に立っている。学習科学の目標は、近年の学習指導要領の改訂に伴って掲げられた学校教育の目標と一致している。文部科学省が発表した高等学校学習指導要領（平成 30 年告示）[1]によると、生徒の新しい時代を生きる力を育成することを目標とした主体的・対話的で深い学びの実現に向けた授業改善が大きなテーマとなっている。

本研究では、学習科学の学問領域の中でも他者と協調（コラボレーション）しながら創造的な問題解決に取り組む能力を育成する協調学習に注目している。協調学習では、他の学習者と協調しながら問題解決に取り組むことによって自身にはない考え方を他の学習者から学んだり、他の学習者と意見をすり合わせる過程を通じてメンバ間の社会的

関係を向上させる能力を習得したりすることができる。また、協調学習における各学習者の知識や考え方の違いをすり合わせる過程を通じて、主体的・対話的で深い学びを実現することができる。

協調学習に関するこれまでの研究成果から、協調学習において学習効果を上げるためにはいくつかの法則があることが明らかになってきている [2-7]。文献 [3] では、ソーシャルネットワーク分析と対話分析に基づく定性分析から、いくつかの対話パターンが協調学習の参加者に対して知識の補完や新たな知識の創造に関与することが明らかになっている。文献 [4] では、同じ課題解決方法を用いる学習者同士をグループとしてまとめることで協調学習において高い学習成果が安定して得られる傾向にあることが示されている。

しかしながら、これらの研究成果を実際の教育現場に適用するのは現状では困難である。これまでの研究では、学習科学の研究者が学習者の学習活動を観察・分析する定性分析によって知識創造のプロセスを明らかにしてきた。具体的には、学習者の会話をボイスレコーダで記録して文字起こししたうえで研究者が読み込んで学習活動を分析している。実際の教育現場では学習者の人数が多いため、学習科学の研究者がこれまで行ってきた定性分析では多数の学習者の学習活動を観察・分析することはデータ量的観点か

¹ 大阪大学大学院情報科学研究科

² 静岡大学大学院総合科学技術研究科

ら困難である。また、これまでの定性分析は基本的に人手によって行われることに起因して時間を要するため、分析結果を即座に教育現場にフィードバックすることも困難である。

以上の観点から、本研究では、学習者の活動を定量的に分析して学習科学の研究者が着目すべきポイントを自動抽出して可視化する Sensor-based Regulation Profiler を提案する。Sensor-based Regulation Profiler は、学習者からセンサデータを取得する名刺型センサと取得したセンサデータを分析して可視化するデータマイニング技術から構成される。また、各名刺型センサには時刻同期モジュールを搭載することで学習者間で得られたセンサデータの高精度な時刻同期を達成する。Sensor-based Regulation Profiler では、学習者に名刺型センサを取り付けて取得したセンサデータから知識創造のプロセスを自動抽出して可視化することで、学習科学の研究者がより詳細かつ定性的に学習活動を分析する。具体的には、自動抽出結果から協調学習のプロセスがうまくいっていないグループを見つけて、そのグループの学習活動のプロセスを学習科学の研究者がリアルタイムにナビゲートするといった利用を想定している。

Sensor-based Regulation Profiler を用いた実証実験から名刺型センサ間で約 30 μ s の時刻同期精度を達成すること、協調学習中の学習者同士の対面を表すソーシャルグラフの自動抽出ができること、協調学習中の学習フェーズの自動抽出ができること、協調学習に参加した 3 名のうち誰が発話したかを平均約 77.8% の精度で特定できることがわかった。

本稿の構成は以下のとおりである。2 節では、協調学習の場に対して定量分析ツールを導入するときの要件について述べる。3 節では、提案手法である Sensor-based Regulation Profiler について述べる。4 節では、名刺型センサである Sensor-based Regulation Profiler Badge について述べる。5 節では、学習分析手法について述べる。6 節では、名刺型センサの無線同期性能評価について述べる。7 節では、協調学習を対象とした実証実験評価について述べる。8 節では、関連研究について述べる。最後に 9 節では、結論を述べる。

2. 協調学習の場に対して定量分析ツールを導入するときの要件

協調学習の場に対して定量分析ツールを導入するためには、以下の 3 つの要件を満たす必要がある。

- (1) 学習環境に簡単に導入できること
- (2) データの時刻同期が取れていること
- (3) 協調学習のフェーズの自動抽出ができること

「1. 学習環境に簡単に導入できること」は定量分析ツールを広く展開するために必要である。学習環境に対して設置するコストが高価な技術や入手性が悪い技術を利用す

ることは現実的ではない。本研究では、学習環境に簡単に導入できることを目的として学習者が首からつり下げられることを想定した名刺型センサの導入を考えている。名刺型のセンサとして、日立のビジネス顕微鏡 [8] や MIT の Sociometric Badge [9] が存在する。たとえばビジネス顕微鏡では、企業の組織内のコミュニケーションの定量分析に成功している。組織内のネットワークの分析によって組織内の壁や一体感を把握することでコミュニケーションの問題を解決している。しかしながら、ビジネス顕微鏡も Sociometric Badge も市販されておらず入手することができなかった。

「2. データの時刻同期が取れていること」は、本研究が各個人ではなく人と人との協調の抽出を対象としていることから必要となる。本研究では、学習者や学習環境などの様々な対象にセンサが設置されており、かつ多様なセンサからのデータの整合性を確認しながら分析する。時刻同期が取れていないデータ同士を結合して分析した場合、実際に起こった事象の時系列的な順序が崩れてしまうため分析の結果が意味をなさないものになってしまう。コラボレーションを抽出するためのセンサとしては先にも述べたとおりビジネス顕微鏡や Sociometric Badge が存在するが、各センサ間の時刻同期を行う仕組みは提供されていない。時刻同期の精度としては、サンプリングレートの 10 分の 1 以下の精度が取得できていることが望ましい。たとえば、100 Hz でセンサデータを取得している場合には 1 ms 以下での時刻同期を取れていることが求められる。

「3. 協調学習のフェーズの自動抽出ができること」は、協調学習における定性分析と定量分析を接続するために必要である。理想的には、学習科学の研究者による定性分析で得られる分析結果と同じ分析結果を定量分析によってすべて自動抽出できることが望ましい。しかしながら、現状では機械と人間が取得・処理できる情報には大きな乖離があるため、定性分析のすべてを定量分析で置き換えることは困難である。そこで本研究では、協調学習における学習フェーズの自動抽出と学習フェーズ内の情報自動抽出としてソーシャルグラフ抽出・発話者特定に対象を絞る。

3. Sensor-based Regulation Profiler

協調学習における定性分析のコスト削減と客観的なデータの提供を目的として、学習者からセンサデータを取得する Sensor-based Regulation Profiler Badge と取得したセンサデータを分析するデータマイニング技術を提案する。図 1 に、提案システムである Sensor-based Regulation Profiler を用いた協調学習分析の全体像を示す。Sensor-based Regulation Profiler では学習科学の研究者による協調学習の定性分析を以下の順序でサポートする。

- (1) 学習者に Sensor-based Regulation Profiler Badge を配布

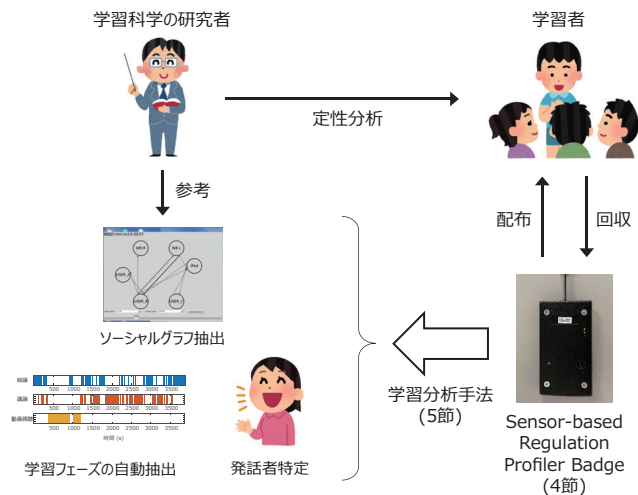


図 1: Sensor-based Regulation Profiler を用いた協調学習分析の全体像

- (2) 学習者による協調学習を実施
- (3) 学習者から Sensor-based Regulation Profiler Badge を回収
- (4) Sensor-based Regulation Profiler Badge からセンサデータを抽出
- (5) センサデータからソーシャルグラフ・学習フェーズ・発話者を自動抽出して可視化
- (6) ソーシャルグラフ抽出結果・学習フェーズ抽出結果・発話者特定結果を用いて学習科学の研究者が協調学習を定性的に分析

Sensor-based Regulation Profiler Badge については 4 節で、学習分析手法であるソーシャルグラフ抽出技術・学習フェーズ抽出技術・発話者特定技術については 5 節でそれぞれ詳細に述べる。

4. Sensor-based Regulation Profiler Badge

図 2 (a) に Sensor-based Regulation Profiler Badge (センサノード) の写真を、図 2 (b) に Sensor-based Regulation Profiler Badge のブロック図を、図 3 に Sensor-based Regulation Profiler Badge Synchronizer (シンクノード) の写真を示す。センサノードは学習者の首から下げることを想定した名刺型のセンサとなっている。センサノードは、電源制御部・CPU センサ部・無線部からなる。

電源制御部では、センサノードを動かすためにリチウムイオン電池が搭載されている。リチウムイオン電池から電源スイッチと Micro Controller Unit (MCU) に電源が供給されている。センサノードの連続稼働時間は 24 時間である。

表 1 に、センサノードに用いたモジュールを示す。CPU センサ部では、STMicroelectronics 社の STM32L476RGT6 を MCU として、ANALOG DEVICES 社の ADXL362 の

表 1: センサノードの各モジュール

モジュール名	型番	メーカー名
MCU	STM32L476RGT6	STMicroelectronics
加速度センサ	ADXL362	ANALOG DEVICES
赤外線 LED	OSI5LAS1C1A	OptoSupply
赤外線受光器	PIC79603	KODENSHI CORP.
アナログマイクروفोन	INMP510	TDK
microSD カードコネクタ	DM3AT-SF-PEJM5	Hirose Electric

加速度センサ、OptoSupply 社の OSI5LAS1C1A の赤外線 LED、KODENSHI CORP. の PIC79603 の赤外線受光器、TDK 社の INMP510 のアナログマイクروفオンが搭載されている。加速度センサは 100 Hz 3 軸 12 bit、音圧センサは 100 Hz 12 bit でサンプリングする。記憶装置として、Hirose Electric 社の DM3AT-SF-PEJM5 の microSD カードコネクタを具備している。加速度データ・赤外線データ・音圧データは microSD カードによって保存できる。FAT32 形式でフォーマットした 32 GB 以下の microSD カードを名刺型センサのスロットに差し込むことでセンサ値のバイナリデータが保存される。

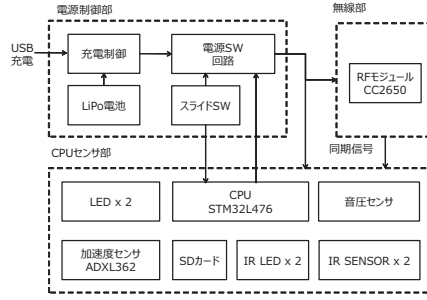
無線部では、無線同期モジュールが搭載されている。無線同期モジュールは、シンクノードから 10 ms ごとに送信される同期信号を他のセンサノードに転送してセンサノード間の時刻同期を実現する。図 2 (b) に示した RF モジュールである Texus Instruments 社の CC2650 上では、センサノード間の高精度な時刻同期を実現する同時送信型フラッディングプラットフォーム「UNISONet (別名 Choco)」[10, 11] が動作している。同時送信型フラッディングでは、任意のセンサノードが近隣のセンサノードに対して時刻同期パケットを転送することで宛先センサノードに時刻同期パケットを伝搬する。センサノードは新たに時刻同期パケットを受信すると即座に他のセンサノードに対して時刻同期パケットを転送する。フラッディングによって各センサノードが時刻同期パケットの受信・転送を繰り返すことで、時刻同期パケットをセンサノード全体に高速で伝搬することができる。

5. 学習分析手法

学習者に取り付けた名刺型センサから得られたセンサデータを用いて学習フェーズを自動的かつ詳細に抽出するためにデータマイニング技術を開発した。具体的には、赤外線データを用いたソーシャルグラフ抽出技術と学習フェーズ抽出技術、音圧データと加速度データを組み合わせた発話者特定技術を提案する。



(a) センサノード



(b) ブロック図

図 2: Sensor-based Regulation Profiler Badge



図 3: Sensor-based Regulation Profiler Badge Synchronizer

Algorithm 1 ソーシャルグラフ抽出

Require: L, U, t_0

Ensure: G

```

1: insert zero into all elements of  $G$ 
2: for all  $d \in U$  do
3:    $S \leftarrow$  all received IDs in  $l_d \in L$  between  $t_0$  to  $t_0 + W$ 
4:   for all  $s \in S$  do
5:     increment  $G[s][d]$ 
6:   end for
7: end for
8: return  $G$ 

```

表 2: Algorithm 1 で用いる変数と関数

変数・関数	説明
U	すべての名刺型センサ ID の集合
L	全名刺型センサが取得した赤外線センサデータの集合
l_d	名刺型センサ d が取得した赤外線センサデータ
t_0	ソーシャルグラフを抽出する時刻
G	$ U \times U $ の二次元配列 ソーシャルグラフのマトリクス
W	ウィンドウサイズ (秒)
d, S, s	計算用の一時変数

5.1 ソーシャルグラフ抽出技術

本手法では、各名刺型センサから得られるセンサデータをもとにして名刺型センサ間の対面関係から学習者同士のネットワークを表すソーシャルグラフを抽出する。各名刺型センサが記録する赤外線データには、1 秒ごとに検知した他の名刺型センサの ID が記録されている。Algorithm 1 にソーシャルグラフ抽出アルゴリズムを、表 2 に Algorithm 1 で用いる変数と関数を示す。Algorithm 1 は、すべての名刺型センサ ID の集合 U 、全名刺型センサが取得した赤外線センサデータの集合 $L = \{l_1, l_2, \dots, l_{|U|}\}$ 、ある時刻 t_0 を入力として、 L における時刻 t_0 のソーシャルグラフを表すマトリクス G を出力するアルゴリズムである。Algorithm 1 では、時刻 $t_0 \sim t_0 + W$ の期間に各名刺型センサが取得した赤外線センサデータから、行を送信元、列を宛先と

して受信回数を累計したマトリクスを生成している。

たとえば、ユーザ 1 の名刺型センサに含まれる赤外線センサが取得したデータが

```

900000000, 1, 2
900000001, 2, 3, 2
900000002, 1, 2

```

であったとする。各名刺型センサの赤外線センサデータは、左からタイムスタンプ、タイムスタンプ時に赤外線センサが検知した他の赤外線センサの個数、検知した赤外線センサを具備する各名刺型センサの ID で構成される。同様に、ユーザ 2 の名刺型センサに含まれる赤外線センサが取得したデータが

```

900000000, 1, 1
900000001, 1, 1
900000002, 1, 1

```

ユーザ 3 の名刺型センサに含まれる赤外線センサが取得したデータが

```

900000001, 1, 1

```

であった場合、算出されるマトリクス G は以下のとおりとなる。得られたマトリクスは図 4 に示す有向グラフを表

IDs	1	2	3
1	-	3	1
2	3	-	0
3	1	0	-

している。マトリクスの値が大きければ大きいほどユーザ間で対面する頻度が高いことから図 4 では濃い矢印で表している。

5.2 学習フェーズ抽出技術

本手法では、名刺型センサが具備する赤外線データから




図 4: ソーシャルグラフの例

得られた学習者同士のネットワークをもとにして学習中のネットワークの変化量から学習フェーズを自動抽出する。学習中のネットワークの変化量は学習フェーズの変遷を表している。協調学習の学習フェーズは動画視聴・議論・結論の3つに分かれている。学習フェーズが移り変わるとき、人は今まで対面していたものから異なる対象への注目が増えたり多数の対象に注目したりと特徴的な変化が表れる。学習中の対面情報に生じる特徴的な変化を赤外線データから捉えることで、学習プロセス全体を分析することなく学習フェーズを抽出するとともに定量的なデータとして活用する。

学習中のネットワークの変化は、各名刺型センサの赤外線データから得られたマトリクス G の時間変化量をもとにして定量化する。各時刻のマトリクス G は Algorithm 1 にしたがって抽出する。ここで、マトリクスは3秒間隔で抽出するものとして、各マトリクスのウィンドウサイズ W は60秒と定めた。ウィンドウごとにマトリクスを作成したあと、あるウィンドウのマトリクスと直後のマトリクスについて要素ごとに差の平方を求めて、その総和を学習中のネットワーク変化量として求める。

ネットワークの変化量から各学習フェーズを高速かつ自動的に抽出するために AutoPlait [12, 13] を使用した。AutoPlait は、様々なパターンを含む大規模時系列データを入力として時系列データの中から重要だと思われる特徴を発見するとともに時系列データのグループ化、グループの可視化を行う手法である。提案手法では、協調学習中のネットワーク変化量に対して AutoPlait を用いることによって AutoPlait が抽出する各時系列データグループとして各学習フェーズを発見することができる。具体的には、ネットワーク変化量を時系列に並べたシーケンスデータについて多階層連鎖モデル (Multi-Level Chain Model: MLCM) に基づいてネットワーク変化量の変化点を発見することでシーケンスデータ全体を部分シーケンス集合 (セグメント) に分割する。このとき、セグメント内のデータが類似するセグメント同士は最小記述長 (Minimum Description Length: MDL) に基づくコスト関数にしたがって共通のグループ (レジーム) として割り当てる。本研究では、得られた各レジームを協調学習における各学習フェーズとして

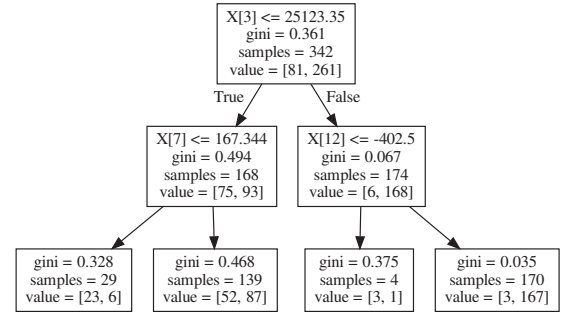


図 5: 決定木分析の例

みなす。

5.3 発話者特定技術

本手法では、各学習者が身につけた名刺型センサから得られる音圧データおよび加速度データを組み合わせて協調学習中の各発言がどの学習者によるものかを特定する。前節で述べたとおり、協調学習中にいずれかの学習者が発話しているとき各学習者の名刺型センサが音圧の変化を検知する。一方で、発話者が同じであっても発話時の向きや声量によって音圧の変化量の傾向は変わるため、各学習者の名刺型センサから得られる音圧データのみを用いて発話者を特定することは困難となる。本手法では、名刺型センサが取得する音圧データと加速度データを同時に用いて発話者を特定するために、目的変数を名刺型センサを身につけていた学習者が発話していたか、説明変数を音圧、加速度の x 軸成分、加速度の y 軸成分、加速度の z 軸成分における最大値・最小値・平均・分散の計16個とした決定木分析を利用する。図5に、決定木分析の例を示す。決定木分析とは、目的変数と説明変数の関係をツリー構造 (決定木) で表現することでデータ集団を効率的に分類できる手法である [14, 15]。

決定木分析のアルゴリズムとしてジニ係数をもとにした CART 法 (Classification and Regression Trees) [16, 17] を使用した。CART 法では、どの説明変数におけるどの値を閾値としてデータを分割するか不純度を指標として決定する。不純度を表すものとしては誤分類率・交差エントロピー・ジニ係数といったものが挙げられるが、本研究では、ジニ係数を用いた不純度によってデータの分割の最適化を図る。ジニ係数 (GI) は式 (1) で表される。

$$GI = 1 - \sum_{i=1}^c [p(i|t)]^2 \quad (1)$$

式中の t はノード、 i はクラス、 c はクラスの数、 p は分割された個体のクラスに属する比率である。ジニ係数の値が1に近づくとき悪い分割を、0に近づくとき良い分割を意味する。ジニ係数が0に近づくように各説明変数に対する閾値を繰り返し変更することで名刺型センサを身につけていた




図 6: 名刺型センサの時刻同期精度

学習者が発話していたかを特定する。

6. 名刺型センサの無線同期性能評価

名刺型センサにおいて、シンクノードとセンサノード間における時刻同期精度を実験評価した。本実験では、机の上にシンクノードとセンサノード 1 台ずつを近距離で配置してシンクノードが送信する同期信号をもとにノード間の時刻のずれを計測した。ノード間の時刻のずれを正確に取るために各ノードのクロックが立ち上がるタイミングをオシロスコープで計測した。また、各センサの無線同期モジュールは 10 ms ごとに同期信号を送信するものとしてサンプル数は 30003 個とした。

図 6 に、無線同期実験で計測した名刺型センサの時刻同期精度を示す。横軸は計測された時刻同期のずれ [μs]、縦軸は度数を示す。図 6 から、時刻同期誤差は $\pm 30 \mu s$ 以内に抑えられていることがわかる。また平均値として $-7.7 \mu s$ 、最小値として $-30 \mu s$ 、最大値として $17 \mu s$ が得られた。センサノードに搭載されている加速度センサと音圧センサのサンプリングレートは 100 Hz であるため、得られた同期誤差は要求される時刻同期精度である 1 ms 以下を十分に満たしていることがわかる。また、シンクノードとセンサノードで同期周波数を定期的に補正することによって同期誤差は常に $\pm 30 \mu s$ 以内に抑えられることから、より高いサンプリングレートのセンサを利用したとしても、複数の名刺型センサのセンサデータを組み合わせた協調学習の分析が可能となることを示唆している。

7. 協調学習を対象とした実証実験評価

各学習者の名刺型センサから得られたセンサデータを用いて協調学習中の学習者の活動からソーシャルグラフ・学習フェーズ・発話者を自動抽出することが可能であることを評価するために実証実験を行った。図 7 に、協調学習を対象とした実証実験の様子を示す。名刺型センサを所持した学生 3 人のグループによる問題解決の様子をモニタリング



図 7: 協調学習を対象とした実証実験の様子

した。センサノード間の時刻同期を実現するために学生が使用する机の中央にシンクノードを設置した。各学生は名刺型センサを胸元に装着しながら協調学習に参加した。学生の議論を補助するためにホワイトボードを設置した。ホワイトボードの左右両端には名刺型センサを設置した。学生に学習課題を提示するために iPad を設置した。iPad の上端にも名刺型センサを装着した。

7.1 ソーシャルグラフの自動抽出結果

図 8 (a) に動画視聴フェーズにおけるソーシャルグラフの 1 つを、図 8 (b) に議論フェーズにおけるソーシャルグラフの 1 つを、図 8 (c) に結論フェーズにおけるソーシャルグラフの 1 つを示す。図 8 (a)・(b)・(c) それぞれの左上に学習経過時刻 [h:mm:ss] が表示されている。図 8 (a)・(b)・(c) において、User 1・User 2・User 3 は学習者に装着した名刺型センサを、WB.R・WB.L はホワイトボードの右端・左端に設置した名刺型センサを、iPad は iPad に設置した名刺型センサを、矢印は名刺型センサが検知した対面データを示す。

図 8 (a) では、学習者および学習環境におけるネットワークがあまり検知されていないことから動画視聴フェーズにおいて学習者同士が対面せずに学習していたと考えられる。図 8 (b) では、User 1, User 2, ホワイトボードの右端との対面および User 2 とホワイトボードの左端との対面が検知されていることがわかる。ホワイトボードの右端に最も近い学習者は User 1 であったことから、User 1 がホワイトボードを使用しているところを User 2 が見ながら学習者同士で議論を行っていたと考えられる。図 8 (c) では、User 1・User 2・User 3 とホワイトボードの右端との対面および User 1 と User 2 との対面が検知されていることがわかる。ホワイトボードの右端に最も近い学習者は User 1 であったことから、User 1 がホワイトボードを使用しているところを User 2・User 3 が見ながら学習者同士で結論を導いていたと考えられる。

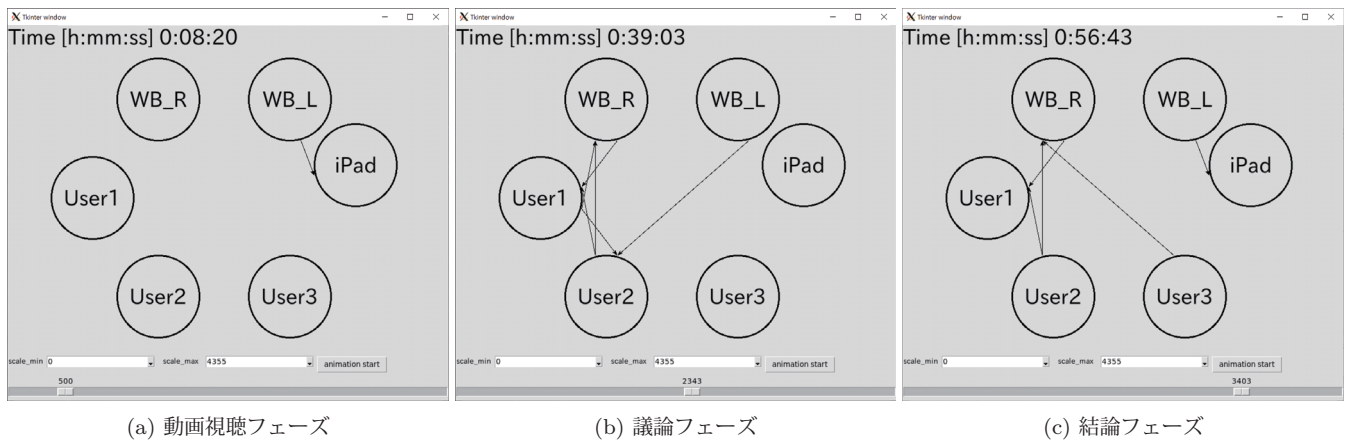


図 8: 各学習フェーズにおけるソーシャルグラフ

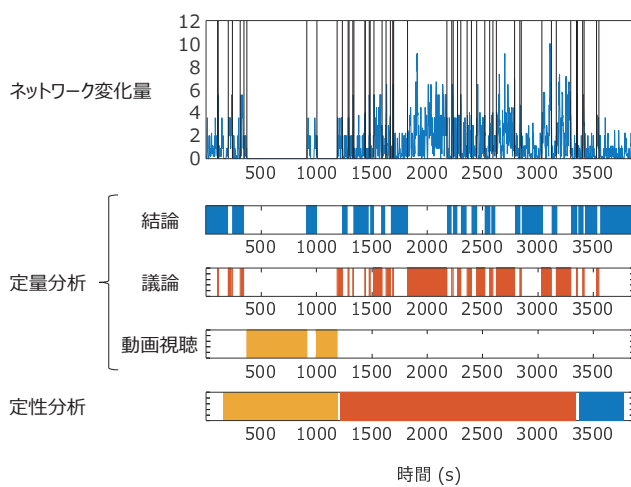


図 9: 学習フェーズの自動抽出結果

7.2 学習フェーズの自動抽出結果

図 9 に、本実験において AutoPlait を用いた学習フェーズの自動抽出結果を示す。図 9 の上段のグラフは、協調学習における学習者間のネットワーク変化量を表している。具体的には、横軸は実験開始からの経過時刻 [秒]、縦軸は正規化したネットワーク変化量を表している。図 9 の中段に示した 3 つのグラフは AutoPlait による学習フェーズ抽出結果を表している。3 つのグラフは、AutoPlait が抽出した学習フェーズである動画視聴・議論・結論の時間をそれぞれ表している。図 9 の下段のグラフは、学習科学の研究者による手動での学習フェーズの抽出結果を表している。手動での学習フェーズの抽出結果では、動画視聴フェーズが 110 秒～1173 秒、議論フェーズが 1213 秒～3335 秒、結論フェーズが 3360 秒～3844 秒となった。自動抽出結果と若干の範囲のずれはあるものの、協調学習プロセス全体からおおよその学習フェーズの自動抽出に成功していることがわかる。範囲のずれの要因としては、データ処理時の 60 秒のウィンドウ幅、人間が捉えられていない現象によるずれ、センサが捉えられていない現象によるずれなど

表 3: 決定木と SVM による発話者特定精度

	User 1	User 2	User 3	平均
決定木	81.1 %	84.0 %	68.2 %	77.8 %
SVM	80.4 %	83.7 %	66.2 %	76.8 %

が考えられる。

7.3 発話者特定精度

提案手法における発話者特定精度を評価するために、結論フェーズにおける各学習者の音圧データと加速度データを用いて決定木分析を行った。また比較手法として Support Vector Machine (SVM) [18] を用いた分析を行った。本評価では、協調学習中の結論フェーズに相当する 410 秒のセンサデータを使用して学習データを作成した。学習データを作成するために一定区間のウィンドウを定めて、ウィンドウ内でどの学習者が発話していたかどうかをラベル付けした。ウィンドウ幅は 5 秒として 2.5 秒ずつウィンドウを移動させて各ウィンドウ内で名刺型センサを所持していた学生が発話していたかをラベル付けした。名刺型センサを所持した学習者 1 人あたり 163 個の学習データが得られることから、学習者ごとに 163 個のサンプルを一様に 7:3 でトレーニングデータとテストデータとに分けてテストデータ使用時の発話者特定精度を評価した。

表 3 に、決定木と SVM をそれぞれ用いた発話者特定精度を示す。発話者特定精度は学習データからテストデータを一様に 100 回選出したときの平均値を取得した。決定木を用いたときの発話者特定精度は User 1 で 81.1 %、User 2 で 84.0 %、User 3 で 68.2 %、全ユーザで平均 77.8 %となることがわかった。SVM を用いたときの発話者特定精度は User 1 で 80.4 %、User 2 で 83.7 %、User 3 で 66.2 %、全ユーザで平均 76.8 %となることがわかった。どちらの手法においても User 3 発話時の特定精度が低下した理由の 1 つとして、User 3 の声量が小さく平常時の音圧センサ値

と発話時の音圧センサ値の差が小さくなったことが考えられる。

8. 関連研究

本研究は、名刺型センサを利用したコラボレーション抽出技術、センサ情報を利用した行動認識手法、協調学習に対する分析手法に関する研究と関連する。

8.1 名刺型センサを用いたコラボレーション抽出技術

被験者が装着した名刺型センサを利用して被験者同士のコラボレーションを抽出する試みはこれまでいくつかの研究で取り組まれている。ビジネス顕微鏡 [8] では、赤外線センサを搭載した名刺型のセンサを被験者が装着する。赤外線センサから得られる被験者同士の対面情報を利用した結果、適切な会議頻度が仕事の効率に影響をもたらすことがわかっている。Sociometric Badge [9] では、被験者が加速度センサ・音圧センサ・位置センサ・Bluetooth・赤外線センサを搭載した名刺型センサを装着する。装着したセンサから被験者同士の対面状況、会話のトーンの変化、近接度を収集することで、被験者同士の対面状況のネットワークが被験者の労働生産性や作業効率に影響をもたらすことがわかっている。Open Badges [19] では、音圧センサ・Bluetooth を搭載した小型のセンサを被験者の首まわりに装着する。音圧センサを用いて取得したセンサデータと Bluetooth を用いて取得した他のセンサからの RSSI 値をもとにして被験者同士の対面を可視化している。

一方でいずれの名刺型センサも市販されておらず入手が困難である。また、各被験者が装着するセンサ間での時刻同期精度が数十ミリ秒から数百ミリ秒であるため協調学習を対象とした定量分析においては学習フェーズの抽出が正しく行われない可能性がある。

本研究で開発した名刺型センサは加速度センサ・赤外線センサ・音圧センサを搭載している。従来の名刺型センサと大きく異なる点として、時刻同期モジュールを搭載することで数十 μ s 程度の時刻同期精度を達成することが挙げられる。数十 μ s 程度の時刻同期を達成することでセンサデータの時系列的な順序において整合性が取れることから協調学習における学習フェーズ抽出等の定量分析精度の向上につなげることができる。

8.2 センサ情報を利用した行動認識手法

被験者が装着した複数のセンサ情報を利用して被験者の行動を認識する研究も進められている。文献 [20] では、被験者の手首・足首・胸に加速度センサを装着して得られたセンサデータをクラウドに送信する。クラウドでは、決定木分析を使用することで被験者の 6 つの行動 (寝そべる、座る、立つ、歩く、走る、自転車に乗る) を分類する。評価実験から 2 秒ごとの行動分類精度が 94% という結果になっ

た。文献 [21] では、加速度センサ・光センサ・温度計・音センサを内蔵した腕時計型のウェアラブルデバイスを被験者が装着する。得られたセンサデータに対して決定木分析を用いることで被験者の 6 つの行動 (座る、立つ、歩く、階段を上る、階段を下る、走る) を 92.5% の精度でリアルタイムに分類できることを示した。文献 [22] では、Zephyr 社の BioHarness BT (Bluetooth) を利用して被験者の加速度情報および生体情報を収集する。収集した加速度情報と生体情報に対して決定木分析を用いることで 3 つの活動 (走る、歩く、座る) を 92.6% の精度で分類できることを示した。また、様々なユーザのデータを学習させることによって再学習することなく新しいユーザに対応することができた。文献 [23] では、3 軸加速度センサを内蔵したデバイスを被験者の利き腕の手首に装着する。得られた 3 軸加速度センサ値に対してファジー基底関数を用いることで 7 つの活動 (歯を磨く、人に触れる、机をたたく、パソコンで作業する、走る、手を振る、歩く) を 94.71% の精度で分類できることを示した。

本研究で提案する Sensor-based Regulation Profiler では、名刺型センサから得られたセンサデータを用いて協調学習の様子や学習者の行動を可視化する。その一例として、名刺型センサに搭載した赤外線センサを用いて学習者間のネットワーク変化量を求めることで協調学習における学習フェーズの変化を自動的に抽出する。学習フェーズを自動抽出することで、学習活動の分析に要する時間を低減することができると同時に学習科学の研究者による適切なナビゲートが期待できる。

8.3 協調学習に対する分析手法

協調学習の学習効果を評価する一般的な手法としてビデオカメラなどで撮影した映像データと音声データを解析する手法がある。一方で映像データと音声データから学習効果を解析する手法では、以下の 2 つの課題が残されている。

- (1) 詳細な分析にコストがかかること
- (2) 研究者の主観が分析に含まれること

「1. 詳細な分析にコストがかかること」は、撮影した協調学習の映像を学習科学の研究者が何度も見返して学習者の台詞を書き起こす文字起こしと、非言語的行動を用いた協調を含む会話の分析に起因する。「2. 研究者の主観が分析に含まれること」は、学習者同士の会話を分析するにあたってどのような協調が行われているかを記述するときに研究者によって表記や配置のずれが生じてしまうことに起因する。

本研究では、上述の課題を解決するために、学習者から得たセンサデータにデータマイニング技術を用いることで協調学習を定量的に分析している。協調学習を定量分析することによってソーシャルグラフ・学習フェーズ・発話者を詳細かつ迅速に分析することができるため、協調学習の

詳細な分析をするうえでのコストを削減することができる。また、名刺型センサの利用によって学習者の様子を各センサの値として表すことができる。センサ値に基づく分析手法を導入することで研究者の主観によらない協調学習の分析が可能となる。

9. おわりに

本研究では、学習者の活動を定量的に分析して学習科学の研究者が着目すべきポイントを自動抽出して可視化する Sensor-based Regulation Profiler を提案した。Sensor-based Regulation Profiler を用いた実証実験から、名刺型センサ間で約 30 μ s の時刻同期精度を達成すること、協調学習中の学習者同士の対面を表すソーシャルグラフの自動抽出ができること、協調学習に参加した 3 名のうち誰が発話したかを平均約 77.8 % の精度で特定できることがわかった。

謝辞

本研究は JSPS 科研費 (JP16H01718, 18H03231, 19H01101) の支援の下で行った。

参考文献

- [1] 文部科学省, “高等学校学習指導要領 (平成 30 年告示),” https://www.mext.go.jp/content/1384661_6_1_3.pdf, March 2018, 2019/12/16 参照。
- [2] J. Oshima, R. Oshima, and Y. Matsuzawa, “Knowledge Building Discourse Explorer: A Social Network Analysis Application for Knowledge Building Discourse,” *Educational Technology Research and Development*, vol.60, no.5, pp.903–921, October 2012.
- [3] J. Oshima, R. Oshima, and W. Fujita, “A Multivocality Approach to Epistemic Agency in Collaborative Learning,” *The Computer Supported Collaborative Learning (CSCL) Conference 2015*, pp.62–69, Gothenburg, Sweden, July 2015.
- [4] J. Oshima, R. Oshima, and K. Fujii, “Student Regulation of Collaborative Learning in Multiple Document Integration,” *the Proceedings of the International Conference of the Learning Sciences*, vol.2, pp.967–971, January 2014.
- [5] J. Oshima, A. Ohsaki, Y. Yamada, and R. Oshima, “Collective Knowledge Advancement and Conceptual Understanding of Complex Scientific Concepts in the Jigsaw Instruction,” *12th International Conference on Computer Supported Collaborative Learning (CSCL) 2017*, pp.57–64, Philadelphia, Pennsylvania, USA, July 2017.
- [6] J. Oshima, R. Oshima, and W. Fujita, “A Mixed-Methods Approach to Analyze Shared Epistemic Agency in Jigsaw Instruction at Multiple Scales of Temporality,” *Journal of Learning Analytics*, vol.5, no.1, pp.10–24, April 2018.
- [7] R. K. Sawyer, *Cambridge Handbook of the Learning Sciences*, Second Edition, Cambridge University Press, 2014.
- [8] Y. Wakisaka, N. Ohkubo, K. Ara, N. Sato, M. Hayakawa, S. Tsuji, Y. Horry, K. Yano, and N. Moriwaki, “Beam-Scan Sensor Node: Reliable Sensing of Human Interactions in Organization,” *2009 Sixth International Conference on Networked Sensing Systems (INSS)*, pp.1–4, Pittsburgh, Pennsylvania, USA, June 2009.
- [9] L. Wu, B. Waber, S. Aral, E. Brynjolfsson, and A. Pentland, “Mining Face-to-Face Interaction Networks Using Sociometric Badges: Predicting Productivity in an IT Configuration Task,” *Proc International Conference on Information Systems*, p.127, Paris, France, December 2008.
- [10] M. Suzuki, C.H. Liao, S. Ohara, K. Jinno, and H. Morikawa, “Wireless-Transparent Sensing,” *Proceedings of the 2017 International Conference on Embedded Wireless Systems and Networks*, pp.66–77, Uppsala, Sweden, February 2017.
- [11] F. Ferrari, M. Zimmerling, L. Thiele, and O. Saukh, “Efficient Network Flooding and Time Synchronization with Glossy,” *Proceedings of the 10th ACM/IEEE International Conference on Information Processing in Sensor Networks*, pp.73–84, Chicago, Illinois, USA, April 2011.
- [12] Y. Matsubara, and Y. Sakurai, “Dynamic Modeling and Forecasting of Time-Evolving Data Streams,” *KDD’19: Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*, pp.458–468, Anchorage, Alaska, USA, August 2019.
- [13] Y. Matsubara, Y. Sakurai, and C. Faloutsos, “AutoPlait: Automatic Mining of Co-Evolving Time Sequences,” *Proceedings of the ACM SIGMOD International Conference on Management of Data*, pp.193–204, Snowbird, Utah, USA, June 2014.
- [14] J. Guo, and H. Hou, “Statistical Decision Research of Long-Term Deposit Subscription in Banks Based on Decision Tree,” *2019 International Conference on Intelligent Transportation, Big Data Smart City (ICITBS)*, pp.614–617, Changsha, China, January 2019.
- [15] J.R. Quinlan, “Induction of Decision Trees,” *Machine Learning*, vol.1, no.1, pp.81–106, March 1986.
- [16] H. Yan, H. Hu, and P. Yu, “A Study on Push Technology of Intelligent Agriculture Service Information Based on CART Algorithm,” *2019 International Conference on Robots Intelligent System (ICRIS)*, pp.258–260, Haikou, China, June 2019.
- [17] L. Breiman, J. Friedman, C.J. Stone, and R.A. Olshen, *Classification and Regression Trees*, Chapman & Hall/CRC, 1983.
- [18] 栗田多喜夫, “サポートベクターマシン入門,” <https://home.hiroshima-u.ac.jp/tkurita/lecture/svm.pdf>, July 2002, 2020/1/22 参照。
- [19] O. Lederman, D. Calacci, A. MacMullen, D. Fehder, F. Murray, and A. Pentland, “Open Badges: A Low-Cost Toolkit for Measuring Team Communication and Dynamics,” *2016 International Conference on Social Computing, Behavioral-Cultural Modeling & Prediction and Behavior Representation in Modeling and Simulation*, pp.1–7, Washington DC, USA, 2016.
- [20] M. Ermes, J. Pärkkä, and L. Cluitmans, “Advancing from Offline to Online Activity Recognition with Wearable Sensors,” *2008 30th Annual International Conference of the IEEE Engineering in Medicine and Biology Society*, pp.4451–4454, Vancouver, Canada, August 2008.
- [21] U. Maurer, A. Smailagic, D. P. Siewiorek, and M. Deisher, “Activity Recognition and Monitoring Using Multiple Sensors on Different Body Positions,” *International Workshop on Wearable and Implantable Body Sensor Networks (BSN’06)*, pp.113–116, Cambridge, Massachusetts, USA, April 2006.

- [22] Ó. D. Lara, and M. A. Labrador, “A Mobile Platform for Real-Time Human Activity Recognition,” 2012 IEEE Consumer Communications and Networking Conference (CCNC), pp.667–671, Las Vegas, Nevada, USA, January 2012.
- [23] T.P. Kao, C.W. Lin, and J.S. Wang, “Development of a Portable Activity Detector for Daily Activity Recognition,” 2009 IEEE International Symposium on Industrial Electronics, pp.115–120, Seoul, South Korea, July 2009.